UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
INSTITUTO FEDERAL DE FÍSICA
CURSO DE MESTRADO EM FÍSICA BACHARELADO

Leonardo Camargo Rossato

ANÁLISE COMPARATIVA DE INDICADORES SOCIOECONÔMICOS DE CIDADES NO BRASIL, ESTADOS UNIDOS E OUTROS PAÍSES

Porto Alegre, RS
2025

Leonardo Camargo Rossato

ANÁLISE COMPARATIVA DE INDICADORES SOCIOECONÔMICOS DE CIDADES NO BRASIL, ESTADOS UNIDOS E OUTROS PAÍSES

ORIENTADOR: Prof. Sebastián Gonçalves

COORIENTADOR: Prof. José Roberto Iglesias

Porto Alegre, RS
2025

RESUMO

ANÁLISE COMPARATIVA DE INDICADORES SOCIOECONÔMICOS DE CIDADES NO BRASIL, ESTADOS UNIDOS E OUTROS PAÍSES

AUTOR: Leonardo Camargo Rossato
ORIENTADOR: Sebastián Gonçalves
COORIENTADOR: José Roberto Iglesias

Comparar indicadores socioeconômicos entre países é um desafio devido às diferenças metodológicas na coleta, estruturação e nos critérios utilizados para o cálculo desses indicadores, ainda mais quando queremos comparar pequenas e médias cidades. Neste contexto, propomos uma abordagem multidisciplinar, com maior ênfase na econofísica, que combina comparações visuais e numéricas para analisar indicadores socioeconômicos de municípios no Brasil, Estados Unidos e nas Américas. Nossa metodologia se estrutura em três etapas principais: engenharia de dados; desenvolvimento e aplicação de técnicas de análise; e elaboração de dashboards para visualização dos resultados. Na primeira etapa, realizamos a extração, correção e estruturação de um banco de dados proveniente de fontes respeitadas em cada país. A segunda etapa identifica padrões visuais e métricos no conjunto de dados, aplicando técnicas como gráficos de dispersão (*scatter*), procedimentos de *binning* para padrões identificados (*binscatters*) e adaptação das dispersões em grafos. Nesta etapa, empregamos uma técnica original: o Algoritmo de Agrupamento Gravitacional adaptado da astrofísica (*B-GCA*). Na terceira etapa, exploramos relações significativas entre os indicadores, com um estudo de caso focado na relação logarítmica entre o IDH Municipal e o tamanho da população. Em alguns países, identificamos mínimos globais, sugerindo uma população crítica acima da qual os municípios apresentam uma tendência positiva e significativa no crescimento do IDH. Este trabalho se destaca pela integração de conceitos de econofísica, *visual analytics* e ciência de dados, culminando em uma aplicação web interativa para a visualização dos resultados e gráficos da tese. A ferramenta desenvolvida amplia as possibilidades de análise exploratória, permitindo também a formatação e carregamanto de novos conjuntos de dados, potencializando interpretações e novas descobertas sobre os indicadores socioeconômicos estudados.

Palavras-chave: Econofísica. *Visual analytics*. Ciência de dados. Sociofísica. Análise de Indicadores Socioeconômicos. Mecânica Estatística. *Overplotting*. Clusterização.

ABSTRACT

COMPARATIVE ANALYSIS OF SOCIOECONOMIC INDICATORS OF CITIES IN BRAZIL, THE UNITED STATES, AND OTHER COUNTRIES

AUTHOR: Leonardo Camargo Rossato
ADVISOR: Sebastián Gonçalves
CO-ADVISOR: José Roberto Iglesias

Comparing socioeconomic indicators across countries is a challenge due to methodological differences in data collection, structuring, and the criteria used for calculating these indicatorsespecially when the focus is on small and medium-sized cities. In this context, we propose a multidisciplinary approach, with a strong emphasis on econophysics, combining visual and numerical comparisons to analyze socioeconomic indicators of municipalities in Brazil, the United States, and the Americas. Our methodology is structured in three main stages: data engineering; development and application of analytical techniques; and the creation of dashboards for results visualization. In the first stage, we extract, correct, and structure a database compiled from reputable sources in each country. The second stage identifies visual and metric patterns in the dataset, applying techniques such as scatter plots, binning procedures for identified patterns (binscatters), and adapting scatter plots into graphs. At this stage, we employ an original technique: the Gravitational Clustering Algorithm adapted from astrophysics (B-GCA). In the third stage, we explore significant relationships among the indicators, with a case study focused on the logarithmic relationship between the Municipal Human Development Index (MHDI) and population size. In some countries, we identify global minima, suggesting a critical population threshold above which municipalities tend to show significant and positive growth in MHDI. This work stands out for its integration of concepts from econophysics, visual analytics, and data science, culminating in an interactive web application for visualizing the results and graphics presented in the thesis. The developed tool expands the possibilities of exploratory analysis, also allowing the formatting and uploading of new datasets, enhancing interpretation and fostering new discoveries regarding the socioeconomic indicators under study.

Keywords: Econophysics. *Visual analytics*. Data Science. Sociophysics. Socioeconomic Indicators Analysis. Statistical Mechanics. Overplotting. Clustering.

LISTA DE FIGURAS

Figura 1.1 – Abordagem Multidisciplinar para análise de indicadores socioeconômicos integrando econofísica, *visual analytics* e ciência de dados. 20
Figura 2.1 – Fluxograma das etapas metodológicas desta pesquisa, dividido em três fases principais: (1) Engenharia de dados, envolvendo a coleta, preparação e padronização dos dados; (2) Desenvolvimento e aplicação de técnicas de análise de dados, utilizando métodos exploratórios e algoritmos avançados, como B-GCA e *binscatter plots*; e (3) Análise, comparação e Representação dos resultados, por meio de gráficos, tabelas, visualizações interativas e *dashboards*. 21
Figura 2.2 – Conversão da escala normal para uma escala log-log de um gráfico de dispersão do índice IDH para cada município (cada ponto), em relação à sua população absoluta. Posteriormente, o gráfico de dispersão é dividido em 5 cores, correspondendo às macrorregiões administrativas do Brasil. 23
Figura 2.3 – Gráfico de dispersão representando a dispersão do IDH para cada município na macrorregião sul com base em suas respectivas populações. Posteriormente, o gráfico é segmentado em regiões (estados), sugerindo que o surgimento do padrão de dispersão subjacente ocorre independentemente da escala. Abreviações dos Estados: RS - Rio Grande do sul, SC - Santa Catarina e PR - Paraná. 23
Figura 2.4 – Comparação das dispersões do IDH por população em quatro das cinco macrorregiões do Brasil, em relação a um estado representativo de cada macrorregião. Destacando o potencial surgimento de padrões semelhantes em ambas as escalas macro e regional. Abreviações dos Estados: MT - Mato Grosso, BA - Bahia, SP - São Paulo e AM - Amazonas. A região norte parece ser uma exceção. 24
Figura 2.5 – Divisão da dispersão em *bins*, com cada ponto representando a média em ambos os eixos para cada *bin* correspondente. O conjunto dos pontos gerados, é entendido como uma curva *binscatter*, na qual foi aplicado um ajuste linear, pelo método dos mínimos quadrados (MMQ), do ponto do mínimo global ao último ponto na amostra. 25
Figura 2.6 – processo de transformar um gráfico de dispersão em um grafo usando uma variação autoral do “Algoritmo de Agrupamento Gravitacional” (GCA). O plano métrico é baseado na taxa de DPI do monitor e a formulação do Raio de Corte é arbitrária. 28
Figura 3.1 – Comparação entre o gráfico de dispersão (*scatter plot*) e a respectiva curva “binscatter” (Sec. 2.3). Os países analisados incluem: Brasil, Chile, Peru, México, El Salvador e EUA. 34
Figura 3.2 – Comparação das curvas *binscatter lines*, geradas pelo processo de divisão de *bins* (Sec. 2.3) dos respectivos gráficos de dispersão (scatters) entre IDH e população para as unidades administrativas de cada país. .. 35
Figura 3.3 – Comparação entre o gráfico de dispersão e a respectiva curva *binscatter* após o processo de conversão de gráfico usando B-GCA (Sec. 2.4). Os países analisados incluem: Brasil, Chile, Peru, México, El Salvador e EUA. 37
Figura 3.4 – Tabela contendo informações estatísticas das redes (gráficos) correspon-

dentes para cada país após o processo de conversão do gráfico de dispersão usando B-GCA (Sec. 2.4). 38
Figura 3.5 – Representação gráfica de quatro variáveis da tabela (Fig. 3.4), correspondendo a: Grau Médio, Variância, Desvio Padrão e Excentricidade, usando gráficos de barra e linha. 38
Figura 3.6 – Ilustração das 5 macrorregiões do Brasil, representadas com duas formatações visuais das mesmas amostras de dados. Acima, subítem a), com *subplots* indepentes; abaixo, subítem b) com todas curvas *binscatter* plotadas em um mesmo gráfico, mantendo os mesmo limites de *bins* para todas curvas. 40
Figura 3.7 – Comparação lado a lado, de todos *scatter plots* das macrorregiões brasileiras e do Brasil. 42
Figura 3.8 – *Subplots* independentes contendo *scatter plots* (gráficos de dispersão) lado a lado da macrorregião sudeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: Brasil, macrorregião sudeste, Espirito Santo (ES), Rio de Janeiro (RJ), São Paulo (SP) e Minas Gerais (MG). 43
Figura 3.9 – *Subplots* independentes contendo *binscatter lines* lado a lado da macrorregião sudeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: Brasil, macrorregião sudeste, Espirito Santo (ES), Rio de Janeiro (RJ), São Paulo (SP) e Minas Gerais (MG). 44
Figura 3.10 – *Binscatter lines* sobrepostos em um mesmo gráfico, mantendo mesmo limites de *bins* para todas curvas, da macrorregião sudeste, Brasil. 45
Figura 3.11 – *Subplots* independentes contendo *scatter Plot* (gráficos de dispersão) lado a lado da macrorregião sul, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião sul, Paraná (PR), Santa Catarina (SC) e Rio Grande do sul (RS). 47
Figura 3.12 – *Subplots* independentes contendo *binscatter lines* lado a lado da macrorregião sudeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião sul, Paraná (PR), Santa Catarina (SC) e Rio Grande do sul (RS). 47
Figura 3.13 – *Binscatter lines* sobrepostos em um mesmo gráfico, mantendo mesmo limites de *bins* para todas curvas, da macrorregião sul, Brasil. 48
Figura 3.14 – *Subplots* independentes contendo *scatter plots* (gráficos de dispersão) lado a lado da macrorregião nordeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião nordeste, Pernambuco (PE), Alagoas (AL), Piauí (PI), Bahia (BA), Paraíba (PB), Ceara (CE), Rio Grande do norte (RN), Maranhão (MA) e Sergipe (SE). 49
Figura 3.15 – *Subplots* independentes contendo *binscatter lines* lado a lado da macrorregião nordeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião nordeste, Pernambuco (PE), Alagoas (AL), Piauí (PI), Bahia (BA), Paraíba (PB), Ceara (CE), Rio Grande do norte (RN), Maranhão (MA) e Sergipe (SE). 50
Figura 3.16 – *Binscatter lines* sobrepostos em um mesmo gráfico, mantendo mesmo limites de *bins* para todas curvas, da macrorregião nordeste, Brasil. 51
Figura 3.17 – Subplots independentes contendo *scatter plots* (gráficos de dispersão) lado a lado da macrorregião norte, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião norte, Pará (PA), Acre

(AC), Rondônia (RO), Amazonas (AM), Roraima (RR), Amapá (AP) e Tocantins (TO). 52
Figura 3.18 – Subplots independentes contendo *binscatter lines* lado a lado da macrorregião norte, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião norte, Pará (PA), Acre (AC), Rondônia (RO), Amazonas (AM), Roraima (RR), Amapá (AP) e Tocantins (TO). 53
Figura 3.19 – *Binscatter lines* sobrepostos em um mesmo gráfico, mantendo os mesmo limites de *bins* para todas curvas, da macrorregião norte, Brasil. 54
Figura 3.20 – Subplots independentes contendo *scatter plots* (gráficos de dispersão) lado a lado da macrorregião centro-oeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião centro-oeste, Goiás (GO), Mato Grosso do sul (MS) e Mato Grosso (MT). 54
Figura 3.21 – Subplots independentes contendo *binscatter lines* lado a lado da macrorregião centro-oeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião centro-oeste, Goiás (GO), Mato Grosso do sul (MS) e Mato Grosso (MT). 55
Figura 3.22 – *Binscatter lines* sobrepostos em um mesmo gráfico, mantendo mesmo limites de *bins* para todas curvas, da macrorregião centro-oeste, Brasil. . 55
Figura 3.23 – Comparação entre diferentes alternaltivas de cálculo de correlação. Adicionalmente, há *subplots* da variância, média e mediana do IDHM e da população. Todas essas imagens, representam o comportamento das métricas em função de uma diminuição progressiva do tamanho da amostra. 57
Figura A.1 – Tabela estatistica contendo informações de correlação de Pearlson, mínimo, máximo, média e mediana (de IDHM e População) para 100% da amostra dos scatters de todas macrorregiões e estados do Brasil. 66
Figura B.1 – Histograma contendo informações de mínimo, máximo, média e mediana (do IDHM) para 100% da amostra dos scatters de todas macrorregiõesdo Brasil. 67
Figura B.2 – Histograma contendo informações de mínimo, máximo, média e mediana (do IDHM) para 100% da amostra dos scatters de todos estados do Brasil. 68
Figura C.1 – Raio de corte = 5 69
Figura C.2 – Case +10% | Raio de corte = 5,5 69
Figura C.3 – Case -10% | Raio de corte = 4,5 69
Figura C.4 – Tabelas de diferença percentual: entre Raio de corte = 5 vs os Casos (+10%) 70
Figura C.5 – Tabelas de diferença percentual: entre Raio de corte = 5 vs os Casos (-10%) 70
Figura C.6 – Caso EUA: Resultados B-GCA | Raio de corte = 5 71
Figura C.7 – Caso EUA: Resultados B-GCA | Raio de corte = 5 + 10% 71
Figura C.8 – Caso EUA: Resultados B-GCA | Raio de corte = 5 -10% 71
Figura C.9 – Caso Chile: Resultos B-GCA | Raio de corte = 5 72
Figura C.10 – Case Chile: Result B-GCA | Raio de corte = 5 + 10% 72
Figura C.11 – Case Chile: Result B-GCA | Raio de corte = 5 - 10% 72
Figura D.1 – Captura de tela do dashboard principal com 3 técnicas mais complexas: NormalScatter, Binscatter e ScatterGraph (não definida e apresentada nesta tese). Além disso, inclui o modo de Análise de Distribuição e Histogramas de Dataframes. Também apresenta 3 ferramentas simples para

comparação: cidades, macrorregiões e países. 73
Figura D.2 – Gráfico de dispersão (*scatter)* dos EUA, com escala log-log e dividida por cores discretas de Macrorregiões: IDH por cidades vs População. Além disso, boxplots marginais para as distribuições de cada eixo, onde cada cor representa uma macrorregião. 74
Figura D.3 – Distribuições com análise de histogramas para identificar o melhor número de intervalos (*bins*) a ser utilizado no processo de *binscatter*, para o caso do México. Em seguida, um gráfico contendo apenas a linha do *binscatter* é plotado junto com a curva de ajuste. Por fim, uma ilustração didática comparando *binscatter* com *scatter*. 75
Figura D.4 – Ferramenta para comparar cidades, entre países ou dentro do mesmo país. Na versão alfa, estão disponíveis apenas as técnicas apresentadas no trabalho. Entretanto, em versões futuras mais aprimoradas, pretendemos adicionar muitas outras funcionalidades. 76

LISTA DE ABREVIATURAS E SIGLAS

$BGCA$	Based on Gravitional Clustering Algorithm (B-GCA)
IDH	Índice de Desenvolvimento Humano
$IDHM$	Índice de Desenvolvimento Humano Municipal
$PNUD$	Programa das Nações Unidas para o Desenvolvimento

SUMÁRIO

1 Introdução 12
1.1 Conceitos Fundamentais e algumas delimitações das áreas envolvidas 14
1.1.1 Econofísica 14
1.1.2 Econofísica e Econometria 15
1.1.3 Econofísica e Sociofísica 16
1.1.4 *Visual Analytics* 16
1.1.5 Ciência de dados 17
1.1.6 Indicadores Sociais 18
1.2 Abordagem multidisciplinar: econofísica, *visual analytics* e ciência de dados 19
2 Modelos e Metodologia 21
2.1 Fluxograma da metodologia 21
2.2 Construção dos bancos de dados e Detecção de Padrões Emergentes Livre de escala 22
2.3 Binscatter process 24
2.3.1 Metodologia para Divisão dos Bins 26
2.4 Based on Gravitational Clustering Algorithm (B-GCA) 28
2.5 Estudo de Caso: IDHM x População de Municípios do Brasil 29
2.5.1 Conversão de Escala e Codificação por Cores 29
2.5.2 Geração dos Gráficos 29
2.5.3 Organização Visual 29
2.5.4 Tabelas Estatísticas 30
2.5.5 Análise comparativa e *visual analytics* 30
2.5.6 Discussão Metodológica 30
2.5.7 Correlação, Variança e outras métricas 31
3 Resultados 33
3.1 IDHM x População: Comparação entre países das Américas 33
3.1.1 Binscatter Plots 33
3.1.2 Baseado em GCA (B-GCA) 36
3.2 Estudo de Caso: IDHM vs População dos Municípios do Brasil em nível macrorregional e regional (estadual) 39
3.2.1 Análise por macrorregião 43
3.2.1.1 Sudeste 43
3.2.1.2 Sul 47
3.2.1.3 Nordeste 49
3.2.1.4 Norte 52
3.2.1.5 Centro-Oeste 54
3.2.2 Resultados para Métricas Estatísticas: correlação, variança entre outras 56
4 Conclusão 58
4.1 Trabalhos Futuros 59
4.2 Agradecimentos 60
4.3 Bancos de Referências 60
4.3.1 Informações Suplementares (S.I) 60
Referências Bibliográficas 62
A Apêndice: Tabela com informações estatísticas complementares dos estados e macrorregiões do Brasil 66

B Apêndice: Histogramas para todas macrorregiões e estados (Regiões) no Brasil 67
C Apêndice: Análise Simples de robustez e influência dos valores do Raio de corte (comparação entre países) 69
D Apêndice: City Comparing 73

1 INTRODUÇÃO

A análise de indicadores sociais é um campo que apresenta desafios inerentes devido à complexidade de sua coleta, interpretação e comparação dos dados. Essa complexidade é amplificada pela diversidade metodológica utilizada nos cálculos e apresentações dos dados entre diferentes regiões e países. Frente a esse cenário, a presente tese adota uma abordagem multidisciplinar, fundamentada principalmente na econofísica, e explora principalmente soluções visuais; em segundo, métricas, para propor e contribuir com bases para soluções mais sólidas no futuro que possam superar essas complexidades inerentes da área.

Um dos desafios iniciais na comparação de indicadores socioeconômicos entre países é a diversidade de medidas e critérios utilizados em diferentes regiões. Essa dificuldade tem sido reconhecida e discutida em diversos artigos contemporâneos e clássicos da área (BOOZER et al., 2003; SOLIGO, 2012; HERRERO; MARTíNEZ; VILLAR, 2018). Uma solução potencial é a definição de indicadores padronizados baseados em modelos fundamentais, que deveriam ser aceitos por institutos internacionais. Este método, até certo ponto, tem obtido êxito na implementação de certos indicadores em nível global, como o Índice de Desenvolvimento Humano (IDH). No entanto, há pressões constantes por mudanças nos critérios de avaliação; além disso, a aplicação do IDH é, de certa forma, restrita pela adaptação de cálculos padrão para as condições locais de cada país (SOLIGO, 2012; NOORBAKHSH, 1998; NEUMAYER, 2001; JAHAN, 2002; STANTON, 2007; KLUGMAN; RODRíGUEZ; CHOI, 2011; ANTO, 2011; NAYAK, 2013; SALAS-BOURGOIN, 2014; ZIROGIANNIS et al., 2018). Por exemplo, podemos citar algumas propostas alternativas e ajustes globais ao IDH, como o IHDI (IDH ajustado à desigualdade) (HICKS, 1997), o PHDI (IDH ajustado às pressões ambientais) (ROY et al., 2022), e o EHDI (IDH ajustado pela eficiência) (DALBERTO et al., 2015). Além disso, existem propostas que não definem seus próprios acrônimos (siglas), apresentando apenas sugestões de mudanças para índices conhecidos (HESHMATI; OH, 2006; SALAS-BOURGOIN, 2014). Em nível local, no Brasil, podemos citar o IDHM (IDH municipal), IFDM (Índice FIRJAN de Desenvolvimento Municipal), IRFS (Índice de Responsabilidade Fiscal, Social e de Gestão) (SILVA et al., 2015) e o ELECTRE TRI-C (*Elimination Et Choix Traduisant la Réalité)* [1]

Nesta dissertação, devido às dificuldades já mencionadas de comparar diferentes países por meio de um único índice comum a todos, calculado exatamente da mesma forma, optamos por analisar um conjunto de indicadores, que consideramos, “equivalentes”. Para isso, determinamos alguns critérios como: os indicadores escolhidos possuem a mesma dimensionalidade no cálculo e utilizam as mesmas variáveis analisadas. Mais especificamente, se selecionamos um índice com “n” componentes, como o IDHM, que

[1] O ELECTRE TRI é uma versão do método que lida especificamente com problemas de classificação ordenada, onde alternativas são alocadas em categorias pré-definidas, baseadas na comparação com perfis de referência. Sendo o sufixo C, uma variante do ELECTRE TRI. (PEREIRA; MOTA, 2016).

considera três dimensões —“renda”,“educação” e “saúde”—, apenas índices equivalentes, que também possuam essas mesmas “n” componentes, serão comparados. Por exemplo, o Chile alterou o padrão de cálculo da componente “renda”, modificando os valores absolutos do índice equivalente ao IDH municipal. No entanto, a estrutura do índice foi mantida, com as mesmas três dimensões (“renda”, “educação” e “saúde”), o que possibilitou sua inclusão no banco de dados para análise e comparação. Por outro lado, índices que possuam um número diferente de componentes (por exemplo, 4 ou 6) não são considerados. Da mesma forma, mesmo que um índice tenha a mesma quantidade de componentes, ele não será incluído se as variáveis analisadas forem diferentes. Um exemplo disso é o IRFS, composto por três dimensões distintas: Índice de Responsabilidade Fiscal (IRF), Índice de Responsabilidade Social (IRS) e Índice de Responsabilidade de Gestão (IRG), que não correspondem às variáveis utilizadas no IDHM —mesmo que o IRFS ainda tenha o mesmo objetivo de comparar os municípios, tão qual o IDHM.

Diante dessa complexidade metodológica, a abordagem adotada nesta dissertação não apenas propõe um critério mais estruturado para a comparação de índices, mas também abre caminho para uma análise mais profunda das diferenças entre as métricas utilizadas por diferentes países. Nesse sentido, este trabalho se insere em uma perspectiva da econofísica, que utiliza técnicas da mecânica estatística e de outras áreas da física para investigar sistemas socioeconômicos, diferenciando-se da abordagem tradicional da econometria.

Embora os dados socioeconômicos sejam a base da análise, a ênfase neste trabalho vai além da econometria clássica, buscando padrões, leis de escala ou de universalidade nos dados, algo mais característico da ciência de dados e da econofísica. Enquanto a econometria se concentra principalmente em regressões lineares ou multilaterais, este estudo faz uso de técnicas adaptadas da astrofísica e da teoria de redes. Embora regressões lineares sejam aplicadas na etapa inicial para identificar correlações em indicadores sociais, o objetivo principal é construir visualizações e modelos que transcendam a relação linear, incorporando metodologias como análise visual, entre outras.

Além da abordagem conceitual, um ponto fundamental desta dissertação é o desenvolvimento, implementação e otimização de técnicas e algoritmos que podem ser aplicados em diversas áreas além do contexto específico dos dados socioeconômicos. Entre as contribuições metodológicas, destacam-se tanto as técnicas de análise de dados quanto as de engenharia de dados, voltadas para a integração de bases provenientes de diferentes fontes e países, como o IBGE (Instituto Brasileiro de Geografia e Estatística), o IPEA (Instituto de Pesquisa Econômica Aplicada) e instituições internacionais. Essa integração possibilita a construção de um banco de dados, essencial para uma análise exploratória mais abrangente e detalhada.

Adicionalmente, algoritmos personalizados, como uma variante autoral do *Gravitational Clustering Algorithm (GCA)*, que nomeamos pelo acrônimo B-GCA (Based on GCA),

são desenvolvidos para agrupar unidades administrativas (municípios e equivalentes) com características socioeconômicas semelhantes, oferecendo alternativas para as limitações impostas por escalas ou normalizações tradicionais. Essa técnica transforma *scatter plots* em grafos e configura-se como uma forma de clusterização de dados, permitindo diferentes aplicações, como a colorização dos *scatter plots* originais e oferecendo uma solução visual para o problema de *overplotting*.[2]

Complementarmente, elaboramos uma aplicação web City Comparing [3] [4] capaz de gerar representações gráficas interativas, como gráficos de dispersão (*scatter plots*) em escala normal e logarítmica; *binscatters*, que permitem identificar padrões de dados emergentes e facilitam a exploração por parte de pesquisadores e gestores; grafos gerados a partir de B-GCA (definido na seção de metodologia 2); além de outras técnicas não abordadas nesta dissertação. Essa abordagem visual amplia o escopo das análises tradicionais, possibilitando novas formas de interpretação e comparabilidade entre sistemas heterogêneos e multiescala.

1.1 Conceitos Fundamentais e algumas delimitações das áreas envolvidas

Ao longo deste trabalho, foi necessário compreender melhor os limites e as especificidades de cada uma das áreas envolvidas (Econometria, Econofísica, Ciência de Dados, etc) para caracterizar e especificar adequadamente a metodologia proposta, cuja essência é multidisciplinar. Apesar dessa natureza multidisciplinar, buscou-se identificar as principais áreas que fundamentam o estudo, bem como definir a abordagem predominante, que se mostrou mais alinhada à Econofísica. Com essa contextualização, foram elaboradas subseções que descrevem, de forma concisa e introdutória, os conceitos fundamentais, as áreas que tangenciam o trabalho e as principais questões relacionadas às delimitações científicas e metodológicas que compõem essa abordagem multidisciplinar.

1.1.1 Econofísica

Econofísica é um campo interdisciplinar de pesquisa que aplica ferramentas e métodos da física, estatística e matemática à análise de sistemas econômicos, sociais e financeiros. O termo econofísica foi usado pela primeira vez na Conferência Internacional de Física Estatística em Kolkata em 1995, através da união dos termos economia e física

[2] Overplotting ocorre quando muitos pontos em um gráfico se sobrepõem, dificultando a visualização precisa da distribuição dos dados, inclusive em análises de indicadores socioeconômicos *(Scientometrics x SocioIndicators)* (BRAUN; SCHUBERT, 1988).

[3] Na data de publicação dessa tese, a ferramenta web encontra-se em versão alfa, indicando que usuários que acessarem posteriormente, provavelmente encontrarão versões mais recentes, com novas funcionalidades e recursos.

[4] Caso o site/URL não esteja acessível, consulte a aplicação atual no repositório oficial da dissertação ou acesse o site da empresa pessoal do autor:
hrefhttps://institutopensemais.com/Instituto Pense Mais.

(CHAKRABORTI et al., 2011). De acordo com Mantegna e Kertész (2011), a aproximação entre o campo da física e o de economia não é recente, com diversas analogias já feitas em estudos anteriores, tais como o modelo de passeio aleatório de Bachelier (1900), Bachelier (2006) e o modelo de precificação de Black e Scholes (1973). Desde então, a área cresceu rapidamente e hoje em dia engloba uma grande variedade de tópicos, incluindo análise de séries temporais financeiras, simulações de modelos econômicos, análise de redes socioeconômicas, além da análise de indicadores e descoberta de padrões emergentes em sistemas socioeconômicos.

De acordo com Schinckus (2016), existem três abordagens principais na econofísica [5]: (i) a **Econofísica Estatística**, que busca identificar padrões macroscópicos emergentes por meio de grandes volumes de dados e análises estatísticas; (ii) a **Econofísica Baseada em Agentes Bottom-Up**, que simula interações individuais para entender como comportamentos micro geram padrões macro; e (iii) a **Econofísica Baseada em Agentes Top-Down**, que parte de padrões macro conhecidos e busca modelar interações micro que os reproduzam.

Considerando a metodologia adotada nesta dissertação, —como a análise de dispersão por ”binscatter” e a construção de grafos com base no algoritmo proveniente da astrofísica de aglomeração gravitacional— verifica-se que o trabalho está alinhado com a abordagem da **Econofísica Estatística**. Outro estudo que podemos citar dessa abordagem é o de Barza et al. (2024), que também utiliza análises de dispersão (*scatter plots*) para identificar padrões emergentes em indicadores (nesse caso, mais econômicos do que sociais) relacionados à mobilidade econômica em cidades brasileiras. Assim como nesta dissertação, o trabalho busca reconhecer padrões universais, livres de escala, que se manifestam no conjunto de dados, utilizando técnicas de visualização e análise empírica. Essa convergência metodológica reforça a semelhança entre os dois estudos na busca por regularidades em sistemas socioeconômicos, como é o caso da análise do comportamento e comparação de indicadores em cidades.

1.1.2 Econofísica e Econometria

Segundo Baltagi (2011), *“[...] a econometria pode ser definida como a análise quantitativa dos fenômenos econômicos ocorridos com base no desenvolvimento paralelo da teoria e das observações e com o uso de métodos de inferência adequados”*. Com isso, é notável a interdisciplinaridade entre a teoria econômica, a matemática e a estatística para analisar e quantificar relações socioeconômicas. É uma área que busca aplicar métodos quantitativos e estatísticos para estudar os fenômenos econômicos, testar hipóteses, desenvolver modelos e prever comportamentos futuros. E, dentre as técnicas que podem ser destacadas, incluem-se: regressão linear, análise de séries temporais, análise de da-

[5] Sem incluir a área de finanças e series temporais

dos de painel e modelos de séries temporais não lineares. Em síntese, a econometria é amplamente utilizada em pesquisa acadêmica, bem como em empresas e instituições governamentais, para analisar dados econômicos e fazer previsões sobre o desempenho futuro da economia.

Embora esta dissertação utilize técnicas econométricas, como a análise de correlações entre indicadores socioeconômicos, o foco recai em abordagens mais complexas. Destacam-se o uso do método *binscatter* para identificar padrões emergentes, a aplicação de uma variante autoral do algoritmo de *clustering* gravitacional (GCA) e a padronização da escala logarítmica nas representações entre os indicadores analisados. Essas abordagens têm inspiração na física estatística e na astrofísica.

Outra distinção em relação à econometria tradicional diz respeito ao tratamento de dados considerados anômalos. Enquanto os métodos econométricos costumam excluir os *outliers* com o intuito de assegurar a normalidade estatística Schinckus (2016), a econofísica os encara como potenciais fontes de informação relevante. Esses dados extremos são vistos não como ruídos a serem eliminados, mas como manifestações que podem revelar propriedades ocultas ou padrões significativos no comportamento de sistemas complexos.

1.1.3 Econofísica e Sociofísica

A sociofísica é um campo interdisciplinar que aplica métodos das ciências físicas, especialmente da física estatística, para modelar e compreender fenômenos sociais, como a propagação de opiniões, dinâmicas de grupos e comportamento coletivo. Segundo Castro e Paula (2020), a sociofísica busca descrever e simular padrões sociais por meio de modelos matemáticos e estatísticos, com o objetivo de identificar regularidades e dinâmicas coletivas emergentes a partir de interações individuais. Embora compartilhe métodos quantitativos com a econofísica, a sociofísica se diferencia pela maior ênfase em fenômenos sociais, frequentemente relacionados a processos de interação humana e dinâmica de opiniões.

Embora esta dissertação aborde aspectos sociais e possibilite em algum nível caminhos para interpretações mais sociológicas, o foco central reside na análise objetiva do comportamento e da interação de um conjunto de indicadores equivalentes, sejam econômicos ou sociais, entre cidades de diferentes países. Ao evitar o uso de referências em teorias sociológicas, como também de interpretações sociais aprofundadas, entendemos que o estudo se alinha mais diretamente aos pressupostos da econofísica.

1.1.4 *Visual Analytics*

Visual analytics é uma disciplina interdisciplinar que combina visualização de dados, análise computacional e interação humana para possibilitar a exploração e a compreensão de grandes volumes de dados. Segundo Keim et al. (2008), *visual analytics* é a ciência

da análise analítica apoiada por interfaces visuais interativas. A área tem como objetivo integrar as capacidades cognitivas humanas com o poder das máquinas para lidar com dados complexos e identificar padrões, tendências e *outliers* de maneira intuitiva.

As metodologias geralmente incluem, mas não se limitam a: redução de dimensionalidade, com métodos como PCA (Principal Component Analysis) para comprimir dados multidimensionais em componentes principais visíveis; interatividade, com ferramentas de análise exploratória que permitem manipular gráficos em tempo real, ajustando filtros e critérios; e integração com inteligência artificial, onde o aprendizado de máquina destaca padrões relevantes e prevê tendências futuras (SACHA et al., 2014).

Além disso, é amplamente utilizada em diversas áreas do conhecimento, como saúde, economia, ciências ambientais e segurança pública. Em indicadores socioeconômicos, por exemplo, facilita a análise de padrões em dados demográficos, econômicos e de desenvolvimento humano, fornecendo *insights* sobre características sociais e dinâmicas regionais. Um dos principais benefícios é sua capacidade de mitigar o problema de *overplotting* em visualizações complexas. Técnicas como agrupamento, redução de dimensionalidade e uso de gráficos interativos são comumente empregadas para lidar com esse desafio (MAYORGA; GLEICHER, 2013).

No contexto de indicadores socioeconômicos, *visual analytics* possibilita análises mais profundas ao combinar visualizações interativas com dados de várias fontes, como censos e relatórios governamentais. Por exemplo, técnicas de *binning*, *scatter plots* interativos e representações logarítmicas têm sido utilizadas para identificar padrões não lineares em dados de desenvolvimento humano e população (HEER; BOSTOCK; OGIEVETSKY, 2010).

1.1.5 Ciência de dados

Ciência de dados, ou *Data Science*, é um campo interdisciplinar que combina estatística, matemática, programação e conhecimento de domínio com o objetivo de analisar, modelar e interpretar dados para apoiar a tomada de decisões, prever tendências e resolver problemas complexos. Segundo Provost e Fawcett (2013), *ciência de dados é um conjunto de princípios fundamentais que orientam a extração sistemática de informações e conhecimento a partir dos dados, permitindo a modelagem preditiva e a tomada de decisão orientada por dados*.

Podemos estruturá-la em torno de três componentes principais: engenharia de dados, que envolve a coleta, armazenamento e processamento de dados utilizando tecnologias como bancos de dados relacionais e ferramentas para *Big Data*; análise estatística e algoritmos, que aplicam métodos estatísticos e técnicas de aprendizado de máquina para modelar padrões e prever comportamentos; e visualização de dados, que utiliza gráficos, *dashboards* e visualizações interativas para comunicar os resultados de forma clara e com-

preensível.

O principal objetivo da ciência de dados é transformar dados brutos em *insights* dados úteis para a tomada de decisão. Em aplicações socioeconômicas, por exemplo, pode ser usada para identificar características sociais, prever tendências econômicas ou modelar o impacto de políticas públicas (CAO, 2017). Também, para combinar dados censitários, informações econômicas e indicadores sociais com o objetivo de explorar relações entre variáveis como renda, educação e desenvolvimento humano.

No contexto desta tese, essa área desempenha um papel crucial ao fornecer as bases para a integração e análise dos dados socioeconômicos. Ferramentas como algoritmos de clusterização e análise exploratória são integradas com as abordagens da econofísica para entender a complexidade dos sistemas socioeconômicos, enquanto técnicas de *visual analytics* tornam os resultados mais acessíveis e compreensíveis.

1.1.6 Indicadores Sociais

Segundo Santagada (1993), os indicadores sociais têm sido amplamente aceitos desde sua criação e são utilizados até em planejamentos governamentais em muitos países. Todavia, no Brasil, a utilização de indicadores sociais como instrumento de planejamento é relativamente recente, pois só foi introduzida a partir de 1975. De acordo com Jannuzzi (2002), um indicador social é uma medida quantitativa com um significado social substancial, que pode substituir, quantificar ou operacionalizar um conceito social abstrato, de interesse teórico (para pesquisa acadêmica) ou programático (para a formulação de políticas). Conforme as afirmações de Soligo (2012), os indicadores sociais não possuem o mesmo grau de consenso e força explicativa que os indicadores utilizados nas ciências exatas. Além disso, sua eficácia para explicar os fenômenos analisados varia de acordo com o espaço e o tempo. Portanto, um indicador útil em uma determinada região ou época pode não ser tão proveitoso em outra região ou momento, mesmo dentro da mesma região.

De acordo com Jannuzzi (2002), para um indicador ser útil na pesquisa acadêmica ou na formulação e avaliação de políticas públicas, é necessário que tenha uma ampla cobertura populacional, seja sensível a políticas públicas, específico em relação a programas setoriais, inteligível para o público-alvo das políticas, atualizável a custos razoáveis e amplamente desagregável em termos geográficos, socioeconômicos e sociodemográficos. Além disso, é fundamental que tenha historicidade para permitir comparações ao longo do tempo e que os procedimentos de construção sejam transparentes e justificados, com as escolhas subjetivas claramente explicitadas. Embora os indicadores compostos, como o IDH, apresentem hipóteses arbitrárias, eles continuam sendo elaborados e divulgados, como o Índice de Condições de Vida Municipal (ICV) da Fundação João Pinheiro e o Índice de Qualidade Institucional Municipal do Ministério do Planejamento (JANNUZZI, 2002)(Guimarães e Jannuzzi, 2005) e o IDHM (IDH municipal) —que utilizamos neste trabalho como

padrão de comparação de características socioeconômicas dos municípios.

1.2 Abordagem multidisciplinar: econofísica, *visual analytics* e ciência de dados

A escolha de uma abordagem multidisciplinar nesta pesquisa, como já mencionada no texto inicial do capítulo de introdução [1], é motivada principalmente pela necessidade de encontrar soluções para lidar com as complexidades da análise de indicadores sociais entre países de maneira integrada. A combinação de **econofísica** [sessão: 1.1.1], ***visual analytics*** [sessão:1.1.4] e **ciência de dados** [sessão:1.1.5] implementa uma sinergia que permite o tratamento de grandes volumes de dados heterogêneos, a visualização interativa de padrões emergentes e a modelagem do comportamento de sistemas socioeconômicos.

Inicialmente, a abordagem adotada foi fortemente influenciada pela econofísica, partindo do estudo dos indicadores sociais sob uma perspectiva baseada em modelos físicos. Um dos principais aspectos dessa perspectiva foi a utilização de gráficos em escala log-log, em substituição às representações convencionais, com o objetivo de identificar padrões independentes de escala. Essa estratégia permitiu uma análise comparativa mais abrangente, superando limitações regionais, macrorregionais e nacionais, e possibilitando a investigação de regularidades estruturais em diferentes escalas amostrais e contextos socioeconômicos. Além disso, a aplicação do B-GCA (*Based on Gravitational Clustering Algorithm*), um método autoral inspirado em algoritmos da astrofísica, reforçou a perspectiva da econofísica no tratamento dos dados.

A necessidade de aprimorar a estruturação e organização dos dados tornou-se evidente ao longo do desenvolvimento do estudo, demandando técnicas que otimizassem a análise exploratória e a extração de informações relevantes. Esse aspecto levou à incorporação de métodos provenientes da Ciência da Computação, possibilitando um tratamento mais eficiente dos dados e o suporte à aplicação de técnicas avançadas para identificação de padrões e tendências.

A complexidade dos dados analisados, aliada ao problema de *overplotting*, exigiu soluções que garantissem maior clareza na representação das informações. Nesse contexto, a adoção de princípios de *visual analytics* permitiu o desenvolvimento de representações otimizadas e interativas, resultando na implementação de uma aplicação web com *dashboards* dinâmicos. Essa ferramenta viabilizou a exploração de múltiplas perspectivas sobre uma mesma amostra de dados, favorecendo uma análise mais acessível e aprofundada dos resultados.

Essa evolução metodológica evidencia a interdisciplinaridade da pesquisa, demonstrando a complementaridade entre econofísica, ciência da computação e *visual analytics* na análise e modelagem de sistemas socioeconômicos.

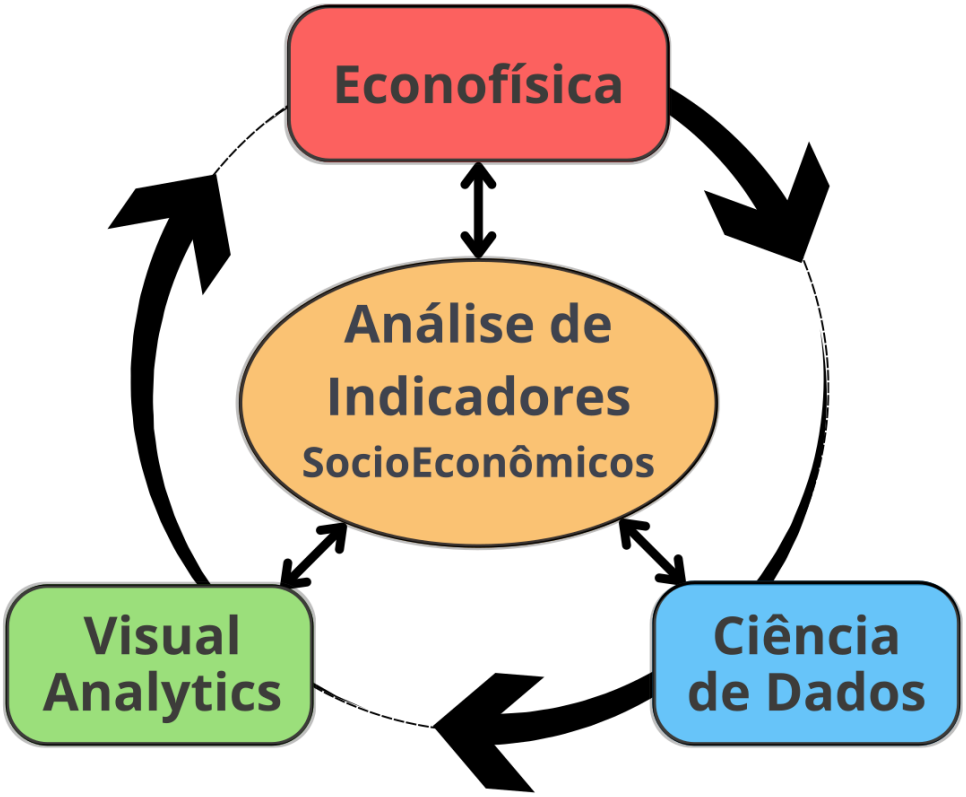

Figura 1.1 – Abordagem Multidisciplinar para análise de indicadores socioeconômicos integrando econofísica, *visual analytics* e ciência de dados.

A abordagem multidisciplinar adotada oferece uma base alternativa para a análise de indicadores socioeconômicos, servindo como ponto de partida para estudos futuros voltados à comparação entre cidades. Nos capítulos seguintes, descrevemos os modelos e métodos utilizados, apresentamos os resultados obtidos e discutimos suas implicações teóricas e práticas, concluindo com as principais contribuições e sugestões para pesquisas futuras.

2 MODELOS E METODOLOGIA

2.1 Fluxograma da metodologia

O fluxograma apresentado na Figura 2.1 sintetiza as etapas metodológicas desta dissertação, articulando-se em três fases principais. Inicialmente, realiza-se a **Engenharia de Dados**, conforme descrito em 2.2, que envolve a pesquisa, extração, padronização e estruturação dos dados em *dataframes*. A seguir, passa-se ao **Desenvolvimento e Aplicação de técnicas de análise de dados**, discutido em 2.3 e 2.4, com a implementação de métodos exploratórios e algoritmos como *binscatter* e o algoritmo Baseado em Clusterização Gravitacional (B-GCA), destinados a identificar padrões e superar desafios como o *overplotting*. Por fim, a **Análise, Comparação e Representação dos Resultados** (seção 1.2) utiliza ferramentas visuais, como gráficos, tabelas e *dashboards* interativos, para comunicar os resultados de forma compreensível e intuitiva.

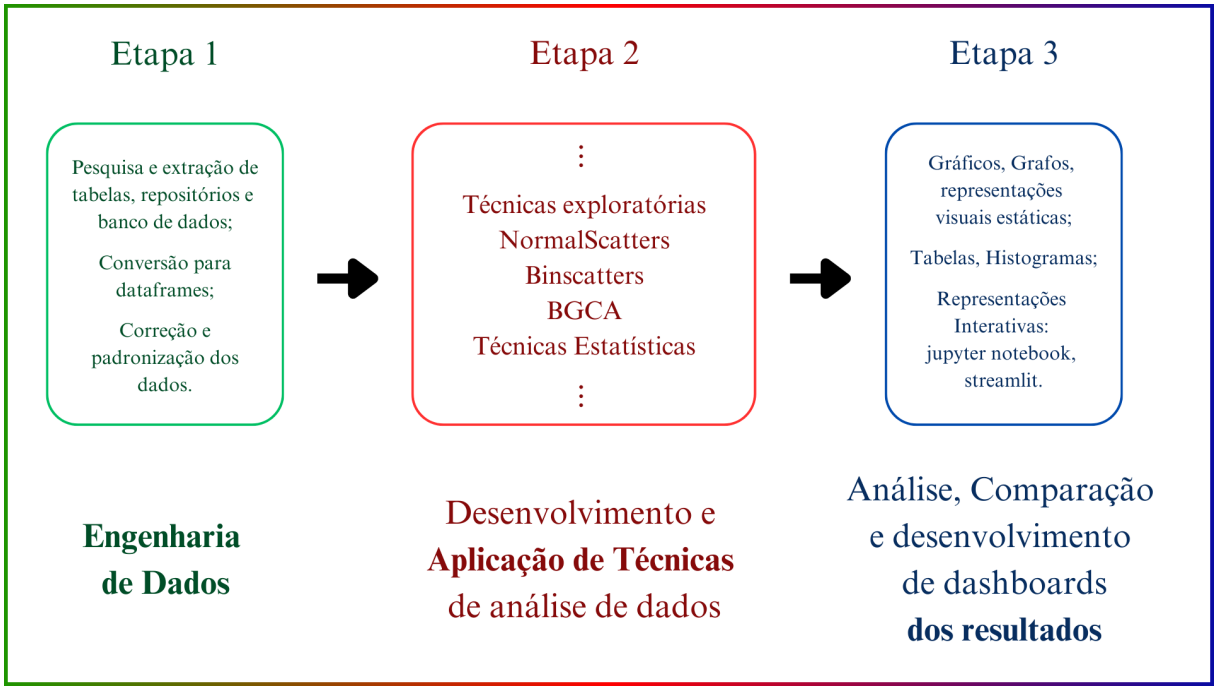

Figura 2.1 – Fluxograma das etapas metodológicas desta pesquisa, dividido em três fases principais: (1) Engenharia de dados, envolvendo a coleta, preparação e padronização dos dados; (2) Desenvolvimento e aplicação de técnicas de análise de dados, utilizando métodos exploratórios e algoritmos avançados, como B-GCA e *binscatter plots*; e (3) Análise, comparação e Representação dos resultados, por meio de gráficos, tabelas, visualizações interativas e *dashboards*.

Após a implementação da metodologia, é conduzido um estudo de caso específico, conforme detalhado em 2.5. Apesar de focar em um exemplo prático, o *framework* apresentado é versátil e pode ser adaptado para outros estudos de caso em diferentes

contextos e sistemas socioeconômicos. Essa flexibilidade reforça a aplicabilidade da abordagem em diversas análises complexas.

2.2 Construção dos bancos de dados e Detecção de Padrões Emergentes Livre de escala

Conforme mencionado na introdução [capítulo: 1], iniciamos construindo um banco de dados com dados de indicadores socioeconômicos de interesse. No caso do Brasil, utilizamos dados do censo de 2010 e da Relação Anual de Informações Sociais (RAIS), ambos desenvolvidos pelo Instituto Brasileiro de Geografia e Estatística (IBGE). Em relação a outros países, utilizamos instituições reconhecidas com dados semelhantes aos fornecidos pelo IBGE para indicadores socioeconômicos por municípios. A lista de fontes está disponível nas referências (Fontes 4.3). Selecionamos seis países, com dados divididos por municípios, cidades ou divisões administrativas equivalentes; exceto para os Estados Unidos da América (EUA), onde só conseguimos obter dados por *Tracts*[1] e tivemos que agrupá-los por condados[2].

Realizamos gráficos de dispersão do IDH vs população de cada unidade administrativa, que generalizaremos e denominaremos como cidades, pela população no mesmo período; onde, nos gráficos de dispersão, cada cidade é representada como um ponto. Em seguida, representamos as distribuições em escala logarítmica, utilizando gráficos de *box plot*, destacando os quartis e valores atípicos. Posteriormente, definimos macrorregiões de cada país por cores. Para cada cor, há um *box plot* respectivo, destinado a comparações entre eles. No caso do Brasil, utilizamos as cinco macrorregiões reconhecidas no país: norte, nordeste, sudeste, centro-oeste e sul.

Em seguida, focamos exclusivamente na macrorregião sul. Classificamos diferentes regiões (equivalentes a estados) por cores e observamos um padrão visual semelhante ao da escala nacional. Aplicamos o mesmo procedimento a cada macrorregião, traçando uma linha de referência usando o Método dos Mínimos Quadrados (MMQ). Registramos os valores correspondentes de correlação, variância, desvio padrão e outras variáveis estatísticas relevantes.

[1] Nos Estados Unidos, *tracts* são subdivisões geográficas definidas pelo *U.S. Census Bureau* para fins de coleta e análise de dados demográficos. Eles são projetados para conter populações relativamente homogêneas em termos de características econômicas, sociais e habitacionais. Cada *tract* geralmente abrange uma população de 1.200 a 8.000 pessoas, com uma média ideal em torno de 4.000. Essas unidades são frequentemente utilizadas em estudos estatísticos, pois oferecem uma granularidade intermediária, menor que um condado, mas maior que um bloco censitário. Nos grandes centros urbanos, os *tracts* ajudam a capturar as diferenças internas de bairros ou áreas menores, refletindo melhor a diversidade local.

[2] Embora possa ser comparável a cidades em vários aspectos, é importante notar que em grandes cidades, como Orlando, há a presença de mais de um condado. Essa subdivisão administrativa pode influenciar e acentuar uma maior homogeneidade na distribuição dos índices.

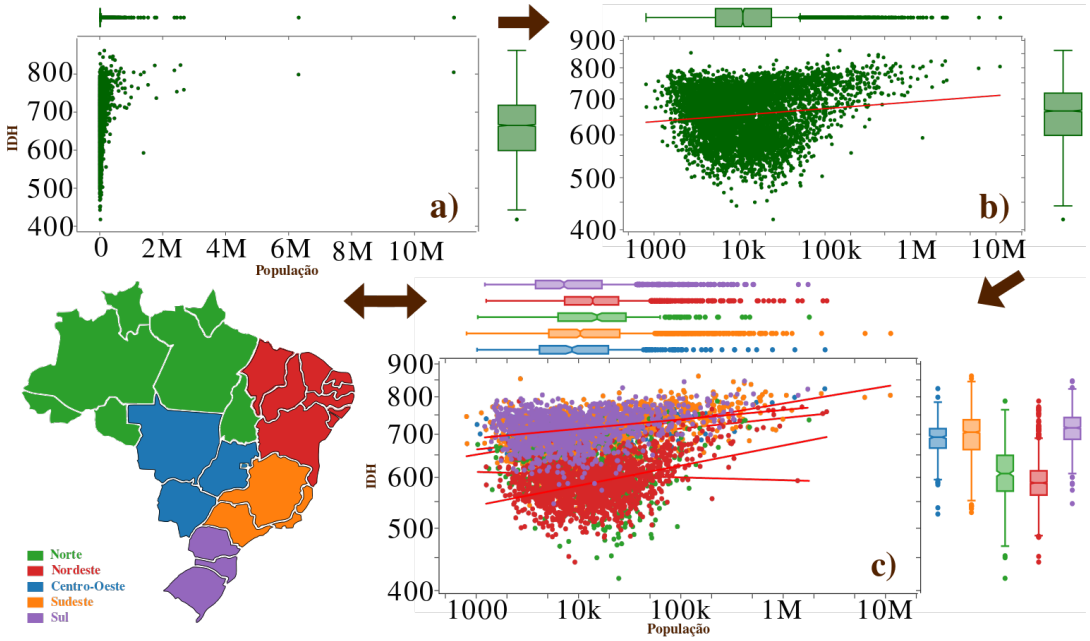

Figura 2.2 – Conversão da escala normal para uma escala log-log de um gráfico de dispersão do índice IDH para cada município (cada ponto), em relação à sua população absoluta. Posteriormente, o gráfico de dispersão é dividido em 5 cores, correspondendo às macrorregiões administrativas do Brasil.

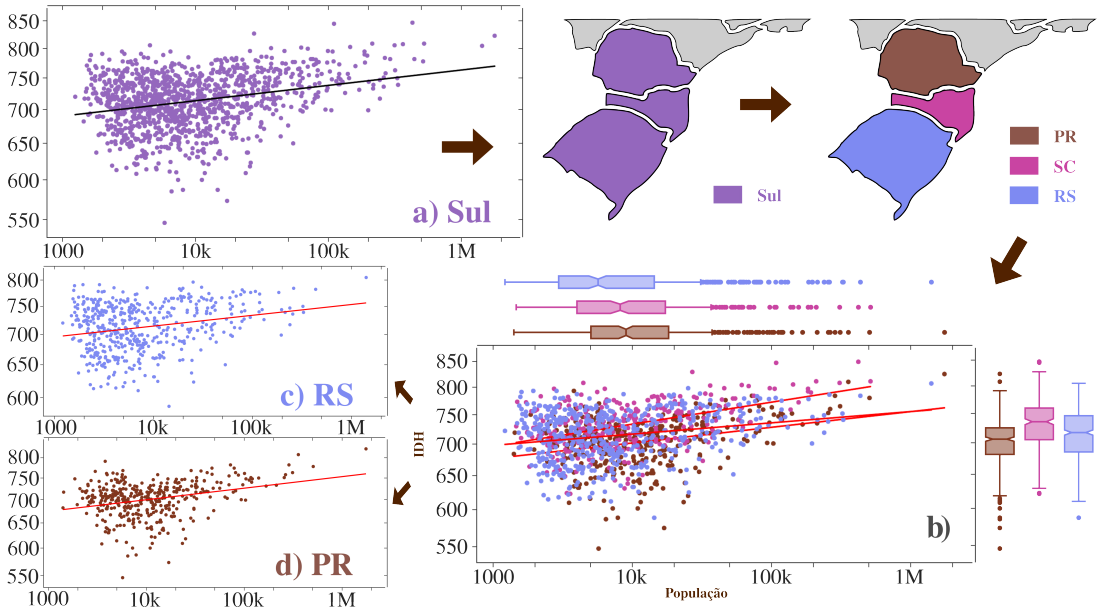

Figura 2.3 – Gráfico de dispersão representando a dispersão do IDH para cada município na macrorregião sul com base em suas respectivas populações. Posteriormente, o gráfico é segmentado em regiões (estados), sugerindo que o surgimento do padrão de dispersão subjacente ocorre independentemente da escala. Abreviações dos Estados: RS - Rio Grande do sul, SC - Santa Catarina e PR - Paraná.

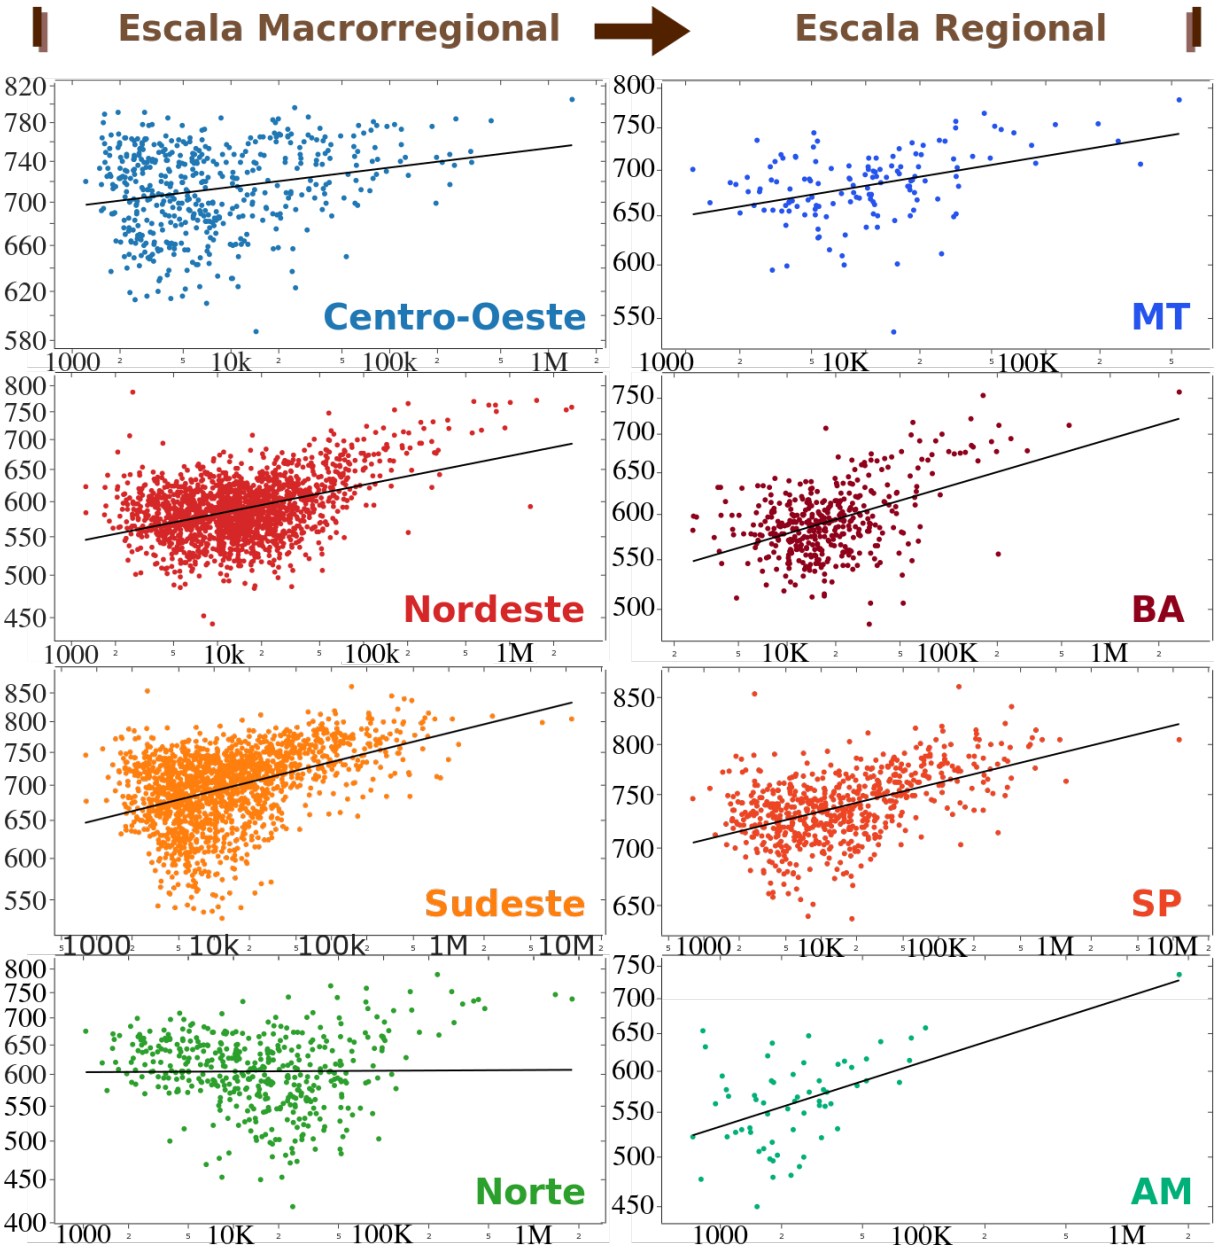

Figura 2.4 – Comparação das dispersões do IDH por população em quatro das cinco macrorregiões do Brasil, em relação a um estado representativo de cada macrorregião. Destacando o potencial surgimento de padrões semelhantes em ambas as escalas macro e regional. Abreviações dos Estados: MT - Mato Grosso, BA - Bahia, SP - São Paulo e AM - Amazonas. A região norte parece ser uma exceção.

O mesmo procedimento desta Seção (Sec. 2.2) foi replicado para os outros países.

2.3 Binscatter process

Para cada gráfico de dispersão, organizamos a amostra de dados em *bins*, semelhante ao processo de gráfico de dispersão agrupado, ou *binscatters* (CATTANEO et al., 2019). Em cada *bin*, calculamos a média das variáveis em cada eixo —especificamente,

a média das cidades contidas naquele *bin* tanto para o IDH quanto para a informação de população. Assim, reduzimos um conjunto de pontos a um único ponto representativo para o conjunto. Consequentemente, após a sequencialidade desse processo para todos os *bins*, obtemos uma coleção de pontos que podemos associar a uma curva, que denominamos *binscatter*, na qual realizamos um ajuste linear nos dados, obtendo os respectivos coeficientes.

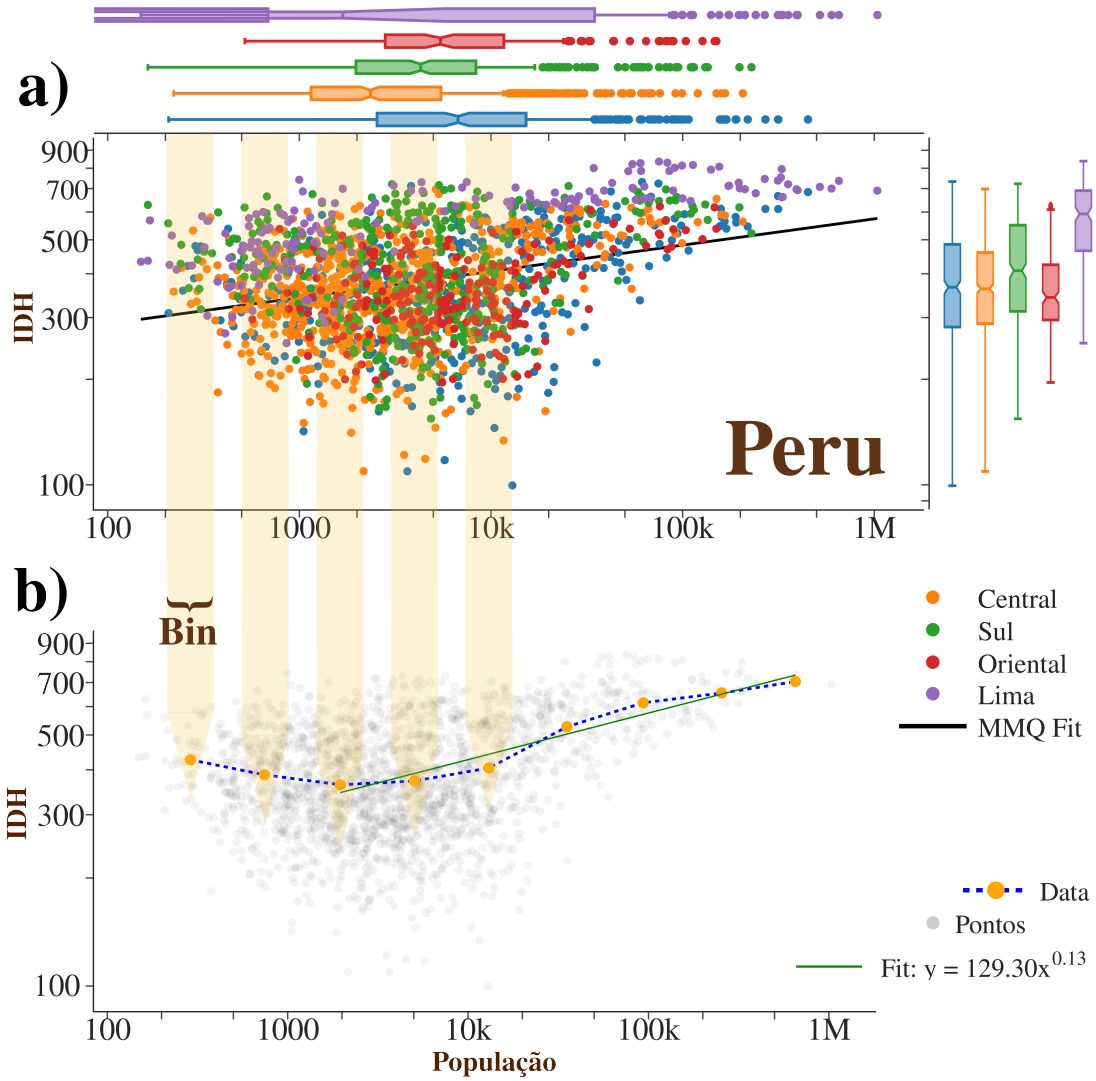

Figura 2.5 – Divisão da dispersão em *bins*, com cada ponto representando a média em ambos os eixos para cada *bin* correspondente. O conjunto dos pontos gerados, é entendido como uma curva *binscatter*, na qual foi aplicado um ajuste linear, pelo método dos mínimos quadrados (MMQ), do ponto do mínimo global ao último ponto na amostra.

Como existem mais de uma maneira de organizar e definir os tamanhos dos *bins*, realizamos uma análise de robustez do sistema escolhido. Testamos várias configurações de tamanhos de *bins* e examinamos a estabilização dos coeficientes na função de ajuste linear resultante. Consequentemente, pudemos determinar valores de coeficientes adequados para cada gráfico de dispersão, assemelhando-se a uma distribuição exponencial

dos dados, levando em consideração a divisão dos tamanhos dos *bins*.

2.3.1 Metodologia para Divisão dos Bins

A divisão dos *bins* foi realizada utilizando uma escala exponencial. Esta escolha é fundamentada pelo comportamento logarítmico da distribuição de dados populacionais, que tende a se assemelhar a uma distribuição log-normal ou exponencial. Além disso, os gráficos gerados utilizam escala log-log, o que torna os *bins* exponenciais ainda mais apropriados, garantindo uma melhor visualização e análise das tendências.

Passos Realizados para Divisão dos Bins

1. **Seleção da Variável Principal:**
   - Cada país possui uma variável de **população total** no eixo x. Por exemplo:
     - **Brasil**: *Total_Pop_Absol*
     - **EUA**: *2015_Tract_population*
     - **México**: *Pop_Total_2010*
   - A partir desses dados, foi calculada a menor população x_{min} como ponto de partida.
2. **Definição dos Bins Exponenciais:**
   - A fórmula utilizada para calcular os *bins* segue a lógica do crescimento exponencial:
     $$\text{bin}_{i+1} = \text{bin}_i \cdot e^{\frac{1}{n}}$$
     onde:
     - e é a base do logaritmo natural.
     - n é o número total de *bins* (neste caso, 10 *bins*).
   - A fórmula garante que cada *bin* aumente de maneira proporcional e exponencial, capturando a ampla variação dos dados populacionais.
3. **Interrupção no Valor Máximo:**
   - O cálculo dos *bins* é interrompido quando o próximo *bin* ultrapassa o valor máximo da variável x (população total do país):
     $$\text{bin}_{i+1} > x_{\text{max}}$$
4. **Geração de *Labels* para os Bins:**

- Os valores dos *bins* foram formatados em unidades mais legíveis utilizando as seguintes regras:
  - Populações maiores que $1.000.000$ são expressas em **milhões (M)**.
  - Populações maiores que 1.000 e menores que $1.000.000$ são expressas em **milhares (K)**.
  - Valores menores permanecem como **números inteiros**.

Justificativa para 10 Bins

A escolha de 10 *bins* visa equilibrar resolução e simplicidade:

- Resolução: 10 *bins* oferecem uma segmentação detalhada o suficiente para capturar as principais variações da distribuição populacional.
- Simplicidade: Mantém a visualização dos dados limpa e compreensível, evitando divisões excessivas.

Além disso, como o gráfico está em escala log-log, os *bins* exponenciais permitem que a distribuição dos dados seja melhor representada e alinhada visualmente com o comportamento esperado de distribuições populacionais.

Exemplo em Fórmulas

- **Valor Inicial:**

$$\text{bin}_0 = x_{\text{min}}$$

- **Bins Seguintes:**

$$\text{bin}_{i+1} = \text{bin}_i \cdot e^{\frac{1}{n}}$$

- **Interrupção:**

$$\text{bin}_{i+1} \, \text{se} \, \text{bin}_{i+1} > x_{\text{max}}$$

- **Labels:**
  - $x > 1.000.000 \rightarrow x/1.000.000$ **M**
  - $x > 1.000 \rightarrow x/1.000$ **K**

2.4 Based on Gravitational Clustering Algorithm (B-GCA)

Na terceira etapa da metodologia, desenvolvemos uma variante de um método da astrofísica: o “Algoritmo de Agrupamento Gravitacional” (GOMEZ; DASGUPTA; NASRAOUI, 2003) (GCA) que é, muito resumidamente, um método de agrupamento inspirado na teoria gravitacional, onde os pontos de dados são tratados como partículas que interagem entre si por meio de forças gravitacionais. O algoritmo define um campo de força em que os pontos mais densamente distribuídos atraem outros, formando naturalmente *clusters* de acordo com uma fórmula matemática específica envolvendo a distância entre os pontos. No nosso caso, há diferenças significativas, principalmente por optarmos por adaptar a estrutura do código base e da fórmula de clusterização para analisar apenas de maneira estática o conjunto de pontos do gráfico, ou seja, sem considerar a dinâmica no sistema. [3]

Na nossa versão, substituímos os corpos celestes pelos pontos correspondentes no gráfico de dispersão, elaboramos uma métrica do plano baseada em pixels[4], e assim, pudemos aplicar uma fórmula de “Raio de Corte” para agrupar os pontos[5].

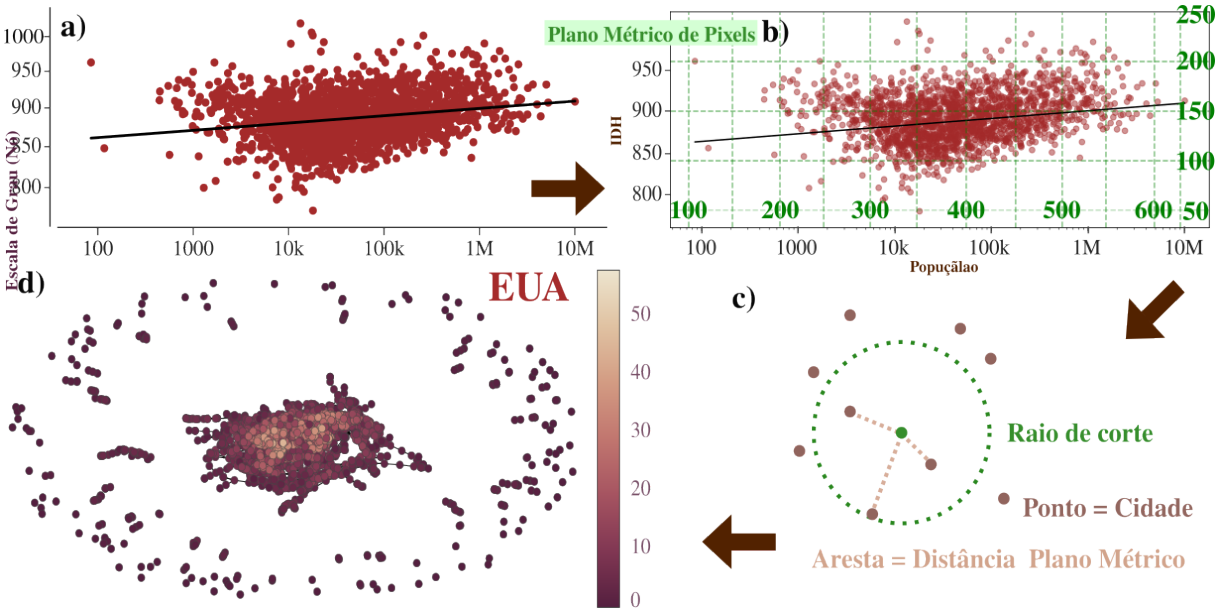

Figura 2.6 – processo de transformar um gráfico de dispersão em um grafo usando uma variação autoral do “Algoritmo de Agrupamento Gravitacional” (GCA). O plano métrico é baseado na taxa de DPI do monitor e a formulação do Raio de Corte é arbitrária.

Experimentamos várias fórmulas para o “Raio de Corte” e optamos por uma seleção

[3] É possível adotar uma fórmula onde se mantém a análise da dinâmica do sistema de pontos, substituindo a variável de tempo por diferentes valores do raio de corte.

[4] Foi desenvolvido um algoritmo que identifica o DPI (pontos por polegada) do monitor no qual o programa está sendo executado, e a diferença na posição dos pixels entre os limites do gráfico permite a criação de um plano métrico para calcular distâncias entre pontos na dispersão.

[5] Se um plano métrico direto fosse criado a partir dos valores contidos nos dados plotados, estaríamos medindo distâncias entre pontos na escala; no entanto, o que queríamos era a distância visual entre pontos após a aplicação da escala logarítmica como se fosse um novo sistema.

simples com a imposição de um raio padrão[6], em que todos os pontos contidos dentro do círculo correspondente definem uma aresta entre esses pontos externos e o ponto de referência localizado no centro. O procedimento foi replicado para cada ponto, gerando a matriz de adjacência do sistema. Consequentemente, obtemos o gráfico correspondente, adotando um padrão de gradiente de cores para destacar a intensidade dos graus de cada cidade. Para cada gráfico, realizamos medidas estatísticas como grau médio, variância, coeficiente de agrupamento, entre outras variáveis.

2.5 Estudo de Caso: IDHM x População de Municípios do Brasil

Este trabalho utilizou duas das três metodologias definidas no artigo base: Comparação direta entre *scatter* e *binscatter process*. Cada metodologia foi aplicada com o objetivo de explorar diferentes perspectivas dos dados, permitindo uma análise mais abrangente e robusta.

2.5.1 Conversão de Escala e Codificação por Cores

Mantivemos como base a conversão da escala normal para a escala log-log em todos os gráficos, o que permite uma melhor visualização e análise das relações não lineares entre os dados de IDHM e população. Além disso, preservamos a codificação por cores das cinco macrorregiões brasileiras (Norte, nordeste, centro-oeste, sudeste e sul), garantindo consistência visual ao longo do estudo.

2.5.2 Geração dos Gráficos

Os gráficos foram gerados utilizando bibliotecas do Python, especialmente o Plotly, que possibilita a criação de visualizações interativas. Adicionamos botões e *widgets* interativos aos Notebooks Jupyter, o que permite que a ferramenta seja utilizada para análises dinâmicas e exploratórias por outros pesquisadores. Os Notebooks estão disponíveis no repositório oficial do artigo no GitHub Paper Github, acessível através da seção de informações suplementares (Supplementary Info, S.I).

2.5.3 Organização Visual

Para facilitar a análise e a interpretação dos resultados, os gráficos foram organizados por macrorregião. Cada macrorregião recebeu uma paleta de cores que reflete a identidade visual definida anteriormente, facilitando a comparação entre diferentes regiões.

[6] É necessário arbitrar/definir um valor de raio como porcentagem para a reprodutibilidade do algoritmo em diferentes taxas de DPI.

Nos gráficos de dispersão (*scatter*), cada ponto representa um município específico, enquanto nos gráficos resultantes do *binscatter process*, cada ponto representa a média do IDH e da população de um *bin*. Para aprimorar a visualização dos resultados do *binscatter*, conectamos os pontos consecutivos por meio de segmentos de reta, que na conjuntura total da amostra podem ser interpretados como uma curva, a qual denominamos *binscatter lines*. Essas curvas (ou linhas) foram utilizadas para destacar padrões e tendências em diferentes estados e macrorregiões.

2.5.4 Tabelas Estatísticas

Construímos uma tabela estatística, contendo informações relevantes de cada macrorregião, como também de cada estado, para uma análise entre os indicadores de IDHM e População, sendo essas: correlação de Pearson, valor mínimo do *binscatter line* (se houver), média e mediana do IDHM e População. Adicionalmente, deixamos em anexo outra tabela contendo os valores absolutos dos quartis de cada eixo, também para cada estado e cada macrorregião.

2.5.5 Análise comparativa e *visual analytics*

Um dos pontos centrais deste trabalho foi a comparação entre diferentes tipos de gráficos para a mesma amostra de dados. Essa abordagem baseia-se nos princípios de *visual analytics*, um campo interdisciplinar que combina visualização interativa e análise de dados para apoiar a exploração e interpretação de padrões complexos. Estudos como os de Keim et al. (2008) destacam a importância de técnicas visuais para revelar *insights* que podem passar despercebidos em representações numéricas ou estáticas. Nesse contexto, a utilização de múltiplas representações gráficas permite uma compreensão mais completa dos dados e ajuda a evitar interpretações enviesadas.

2.5.6 Discussão Metodológica

A escolha de diferentes representações gráficas visa explorar os dados sob diversas perspectivas. Por exemplo:

- Nos gráficos de dispersão (*scatter*), é possível identificar a dispersão dos municípios e tendências gerais;
- Nos gráficos do *binscatter process*, a redução do ruído facilita a identificação de padrões emergentes, como pontos críticos em que a relação entre IDHM e população muda de comportamento;

Essa abordagem foi inspirada por trabalhos que utilizam *visual analytics* para explorar dados complexos em domínios como economia e ciências sociais (THOMAS; COOK,

2005). A aplicação dessas técnicas no contexto de econofísica, como observado em estudos recentes ((MANTEGNA; KERTÉSZ, 2011)), oferece uma abordagem inovadora para compreender padrões e dinâmicas em sistemas sociais e econômicos.

2.5.7 Correlação, Variança e outras métricas

As técnicas estatísticas utilizadas nesta análise são amplamente reconhecidas e consolidadas no meio acadêmico. Por serem ferramentas robustas e frequentemente empregadas na literatura científica, optamos por uma descrição breve de cada uma, destacando sua aplicação específica no contexto deste estudo. As metodologias são sustentadas por referências amplamente citadas na literatura, as quais são mencionadas ao longo do texto.

Uma tabela foi construída contendo as informações relacionadas à correlação de Pearson, valores mínimos, máximos, médias e medianas para ambos os eixos (população total e IDHM 2010). Essa tabela reflete os cálculos realizados para a amostra completa (100%) e abrange todas as macrorregiões e estados brasileiros. Esses dados foram utilizados como referência para a análise das diferentes métricas.

Adicionalmente, outras métricas e análises de correlação, variando ao longo do tempo ou conforme a amostra é progressivamente reduzida, foram apresentadas apenas para três casos específicos: uma aplicação a nível nacional, outra a nível macroregional e uma terceira a nível regional (estado). Essa abordagem seletiva foi adotada para demonstrar a aplicabilidade prática das técnicas em diferentes escalas geográficas, mantendo o foco nas interações mais relevantes para o estudo.

A análise utilizou diferentes métricas estatísticas para avaliar a relação entre os indicadores Total População Absoluta (população total) e IDHM 2010. A amostra foi reduzida progressivamente em uma escala logarítmica para destacar o comportamento dos dados em diferentes níveis de representatividade.

A correlação de Pearson foi empregada para medir a relação linear entre as variáveis. O coeficiente varia entre -1 (relação linear negativa perfeita) e 1 (relação linear positiva perfeita), com 0 indicando ausência de correlação. O cálculo foi realizado para cada subconjunto da amostra em escala logarítmica, permitindo avaliar como a relação linear entre população e IDHM varia com a redução da amostra.

Para avaliar relações não lineares ou monotônicas, foi calculada a correlação de Spearman. Esta métrica baseia-se nos rankings dos dados, sendo robusta contra a presença de relações não lineares. Assim como na correlação de Pearson, o coeficiente de Spearman foi recalculado em cada etapa da redução da amostra.

A “Informação Mútua” foi utilizada para quantificar a dependência mútua entre as variáveis. Esta métrica não paramétrica avalia quanto uma variável reduz a incerteza sobre a outra. O cálculo foi realizado utilizando o algoritmo de estimativa de “Informação Mútua”,

ajustando dinamicamente o número de vizinhos para evitar erros em amostras reduzidas.

A análise incluiu a modelagem por regressão linear, com o cálculo do coeficiente de determinação R^2, que indica a proporção da variância de IDHM 2010 explicada por Total População Absoluta. Além disso, uma regressão logarítmica foi aplicada ao eixo X (população total), considerando a transformação logarítmica para avaliar relações exponenciais. Em ambas as modelagens, o coeficiente R^2 foi recalculado para cada subconjunto da amostra.

As variâncias de X e Y foram calculadas para medir a dispersão de Total População Absoluta e IDHM 2010, respectivamente, em cada etapa. A análise da variância permitiu compreender como a dispersão dos dados influencia os resultados das métricas à medida que a amostra é progressivamente reduzida.

Além dessas métricas, foram calculadas a média e a mediana do eixo Y (IDHM 2010) em cada subconjunto da amostra. Essas medidas de tendência central ajudam a identificar mudanças graduais na distribuição do IDHM à medida que a amostra é reduzida. A média é particularmente útil para capturar o comportamento geral da variável, enquanto a mediana oferece *insights* sobre a posição central da distribuição, mesmo na presença de valores discrepantes. Os dados foram inicialmente filtrados para remover valores inválidos, como zeros ou negativos no eixo X, e transformados em escala logarítmica para alinhar os dados a uma escala exponencial. A redução progressiva da amostra foi realizada dividindo o intervalo de valores logarítmicos em 20 etapas, onde a cada etapa, a parte inferior dos dados foi removida. Essa abordagem permitiu avaliar a sensibilidade das métricas estatísticas em relação ao tamanho da amostra.

Os resultados foram apresentados em *subplots*, onde o eixo X representa o tamanho da amostra em escala logarítmica e o eixo Y exibe os valores das métricas calculadas. Essa visualização em escala logarítmica foi essencial para destacar relações que seriam menos evidentes em uma escala linear, proporcionando uma análise detalhada das interações entre população e IDHM em diferentes cenários.

3 RESULTADOS

3.1 IDHM x População: Comparação entre países das Américas

3.1.1 Binscatter Plots

O primeiro resultado apresentado é o IDH por municípios de cada país. Os gráficos são de dispersão (*scatter plots*) em escala log-log. O valor do IDH é indicado pela posição no eixo vertical, enquanto a posição no eixo horizontal corresponde ao tamanho da população do município. Além dos pontos individuais, incluímos curvas que denominamos *binscatter lines*, obtidas a partir da metodologia *binscatter* 2.3. Essas curvas permitem visualizar a tendência dos dados ao longo da distribuição de dispersão e compará-los com o ajuste pelo Método dos Mínimos Quadrados (MMQ), também plotado no mesmo conjunto de dados.

Algumas curvas exibem mínimos globais, sugerindo a existência de uma "população crítica" em alguns países, delineando duas regiões com comportamentos distintos: cidades com uma população abaixo do limiar crítico mostram uma correlação negativa com o aumento do IDH, enquanto cidades com uma população acima deste limiar tendem a ter uma correlação positiva com o IDH. No entanto, ao examinar os gráficos de dispersão, observa-se que a primeira região tem alta variância, tornando desafiador inferir uma relação de causa e efeito (TRZESNIAK, 1998), mesmo assumindo uma correlação negativa. Por outro lado, a segunda região exibe menor variância, diminuindo à medida que a população aumenta. Esta observação sugere que, sob estas condições, o crescimento populacional nas cidades está associado a um IDH mais alto. Uma interpretação preliminar poderia sugerir que, à medida que a população aumenta, o volume de transações no mercado cresce, impactando positivamente o Produto Interno Bruto (PIB), que, por sua vez, é um componente significativo do IDH (BOOZER et al., 2003; ZGHEIB et al., 2006). No entanto, enfatizamos que determinar e validar a causalidade requer uma investigação mais aprofundada. Este artigo foca em apresentar os resultados obtidos e, acima de tudo, na metodologia apresentada como uma abordagem alternativa para identificar padrões emergentes, considerando a natureza livre de escala. Ressaltamos que correlação não necessariamente implica causalidade.[1]

[1] Além disso, em estudos adicionais, identificamos uma correlação mais pronunciada entre o IDHM e a densidade populacional dos municípios.

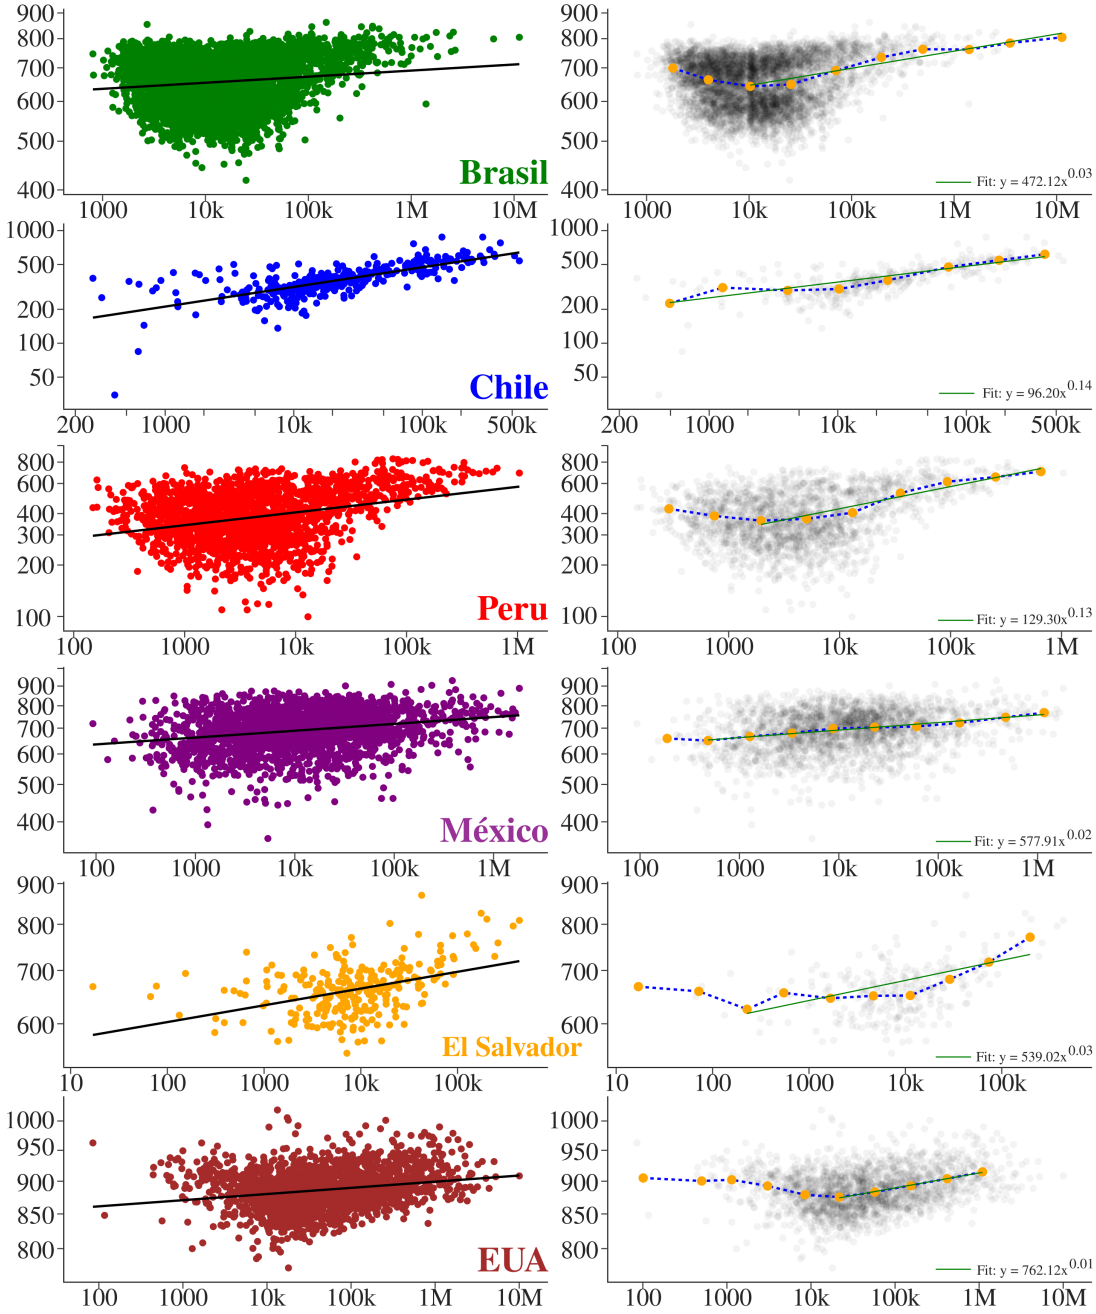

Figura 3.1 – Comparação entre o gráfico de dispersão (*scatter plot*) e a respectiva curva "binscatter" (Sec. 2.3). Os países analisados incluem: Brasil, Chile, Peru, México, El Salvador e EUA.

Realizamos uma segunda comparação, presente em duas configurações de separação de *bins*. Tais ilustrações (Fig. 3.2) fornecem uma visualização mais explícita e numérica das relações entre as distribuições dos países analisados. É digno de nota, por exemplo, que as curvas "*binscatter lines*" relacionadas aos EUA apresentam variância significativamente baixa, enquanto o Chile mostra variância substancialmente alta, um aspecto que será discutido com mais detalhes na seção de conclusão (Sec. 4).

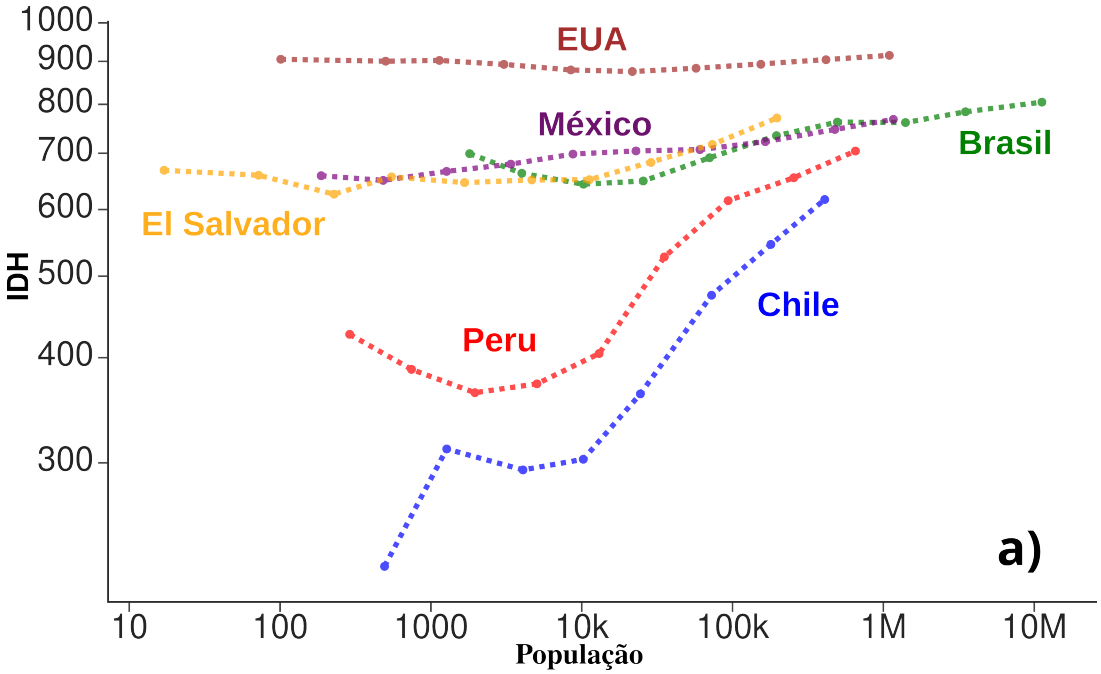

(a) A divisão de *bin* é ajustada para cada país.

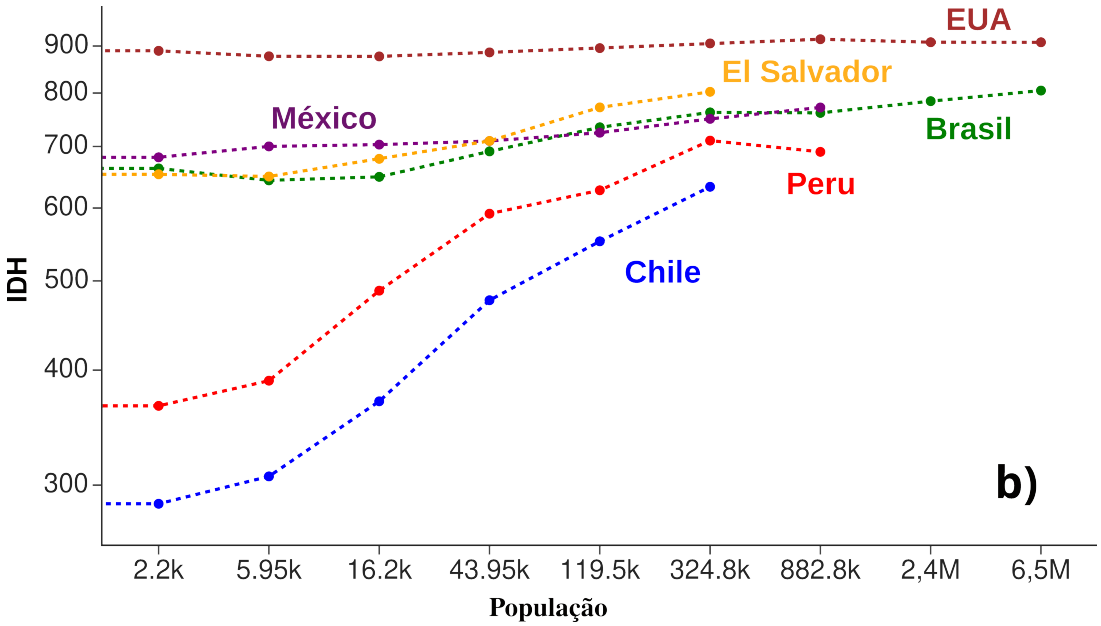

(b) Usando o mesmo tamanho de *bin* para todos os países.

Figura 3.2 – Comparação das curvas *binscatter lines*, geradas pelo processo de divisão de *bins* (Sec. 2.3) dos respectivos gráficos de dispersão (scatters) entre IDH e população para as unidades administrativas de cada país.

Adicionalmente, ambas as ilustrações corroboram as características examinadas na comparação visual lado a lado (Fig. 3.2). No entanto, é essencial notar as diferenças entre as configurações de divisão de *bin*. Na configuração a), os *bins* são ajustados para otimizar as distribuições individualmente para cada país, enquanto na configuração b), uma divisão de *bin* geral é ajustada, adotando apenas uma escala de *bin* exponencial seguindo a geratriz: $x_{n+1} = x_n * e + x_0$, onde x_0 é o valor correspondente à população mínima do

conjunto de dados de referência. Na configuração geral, o mínimo é adotado para todos os países, e na configuração a), o mínimo é respectivo a cada país.

Entre outras possíveis análises, vale a pena notar diferenças substanciais nos gráficos, mesmo ao considerar o mesmo conjunto de dados para o propósito comum de comparar as curvas *binscatter lines* entre os países. Na configuração a), uma expressão mais pronunciada das características individuais de cada país é observada devido à otimização independente, destacando mínimos globais e locais nas curvas *binscatter*. Em contraste, na configuração b), há uma homogeneização das características nacionais, acentuando e linearizando as curvas. Esta distinção na representação reforça a questão inicialmente abordada na introdução. Ao buscar resolver o problema de diferentes bases de cálculo através da padronização metodológica, há uma perda das características locais. No entanto, essa homogeneização permite uma comparação numérica direta na mesma escala. Algumas disparidades nas representações são esperadas e são, de alguma forma, uma evidência de complexidades. Indicadores sociais medem facetas de fenômenos sociais, e obter conhecimento preciso sobre algo inerentemente impreciso é logicamente impossível. Entender um fenômeno acompanha a natureza desse fenômeno; se caracterizar países é algo complexo que requer uma diversidade de abordagens e variáveis para análise, tal complexidade se manifestará nos resultados e conclusões.

3.1.2 Baseado em GCA (B-GCA)

Similarmente à comparação visual lado a lado na subseção anterior (Fig. 3.1), construímos uma comparação de gráficos de dispersão com os gráficos resultantes da metodologia B-GCA (Sec. 2.4).

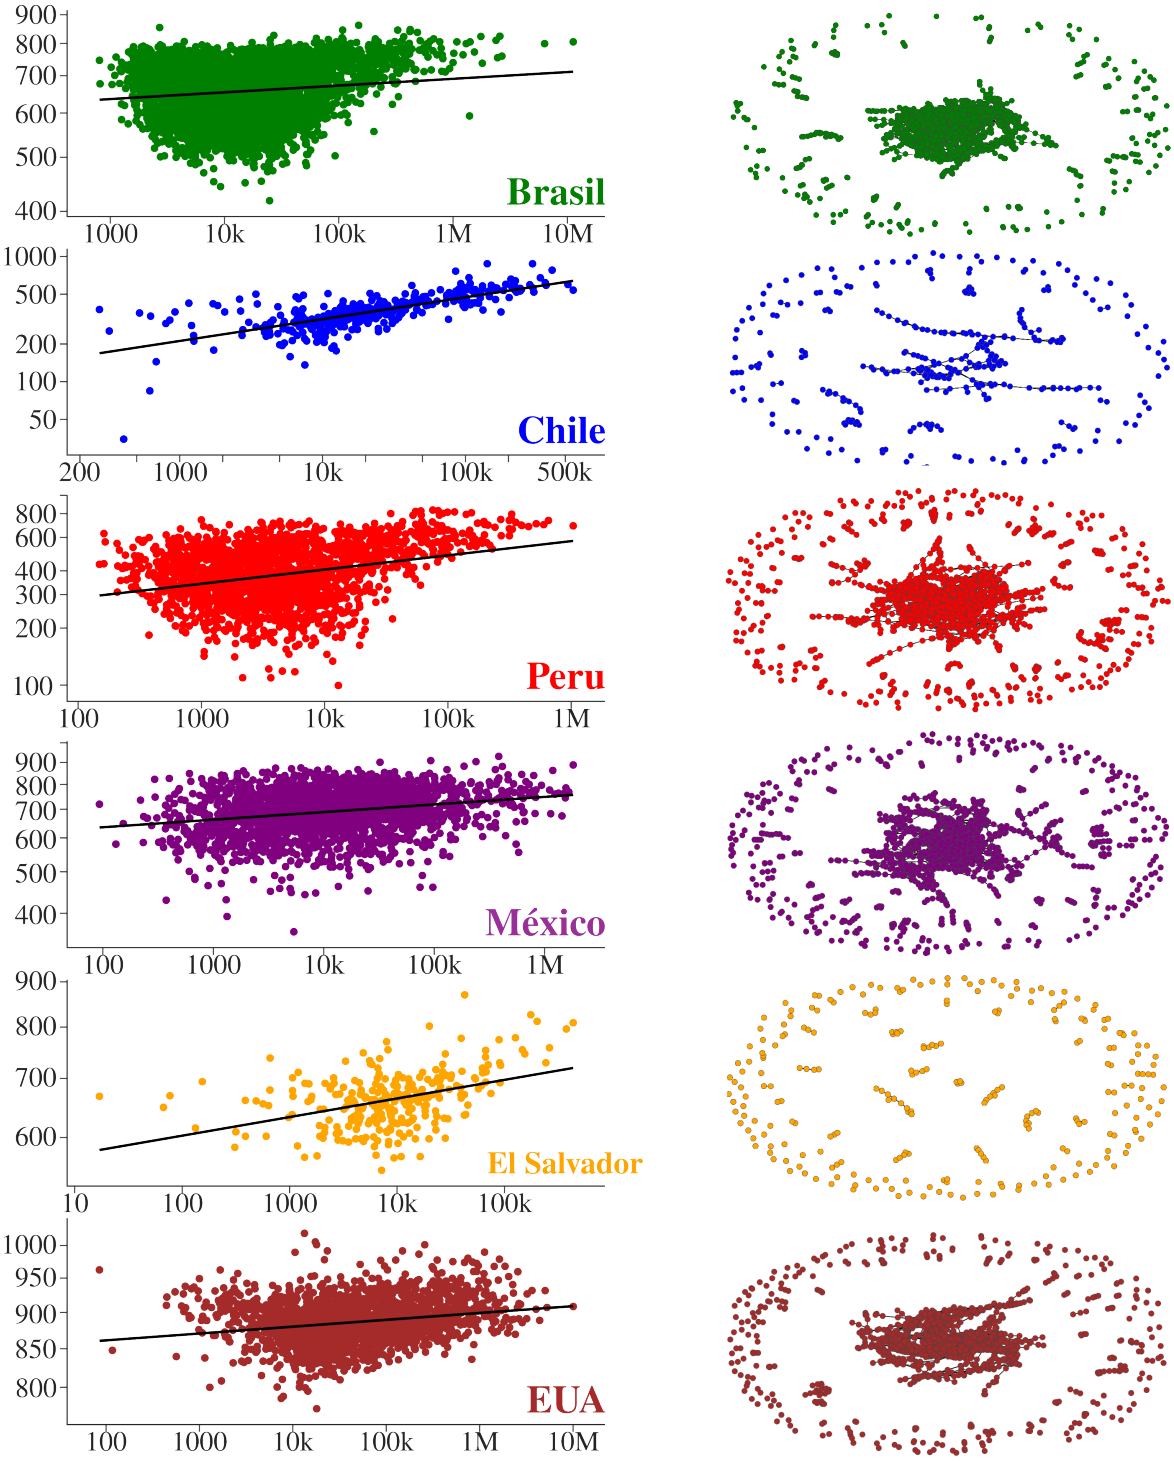

Figura 3.3 – Comparação entre o gráfico de dispersão e a respectiva curva *binscatter* após o processo de conversão de gráfico usando B-GCA (Sec. 2.4). Os países analisados incluem: Brasil, Chile, Peru, México, El Salvador e EUA.

Nesta ilustração comparativa, é possível deduzir que os gráficos associados ao Brasil e ao Peru compartilham semelhanças, assim como o México e os EUA. Além disso, observa-se que, à medida que o número de pontos no gráfico, correspondente ao número

de nós no gráfico, aumenta, há uma tendência para o hub central no gráfico crescer. A concentração proporcional do gráfico em relação ao número de nós impacta diretamente a proximidade dos pontos no gráfico de dispersão, onde nós localizados nas bordas do gráfico representam pontos que estão mais distantes ou até isolados no plano métrico do gráfico de dispersão. Além disso, algumas outras medidas caracterizando um gráfico foram calculadas e exibidas em uma tabela (Fig. 3.4) para comparação entre os países.

Métricas	Brasil	Chile	Peru	México	ElSalvador	EUA
Nº de nós	5565	345	1874	2193	261	3142
Nº de arestas	60890	456	4535	8449	112	27652
Grau Médio	21.9	2.6	4.8	7.7	0.9	17.6
Máximo Grau	59	12	15	30	4	54
Mínio Grau	0	0	0	0	0	0
Variança	141.4	6.0	10.4	33.2	1.0	148.9
Desvio Padrão	11.9	2.5	3.2	5.8	1.0	12.2
Excentricidade Média	41.5	10.3	43.6	44.9	5.5	46.9

Figura 3.4 – Tabela contendo informações estatísticas das redes (gráficos) correspondentes para cada país após o processo de conversão do gráfico de dispersão usando B-GCA (Sec. 2.4).

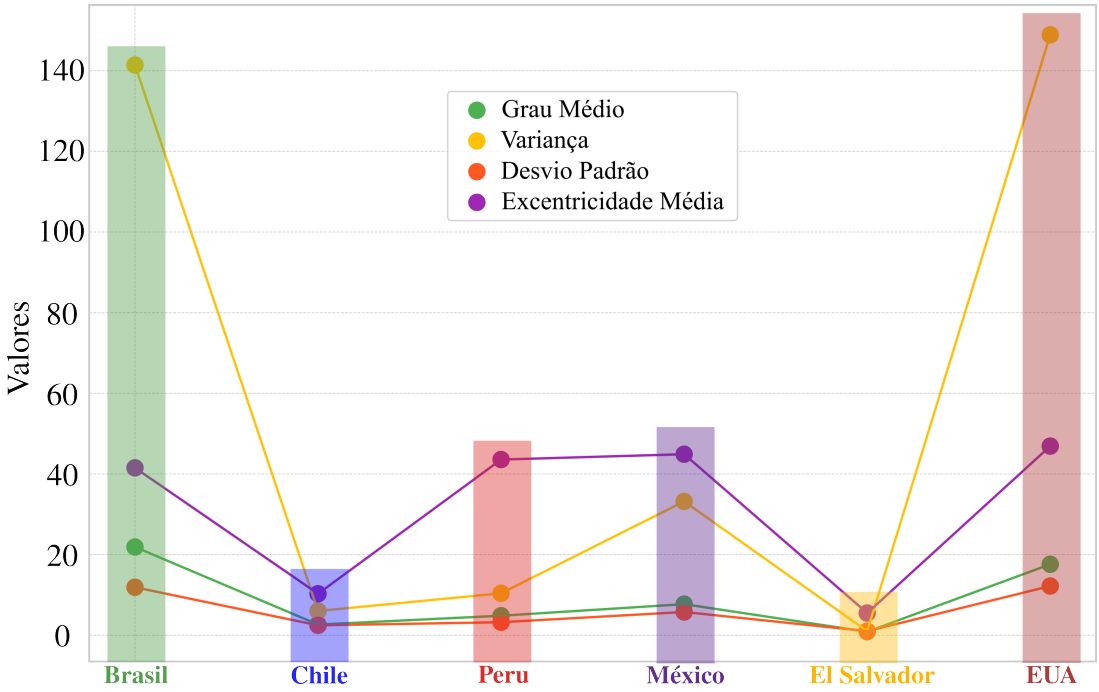

Figura 3.5 – Representação gráfica de quatro variáveis da tabela (Fig. 3.4), correspondendo a: Grau Médio, Variância, Desvio Padrão e Excentricidade, usando gráficos de barra e linha.

Em geral, um alto número de nós está correlacionado com altos valores em outras métricas. No entanto, características específicas, como variância, excentricidade e grau médio, merecem atenção. Brasil e EUA exibem valores substancialmente altos de variância, desvio padrão e grau médio em comparação com outros países, indicando uma variação significativa na distribuição dos pontos no gráfico de dispersão. Notavelmente, a excentricidade não segue as proporções das outras variáveis.

A variância e o desvio padrão dos graus dos nós no grafo refletem a diferença entre os graus máximos e mínimos na rede. Na tabela fornecida 3.4, países como Estados Unidos e Brasil, com altas variâncias e desvios padrões, mostram grandes diferenças entre os graus máximos e mínimos, indicando uma rede altamente heterogênea. Por outro lado, países com variância e desvio padrão mais baixos, como El Salvador e Chile, mostram diferenças menores entre os graus, sugerindo uma rede mais homogênea, com números semelhantes de conexões entre os municípios.

Adicionalmente, a regra de criação de arestas, baseada na proximidade de pontos no gráfico de dispersão, implica que um pequeno valor de grau máximo se refere a uma distribuição de pontos mais esparsa, enquanto um alto valor de grau máximo indica pontos mais próximos (mais densos). Isso é corroborado pelo grau médio apresentado. Portanto, a variância e o desvio padrão não apenas refletem a heterogeneidade da rede, mas também a distribuição espacial dos municípios no gráfico de dispersão.

3.2 Estudo de Caso: IDHM vs População dos Municípios do Brasil em nível macrorregional e regional (estadual)

NOTA: Esse estudo de caso pode ser aplicado a outros países desse banco de dados. Nesta dissertação, mostraremos apenas o caso de análise do Brasil, mas pelos códigos disponíveis no repositório oficial da tese 4.3.1 quanto pela ferramenta City Comparing , é possível gerar todos os gráficos dessa seção de resultados para os outros países. Além disso, é possível adicionar novos países por meio da funcionalidade de upload de tabelas, ampliando a abrangência das análises.

Como primeiro resultado, destacamos a importância de utilizar diferentes representações visuais para uma análise exploratória mais robusta dos dados. Na Figura 3.6, observamos as *binscatter lines* correspondentes à amostra de dados do Brasil como um todo e de cada macrorregião. Essas representações ajudam a identificar padrões específicos e comparações globais, dependendo do enfoque visual adotado.

Na Representação A, prioriza-se a forma visual individual de cada curva, o que permite observar características próprias de cada macrorregião com maior clareza. Por exemplo, destaca-se o fato de o nordeste ser a única macrorregião onde o *bin* com maior IDHM não corresponde ao de maior população, indicando uma particularidade estrutural na relação entre população e desenvolvimento humano nessa região. Além disso, os mínimos

globais das curvas tornam-se evidentes, permitindo notar que a macrorregião norte apresenta o mínimo global mais acentuado e deslocado para uma faixa de população maior, próxima de 30 mil habitantes, enquanto outras macrorregiões têm seus mínimos próximos da faixa de cidades com menos de 5 mil habitantes. Já o Brasil como um todo apresenta seu mínimo global próximo de 10 mil habitantes.

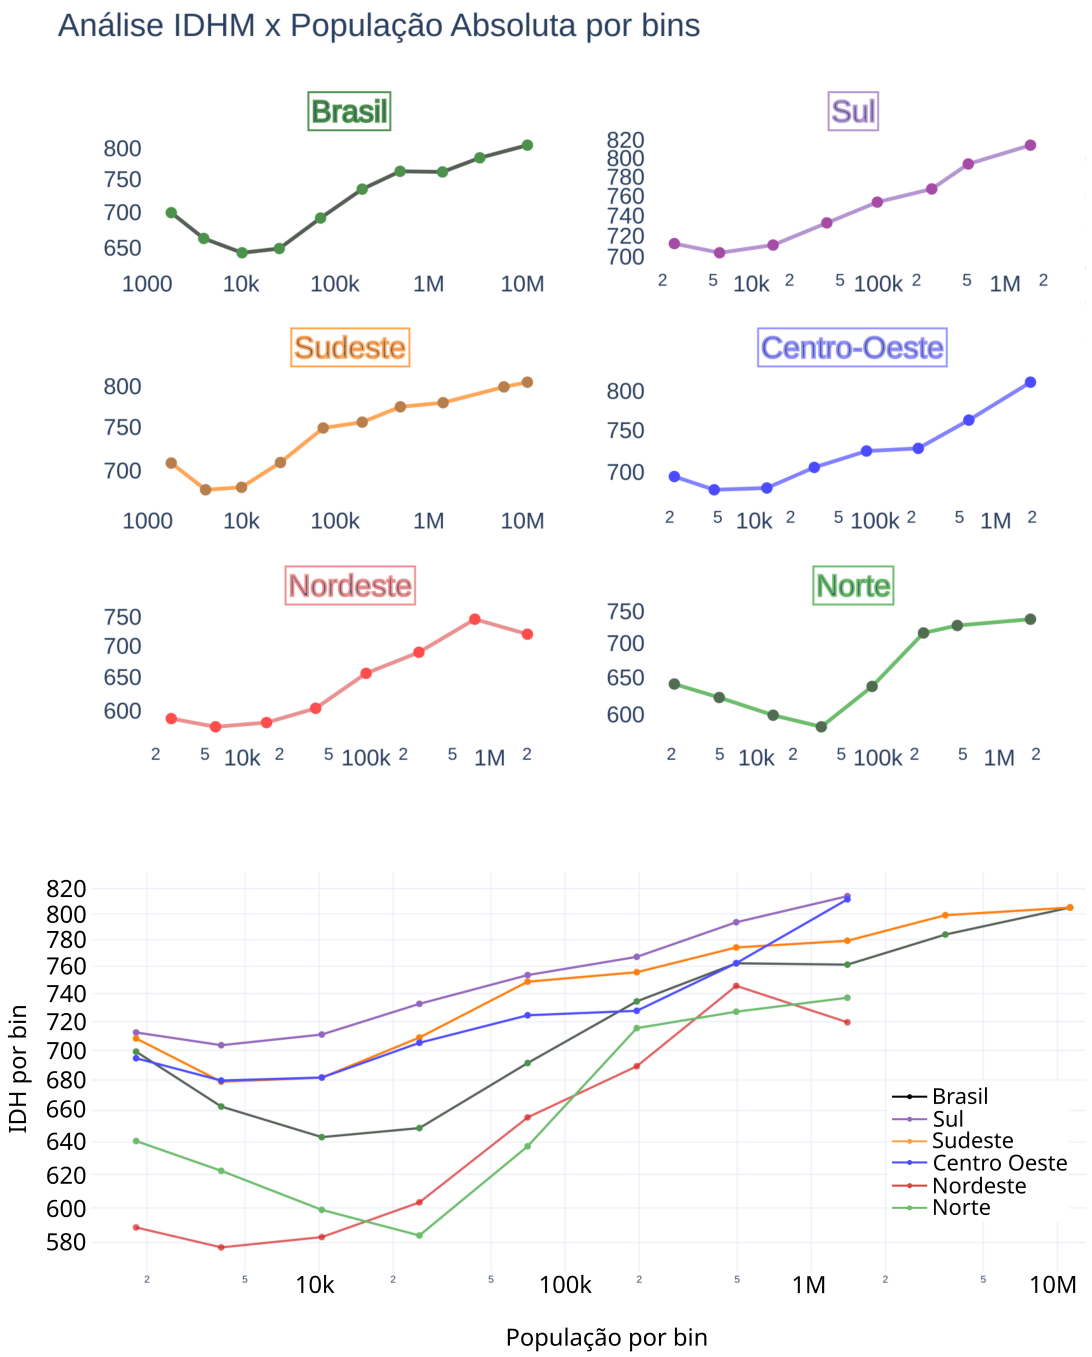

Figura 3.6 – Ilustração das 5 macrorregiões do Brasil, representadas com duas formatações visuais das mesmas amostras de dados. Acima, subítem a), com *subplots* independentes; abaixo, subítem b) com todas curvas *binscatter* plotadas em um mesmo gráfico, mantendo os mesmo limites de *bins* para todas curvas.

Na Representação B, a prioridade é facilitar a comparação direta dos valores absolutos entre as diferentes curvas. Essa abordagem evidencia, por exemplo, que o nordeste apresenta IDHM significativamente inferior às outras macrorregiões para *bins* com pequena e média população. Por outro lado, o norte também apresenta valores baixos em *bins* menores e, em algumas faixas de população, torna-se a macrorregião com o menor valor absoluto de IDHM. Observa-se, contudo, que o valor máximo de IDHM da curva do nordeste supera o valor máximo do norte, indicando uma recuperação relativa em *bins* com populações maiores.

Além disso, observa-se que a macrorregião sul apresenta os melhores valores de IDHM em todos os *bins* até a faixa de cidades com menos de 1,5 milhão de habitantes. Acima desta faixa, apenas o sudeste possui cidades, de acordo com o censo de 2010. Uma hierarquia decrescente geral entre as macrorregiões, considerando os valores de IDHM, seria: sul, sudeste, centro-oeste, Brasil (média geral), norte e, por último, nordeste. No entanto, é importante destacar que essa ordem pode variar em *bins* específicos, especialmente em faixas intermediárias de população.

Analisando em maior profundidade a Representação A, todas as macrorregiões apresentam mínimos globais, mas com diferenças marcantes. O norte possui um mínimo mais acentuado e deslocado para uma faixa de população maior, como mencionado anteriormente. Já o centro-oeste e o sudeste possuem mínimos globais menos pronunciados, indicando uma distribuição mais equilibrada entre IDHM e população. Essa diferença na "acentuidade" dos mínimos pode refletir desigualdades internas mais acentuadas em algumas regiões, especialmente em áreas menos densamente povoadas.

Outro padrão interessante é a recuperação de IDHM do nordeste em *bins* de maior população. Apesar de apresentar os menores valores em *bins* iniciais, a curva do nordeste cresce de forma mais pronunciada do que a do norte, o que pode estar relacionado a concentrações urbanas mais desenvolvidas em estados como Pernambuco e Bahia.

Por fim, na Representação B, é notável que os valores absolutos permitem observar com clareza que a macrorregião sul mantém uma liderança consistente em termos de IDHM até a faixa de 1,5 milhão de habitantes. Após essa faixa, o sudeste se torna dominante, refletindo a concentração de grandes cidades nessa região, como São Paulo (SP) e Rio de Janeiro (RJ), com populações acima desse limite.

Outra forma de visualizar e representar os mesmos dados é utilizando a comparação lado a lado com scatters, como apresentado na figura 3.7.

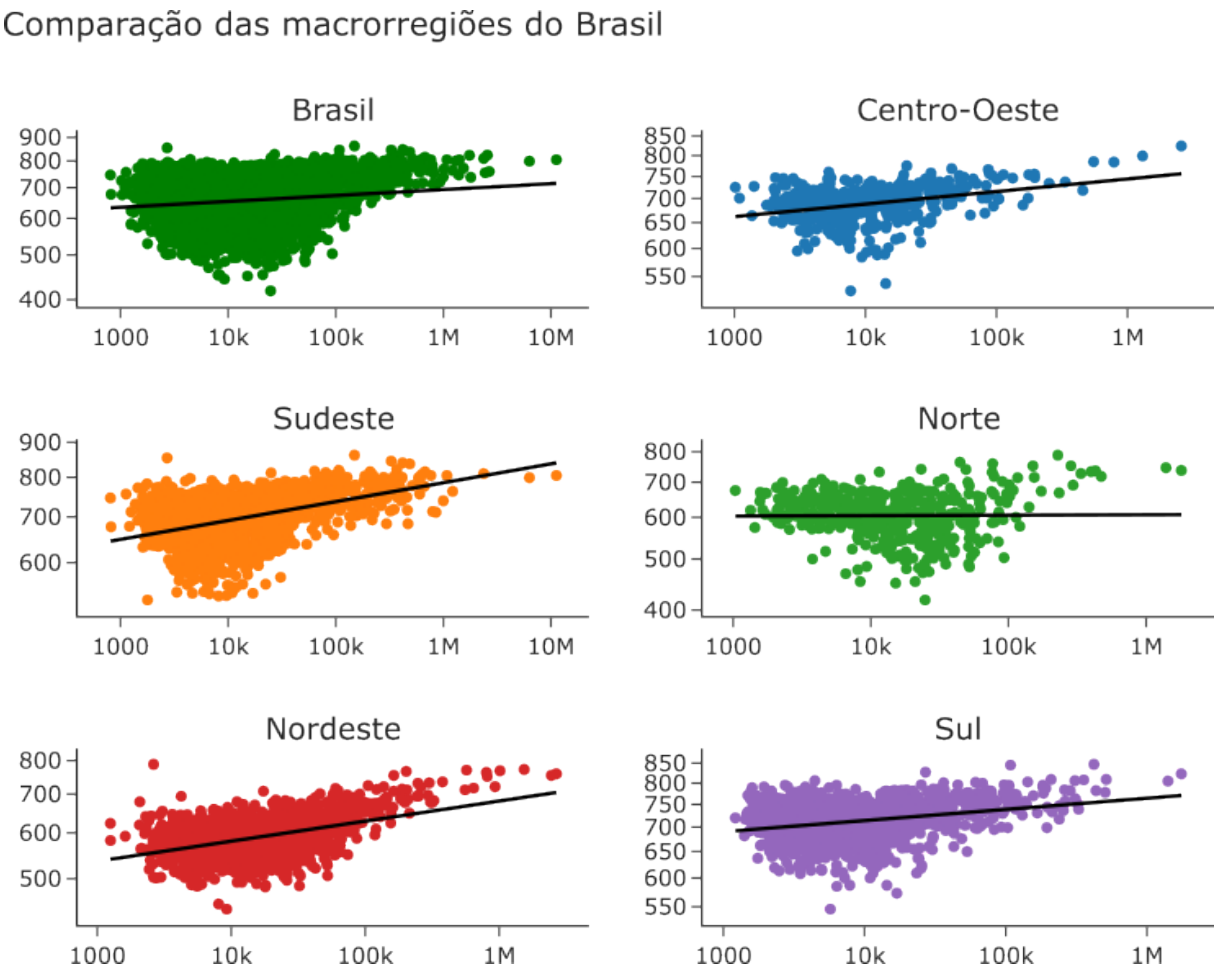

Figura 3.7 – Comparação lado a lado, de todos *scatter plots* das macrorregiões brasileiras e do Brasil.

Aqui podemos observar outras características das macrorregiões, como a alta variância dos dados em relação a valores absolutos de IDHM, quando se fixa um *bin*. Pelo *scatter*, notamos que, principalmente para regiões de menor população, cidades que possuem uma população semelhante podem ter IDHM bem distintos. À medida que a população aumenta, essa variância diminui, tendendo a inferir uma correlação positiva significativa entre aumento da população e aumento do IDHM.

Pela tabela A podemos notar que os valores de correlação global, quando calculados sobre toda a amostra de dados das macrorregiões, são pequenos e não muito significativos. Contudo, como podemos observar na figura (criar gráfico e fazer referência), quando se analisa a correlação variando a faixa amostral de população, notamos que para valores altos de população do limite inferior da faixa amostral, a correlação de Pearson se torna significativa. E pela figura (criar figura e referenciar), podemos definir duas regiões com comportamento distinto: uma de alta variância do IDHM e baixa correlação; outra de menor variância e correlação positiva significativa.

Nesse artigo não pretendemos nos aprofundar quanto à otimização de qual seria o melhor ponto de separação entre os dois regimes de comportamento identificados. Para

isso, estamos estruturando algumas técnicas, também utilizando a metodologia comparativa para a apresentação de argumentos e resultados mais robustos.

3.2.1 Análise por macrorregião

3.2.1.1 Sudeste

Como exemplo de análise mais aprofundada, utilizaremos a macrorregião sudeste. Quanto às outras macrorregiões, nos conteremos a observações mais gerais, ressaltando alguns destaques de características da macrorregião. Além disso, é importante lembrar que nos arquivos do repositório do GitHub (S.I) [4.3.1], há figuras contendo todos os estados lado a lado, tanto na representação de *scatter* quanto nas de *binscatters* com *subplots* independentes.

Para demonstrar a complementaridade e a robustez das análises visuais, utilizamos três representações distintas da mesma amostra de dados referentes à macrorregião sudeste: *scatter plots* comparativos, *binscatter lines* em *subplots* independentes e *binscatters* sobrepostos em um único gráfico. Essas representações são apresentadas, respectivamente, nas Figuras 3.8, 3.9 e 3.10.

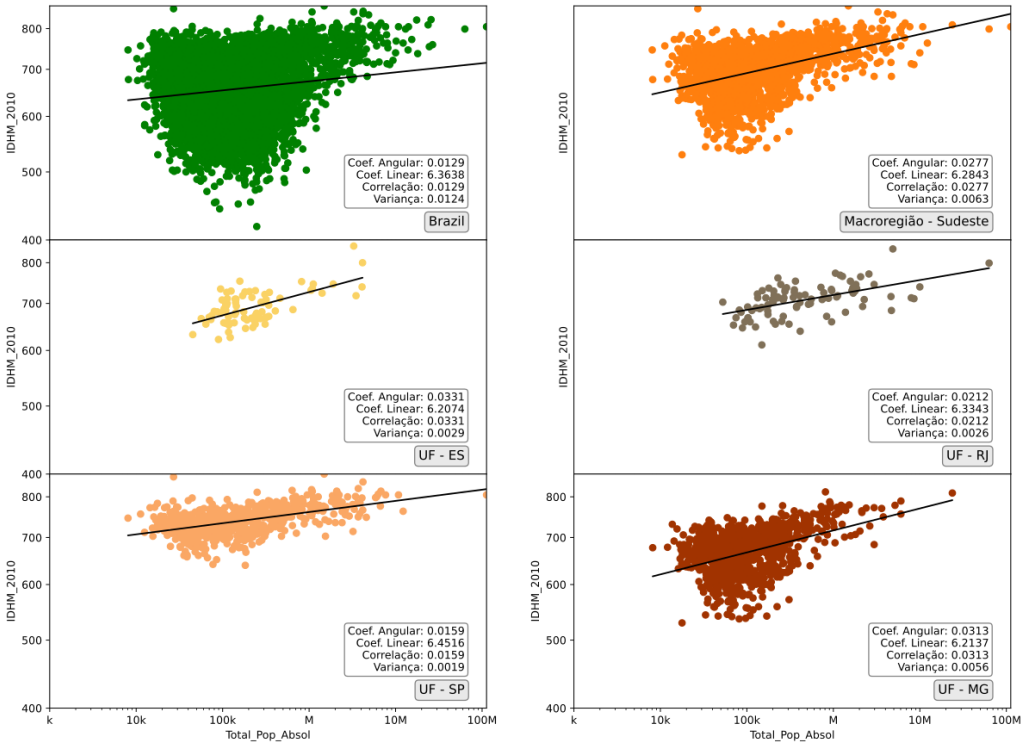

Figura 3.8 – *Subplots* independentes contendo *scatter plots* (gráficos de dispersão) lado a lado da macrorregião sudeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: Brasil, macrorregião sudeste, Espirito Santo (ES), Rio de Janeiro (RJ), São Paulo (SP) e Minas Gerais (MG).

Como já mencionado na introdução e metodologia, a representação por scatters tende a destacar mais características visuais entre as regiões comparadas. Nesse caso, diferentemente da figura 3.7, mantivemos fixos os valores dos eixos, o que faz com que a forma do scatter se comprima mais, amenizando acentuidades que visualmente poderiam indicar alguma característica própria.

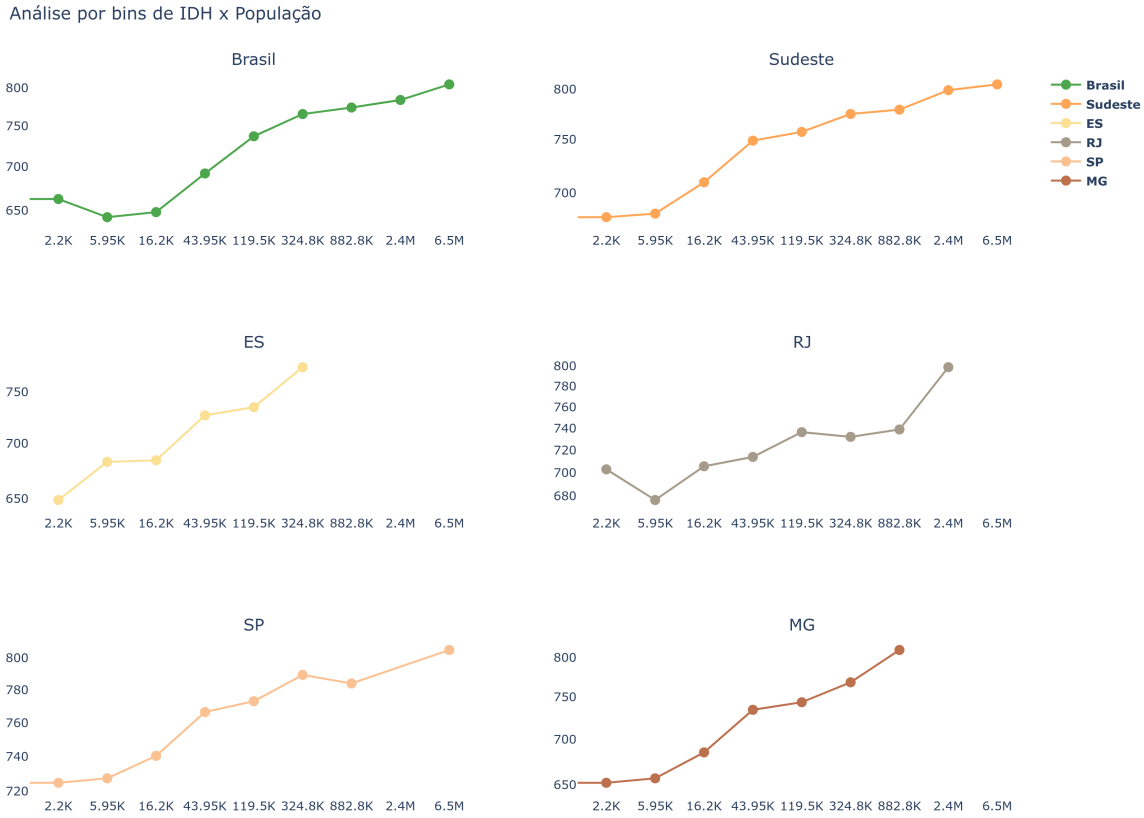

Figura 3.9 – *Subplots* independentes contendo *binscatter lines* lado a lado da macrorregião sudeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: Brasil, macrorregião sudeste, Espirito Santo (ES), Rio de Janeiro (RJ), São Paulo (SP) e Minas Gerais (MG).

Em contrapartida, justamente por fixar os valores nos eixos, podemos comparar os valores absolutos mais diretamente. Assim, notamos a proporção visual relativa entre os estados, como ES tendo uma concentração maior da faixa amostral tanto da população quanto do IDHM. Como também podemos perceber que a estrutura visual (o formato) do *scatter* de MG é o mais semelhante ao da macrorregião sudeste. No caso, mostrando a questão do aumento da correlação, com o aumento da população nos *bins* analisados. O ES apresenta uma exceção a essa relação do aumento de correlação com os *bins*, no qual a faixa de maior população do estado possui 4 cidades com uma variância de IDHM bem significativa entre elas. Além disso, é notável também que SP, RJ e ES apresentam maior homogeneidade ao longo do gráfico, enquanto MG apresenta uma estrutura mais triangu-

lar (tão qual o *scatter* da macrorregião sudeste). Essa análise ressalta como os *scatter plots* são eficazes para identificar padrões visuais e assimetrias entre regiões, mas têm limitações para comparações diretas em faixas específicas de valores, onde as *binscatter lines* se mostram mais úteis.

Uma análise mais aprofundada sobre classificação, usando *machine learning*, entre outras técnicas, e possíveis implicações desses formatos visuais da estrutura dos *scatters*, está sendo elaborada em outros projetos, na qual pretendemos publicar em um artigo separado.

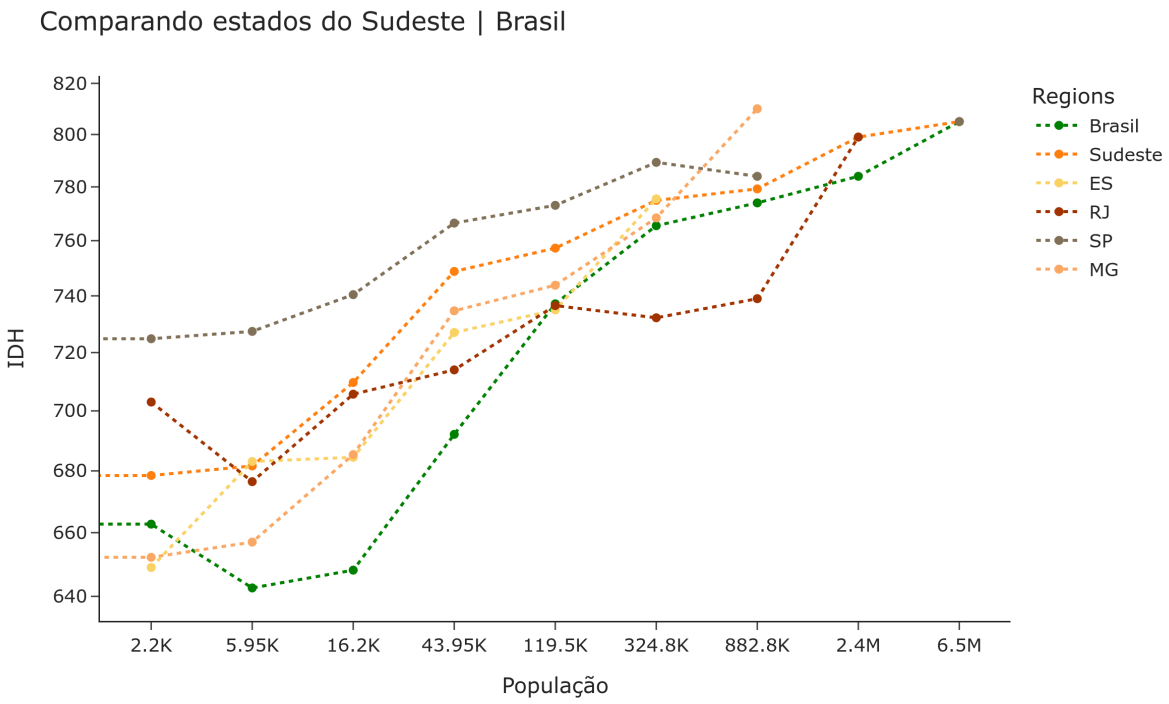

Figura 3.10 – *Binscatter lines* sobrepostos em um mesmo gráfico, mantendo mesmo limites de *bins* para todas curvas, da macrorregião sudeste, Brasil.

Quanto às representações de *binscatter lines*, presente na figura 3.9, devemos principalmente notar que somente uma das curvas dos estados, a do RJ, apresenta mínimo global. Todavia, o menor *bin* só possui uma cidade, Macuco (RJ), com 5269 habitantes, o que torna, na prática, um *bin* não muito significativo, o que, por muitas outras áreas, como por exemplo Econometria, iria ser desconsiderado da análise e, portanto, no RJ também não haveria mínimo global. Entretanto, como é econofísica, consideramos todos os pontos da amostra para a análise, mesmo que, nesse caso, realmente o mínimo global seja uma questão dessa representação em particular dos dados, que determinou uma distribuição fixa e igual a todos os limites dos *bins*, que inclui valores de população muito baixos em referência aos padrões do RJ.

E em relação à figura 3.10, na qual todas as curvas estão no mesmo gráfico, possibilita uma comparação direta entre os estados, *bin* por *bin*. Tal abordagem mostra que

SP detém os maiores valores de IDHM do sudeste, com exceção do *bin* com média de população de 882 mil habitantes, na qual MG se destaca. Também é possível notar, neste banco de dados referentes ao censo 2010, que SP não possui nenhuma cidade na faixa com média de 2,4 milhões de habitantes. A ordem descendente geral de todas as curvas, com referência no IDHM é: SP, sudeste, MG, ES e RJ, Brasil.

Essas diferentes representações são complementares, cada uma contribuindo de forma única para a análise. Os *scatter plots* são ideais para identificar padrões visuais gerais e diferenças estruturais entre os estados, enquanto as *binscatter lines* em *subplots* independentes destacam tendências locais e padrões únicos. Já as *binscatter lines* sobrepostas facilitam a comparação direta entre os estados, permitindo uma análise detalhada das variações relativas em cada *bin*. Essa abordagem está alinhada com os princípios de *visual analytics*, que combinam técnicas visuais para explorar dados complexos e garantir interpretações mais robustas. Trabalhos como os de Keim et al. (2008) e Mantegna e Stanley (2000) reforçam a relevância de múltiplas perspectivas visuais para evitar viés e assegurar conclusões mais abrangentes.

A análise da macrorregião sudeste ilustra como o uso de diferentes representações é essencial para aprofundar o entendimento dos dados. Enquanto os *scatter plots* oferecem uma visão geral das proporções e padrões, as *binscatter lines* detalham relações específicas entre IDHM e população em faixas definidas, proporcionando uma robustez metodológica que permite identificar características únicas de cada estado e da macrorregião como um todo.

3.2.1.2 *Sul*

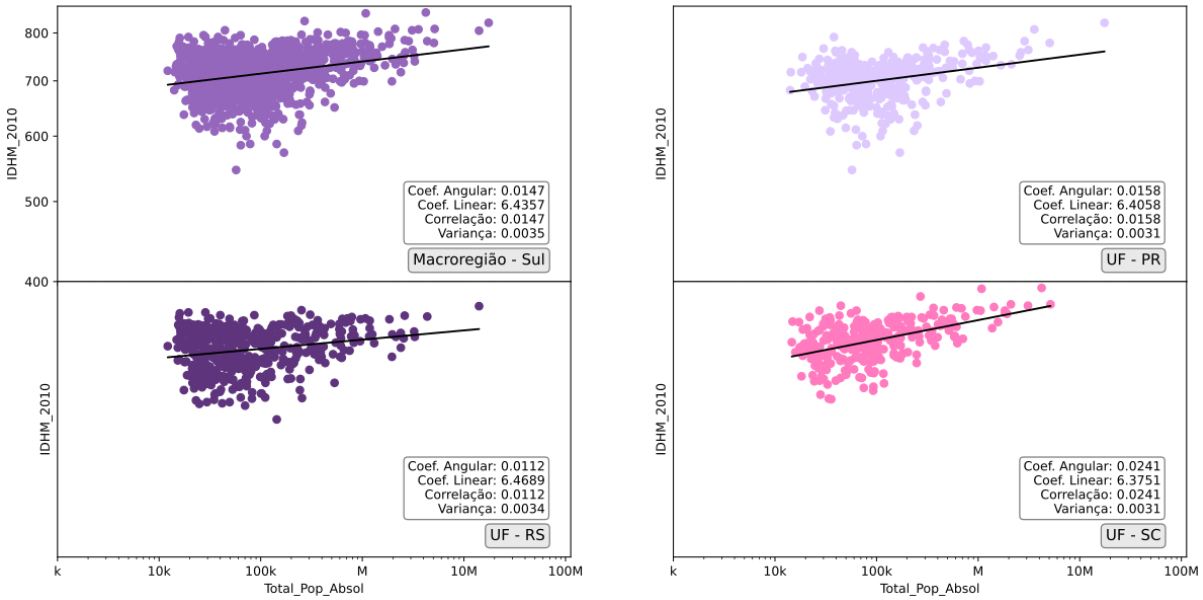

Figura 3.11 – *Subplots* independentes contendo *scatter Plot* (gráficos de dispersão) lado a lado da macrorregião sul, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião sul, Paraná (PR), Santa Catarina (SC) e Rio Grande do sul (RS).

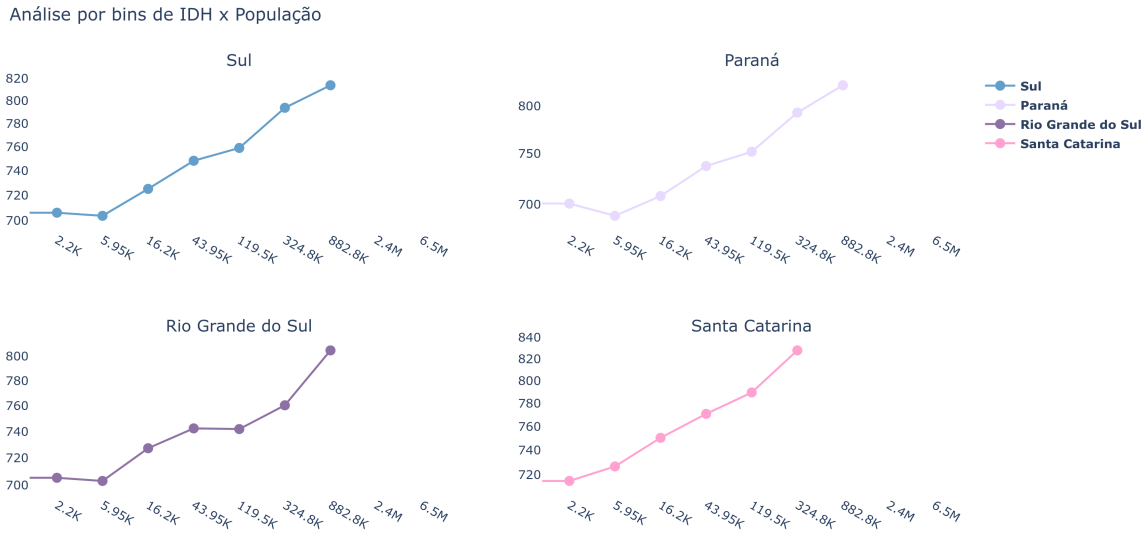

Figura 3.12 – *Subplots* independentes contendo *binscatter lines* lado a lado da macrorregião sudeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião sul, Paraná (PR), Santa Catarina (SC) e Rio Grande do sul (RS).

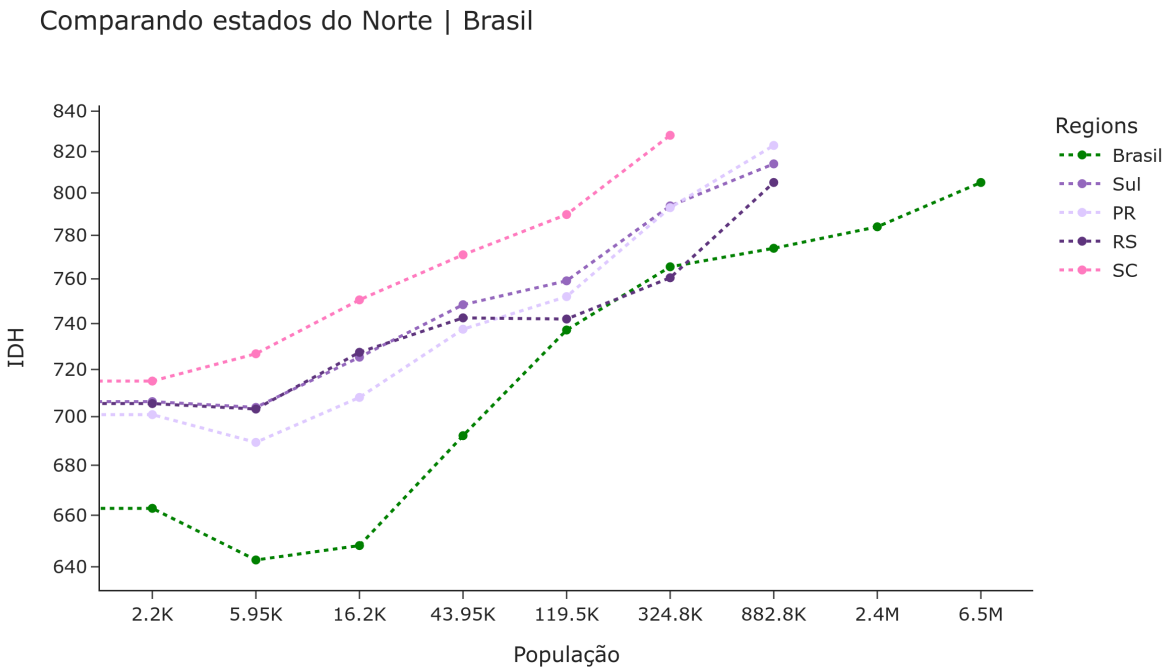

Figura 3.13 – *Binscatter lines* sobrepostos em um mesmo gráfico, mantendo mesmo limites de *bins* para todas curvas, da macrorregião sul, Brasil.

3.2.1.3 *Nordeste*

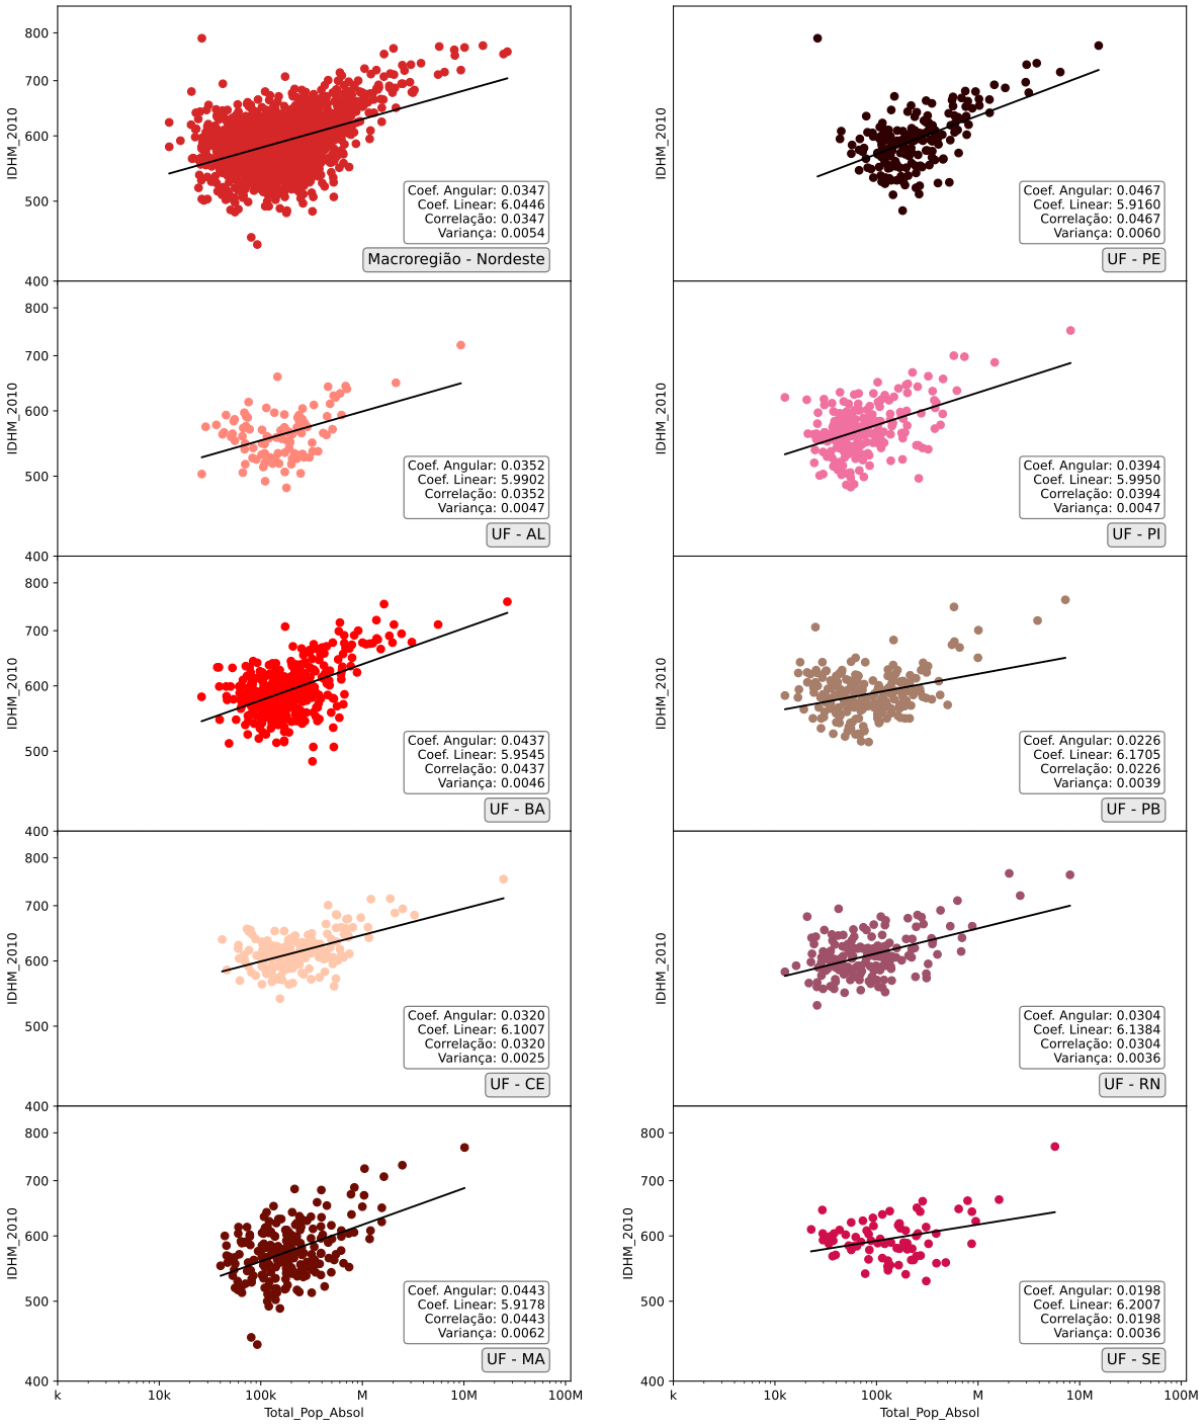

Figura 3.14 – *Subplots* independentes contendo *scatter plots* (gráficos de dispersão) lado a lado da macrorregião nordeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião nordeste, Pernambuco (PE), Alagoas (AL), Piauí (PI), Bahia (BA), Paraíba (PB), Ceara (CE), Rio Grande do norte (RN), Maranhão (MA) e Sergipe (SE).

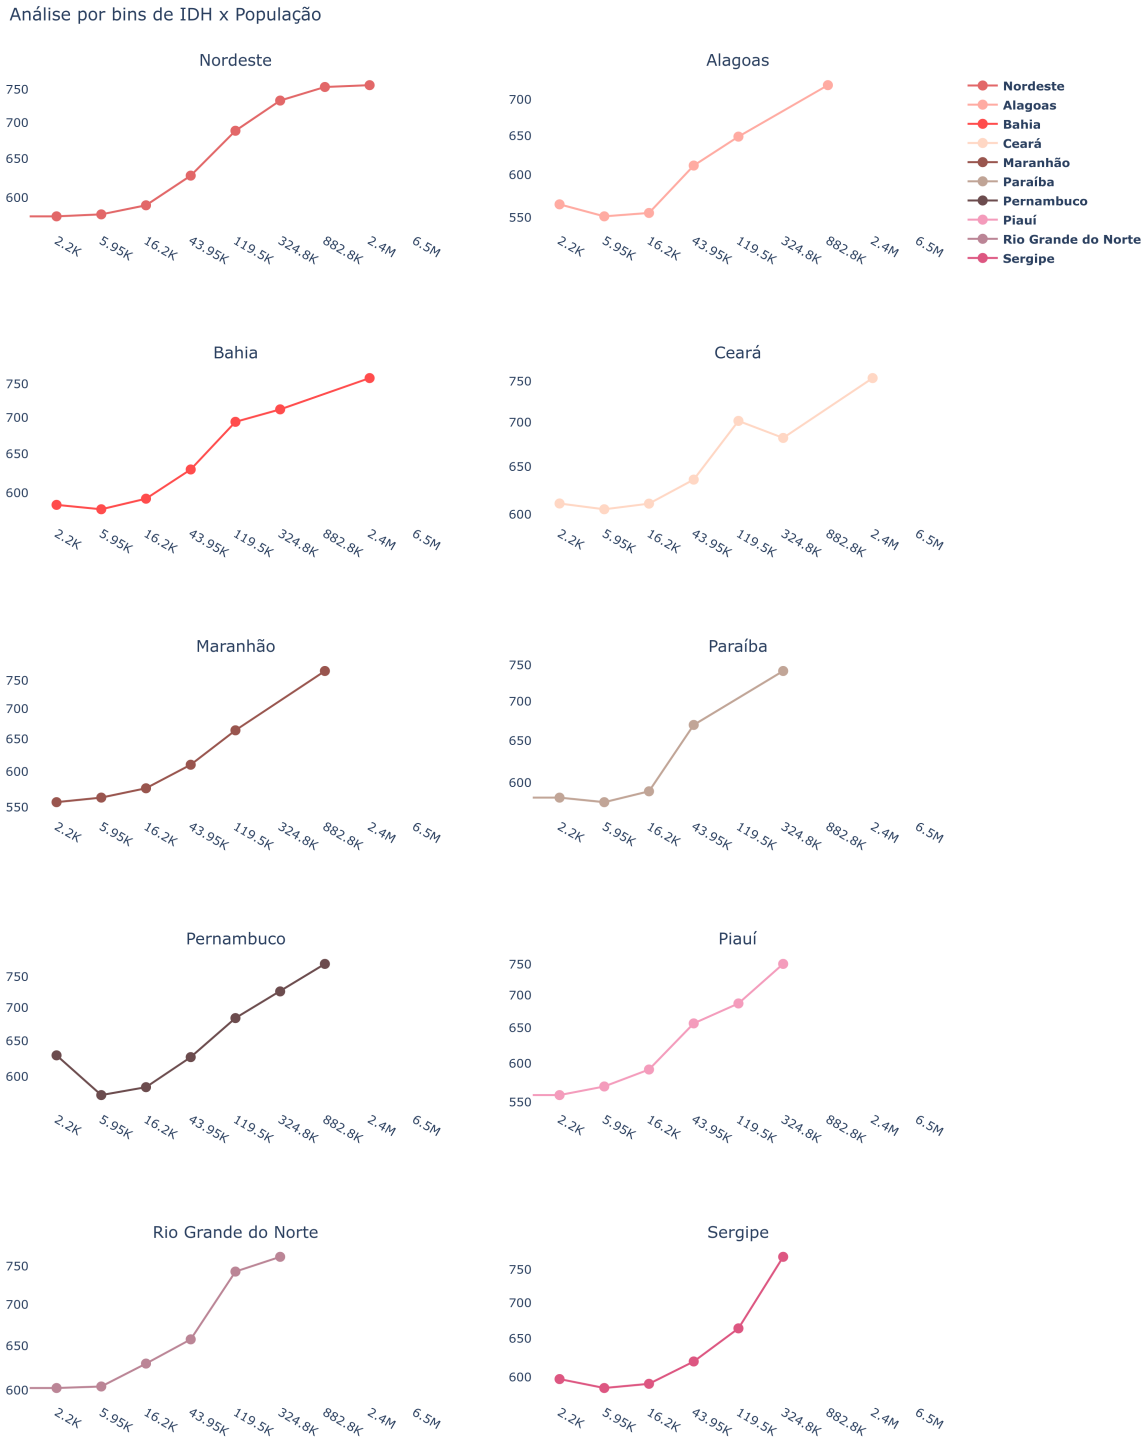

Figura 3.15 – *Subplots* independentes contendo *binscatter lines* lado a lado da macrorregião nordeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião nordeste, Pernambuco (PE), Alagoas (AL), Piauí (PI), Bahia (BA), Paraíba (PB), Ceara (CE), Rio Grande do norte (RN), Maranhão (MA) e Sergipe (SE).

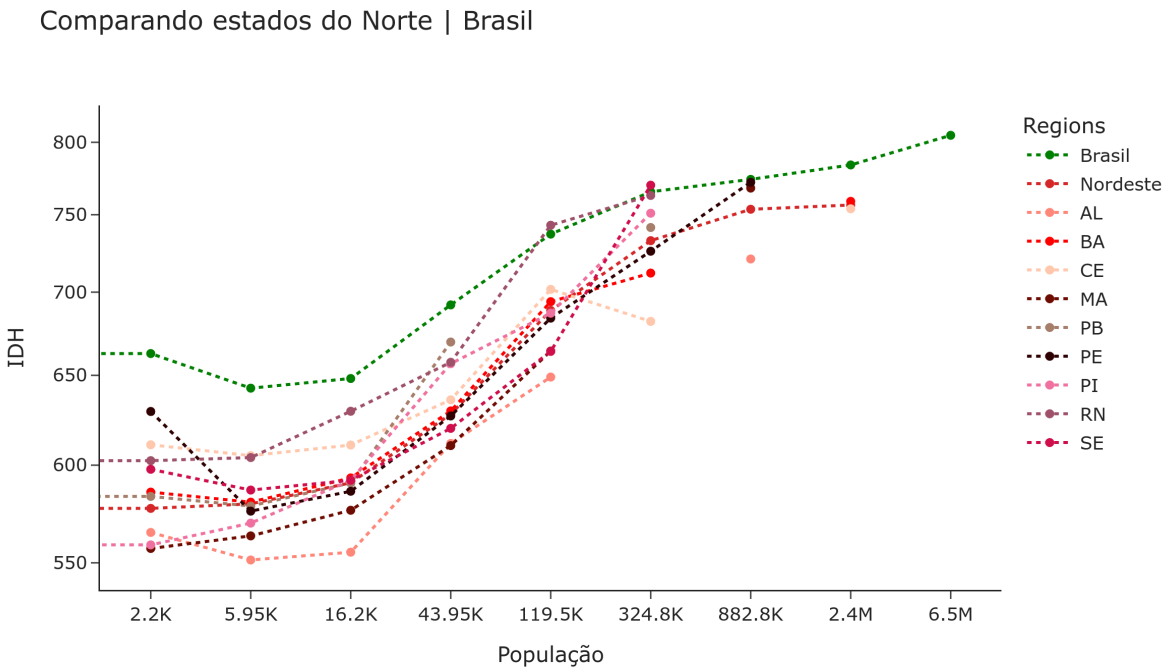

Figura 3.16 – *Binscatter lines* sobrepostos em um mesmo gráfico, mantendo mesmo limites de *bins* para todas curvas, da macrorregião nordeste, Brasil.

3.2.1.4 *Norte*

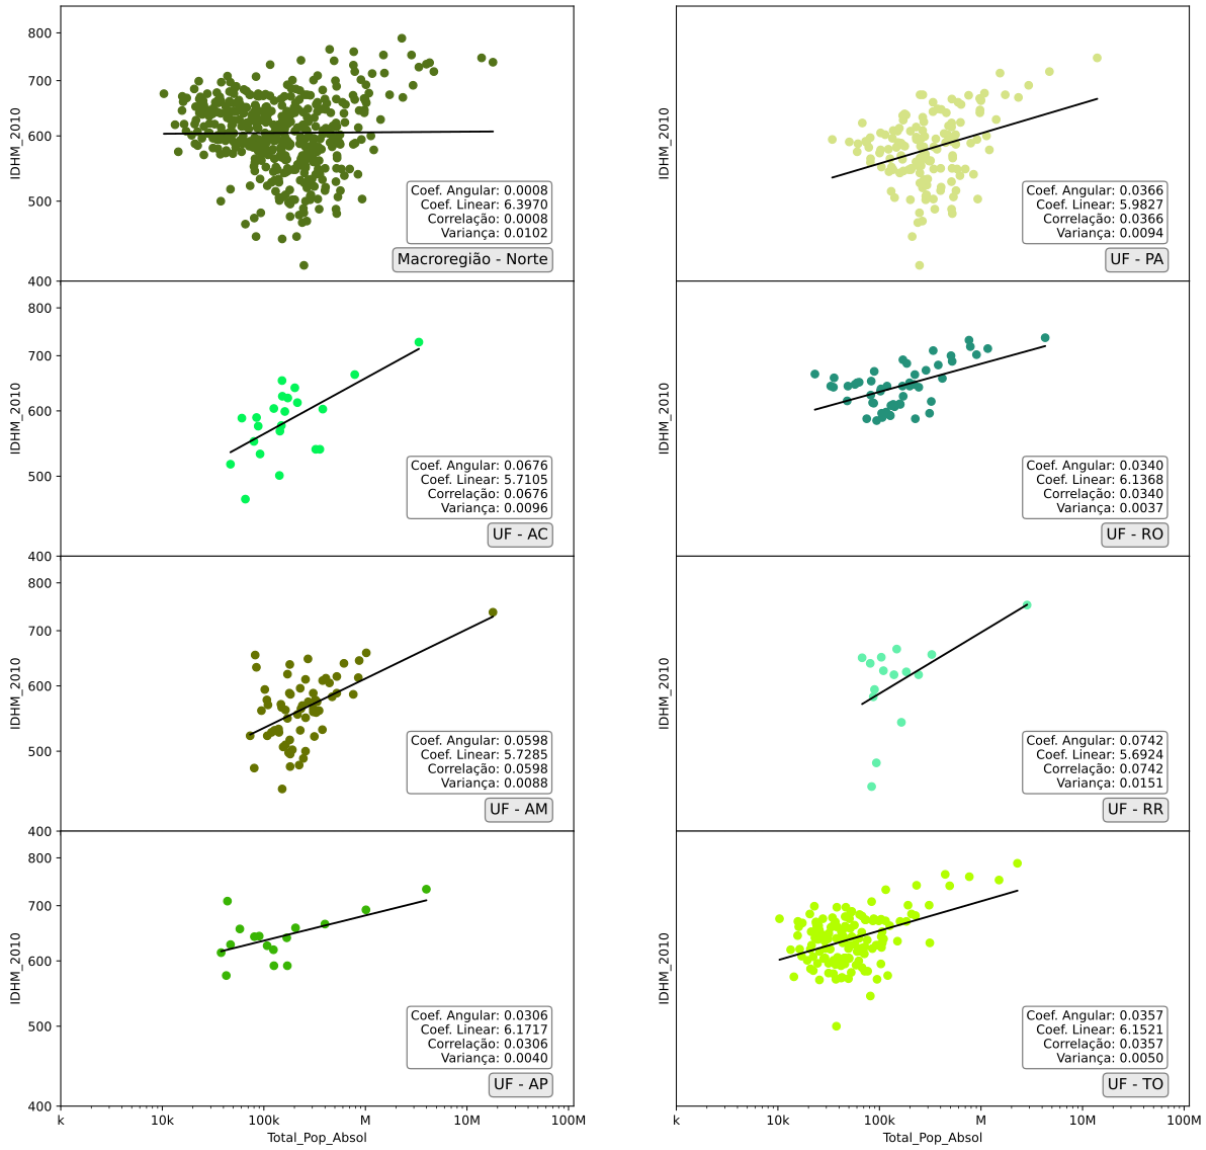

Figura 3.17 – Subplots independentes contendo *scatter plots* (gráficos de dispersão) lado a lado da macrorregião norte, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião norte, Pará (PA), Acre (AC), Rondônia (RO), Amazonas (AM), Roraima (RR), Amapá (AP) e Tocantins (TO).

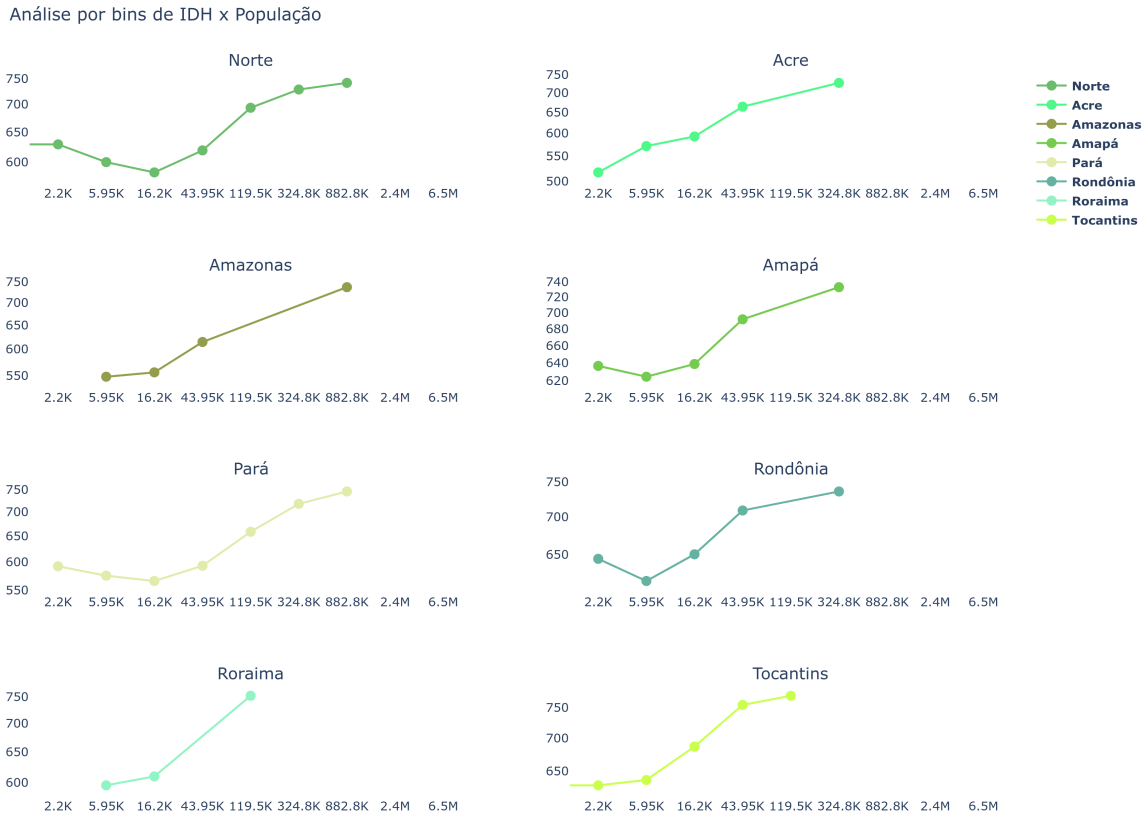

Figura 3.18 – Subplots independentes contendo *binscatter lines* lado a lado da macrorregião norte, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião norte, Pará (PA), Acre (AC), Rondônia (RO), Amazonas (AM), Roraima (RR), Amapá (AP) e Tocantins (TO).

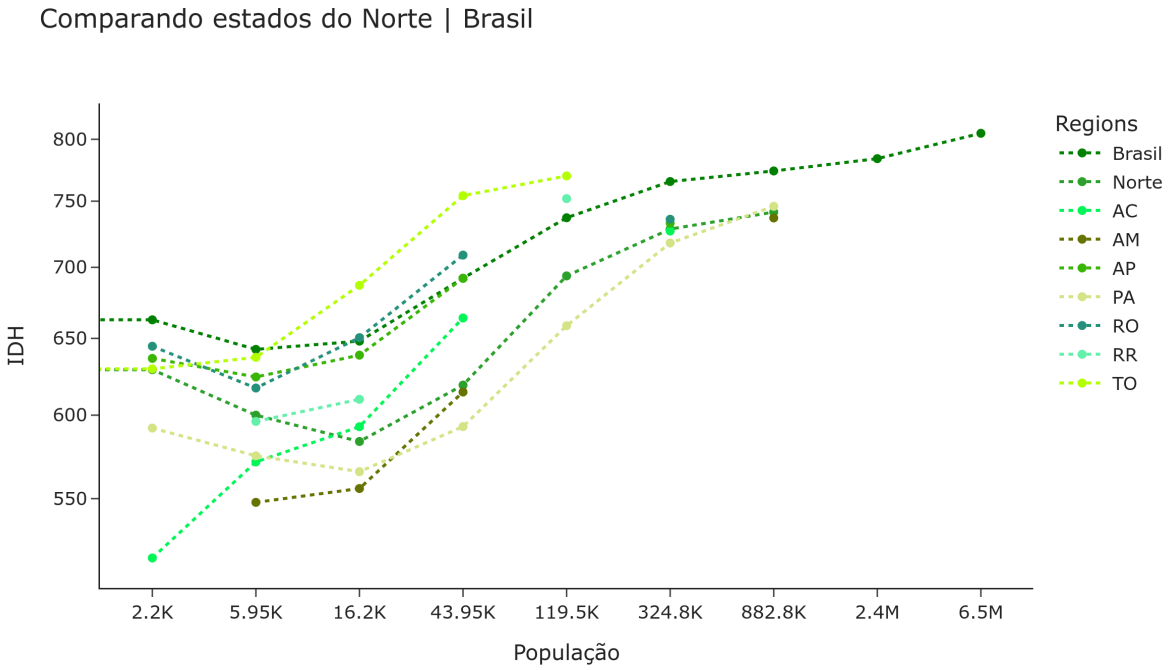

Figura 3.19 – *Binscatter lines* sobrepostos em um mesmo gráfico, mantendo os mesmo limites de *bins* para todas curvas, da macrorregião norte, Brasil.

3.2.1.5 Centro-Oeste

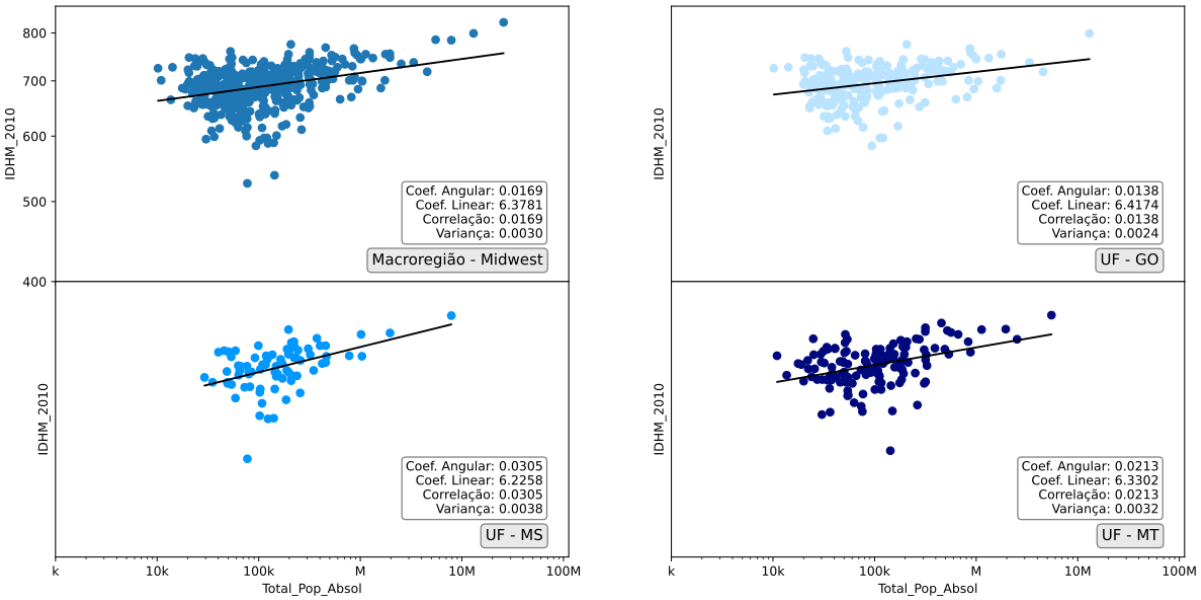

Figura 3.20 – Subplots independentes contendo *scatter plots* (gráficos de dispersão) lado a lado da macrorregião centro-oeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião centro-oeste, Goiás (GO), Mato Grosso do sul (MS) e Mato Grosso (MT).

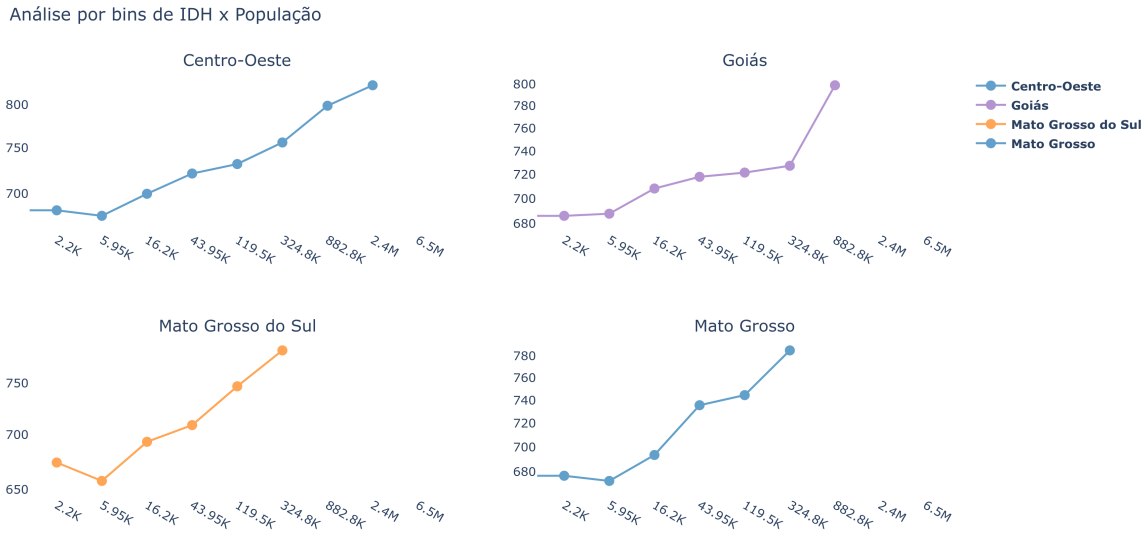

Figura 3.21 – Subplots independentes contendo *binscatter lines* lado a lado da macrorregião centro-oeste, Brasil. Respectivamente, da esquerda para direita, de cima para baixo: macrorregião centro-oeste, Goiás (GO), Mato Grosso do sul (MS) e Mato Grosso (MT).

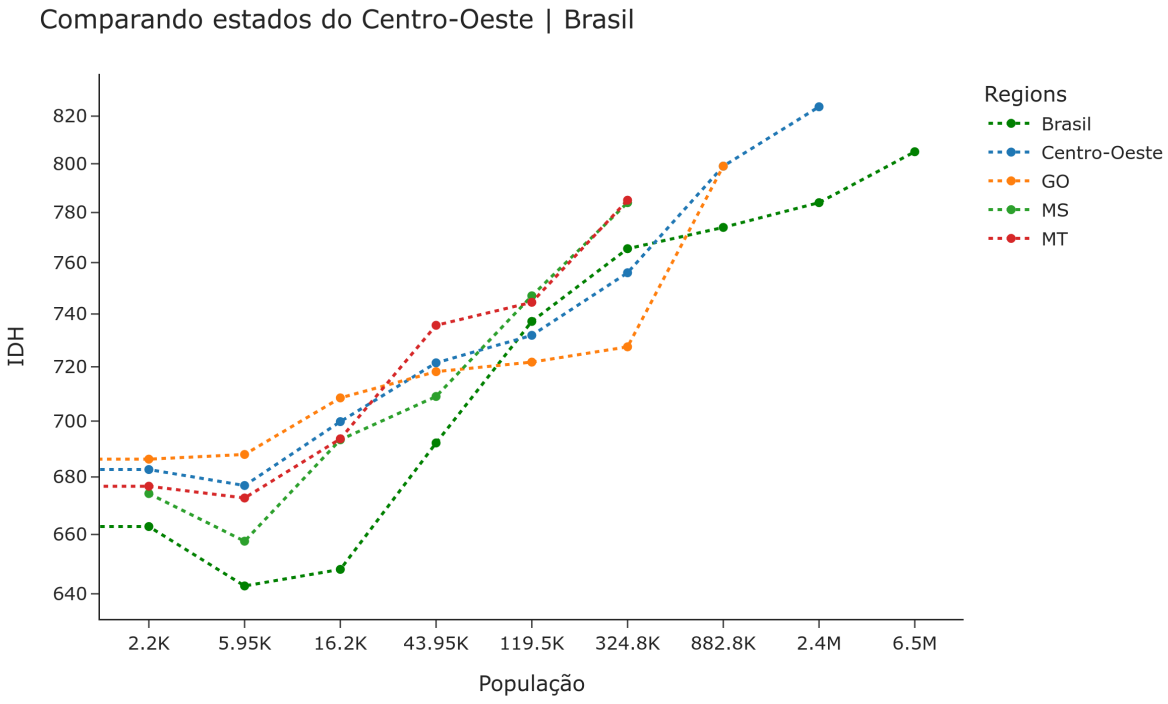

Figura 3.22 – *Binscatter lines* sobrepostos em um mesmo gráfico, mantendo mesmo limites de *bins* para todas curvas, da macrorregião centro-oeste, Brasil.

3.2.2 Resultados para Métricas Estatísticas: correlação, variança entre outras

A análise foi realizada utilizando uma tabela estatística e gráficos de métricas diversas para explorar a relação entre a população total e o IDHM 2010. A tabela estatística, que se encontra em anexo A, apresenta informações relacionadas à correlação de Pearson, valor mínimo, máximo, média e mediana dos eixos para ambas as variáveis (população e IDHM). Essa tabela foi gerada utilizando 100% da amostra, abrangendo todas as macrorregiões e estados brasileiros. Seu principal objetivo é fornecer uma visão geral, expositiva e complementar para a comunidade acadêmica. Apesar de seu caráter descritivo, observa-se que os valores de correlação apresentados indicam, em geral, uma baixa relação linear direta, refletindo, em parte, os problemas associados à heterogeneidade e variação não homogênea da variância ao longo dos dados. Essa variação é particularmente perceptível nas regiões de menor população, onde há maior dispersão no IDHM.

Adicionalmente, os gráficos apresentados na Fig.3.23 utilizam a redução progressiva da amostra em escala logarítmica para destacar o comportamento das métricas ao longo de diferentes níveis de representatividade. Essa redução segue uma abordagem em que intervalos logarítmicos são definidos no eixo populacional, e os dados de menor população são progressivamente excluídos. No caso da figura 3.23, a amostra que está sendo analisada é a da macrorregião sudeste; contudo, é possível expandir esse comportamento a outras macrorregiões, estados e à escala nacional.

Os gráficos mostram padrões interessantes. As correlações de Pearson e de Spearman, por exemplo, indicam picos em valores intermediários da amostra, com declínio à medida que a amostra é reduzida drasticamente. Isso pode ser explicado pelo aumento da variância em amostras menores, especialmente nos extremos populacionais. Em contrapartida, os valores de variância para a população crescem exponencialmente com a redução da amostra, enquanto a variância do IDHM diminui, demonstrando a estabilização relativa do IDHM nas cidades de maior população.

A inclusão das métricas de média e mediana do IDHM trouxe novas perspectivas. A média do IDHM cresce consistentemente à medida que a amostra é reduzida, destacando que as cidades restantes possuem, em média, níveis mais altos de desenvolvimento humano. A mediana do IDHM, por outro lado, acompanha um comportamento semelhante, reforçando a robustez da tendência de maior IDHM para populações maiores.

Esses resultados refletem uma relação visual clara entre o aumento da população e o crescimento do IDHM, evidenciado também pela análise dos gráficos de dispersão (*scatter plots*). As dispersões com forma visual triangular reforçam a hipótese de uma relação positiva, embora a correlação de Pearson sofra influência significativa das disparidades de variância nos dados.

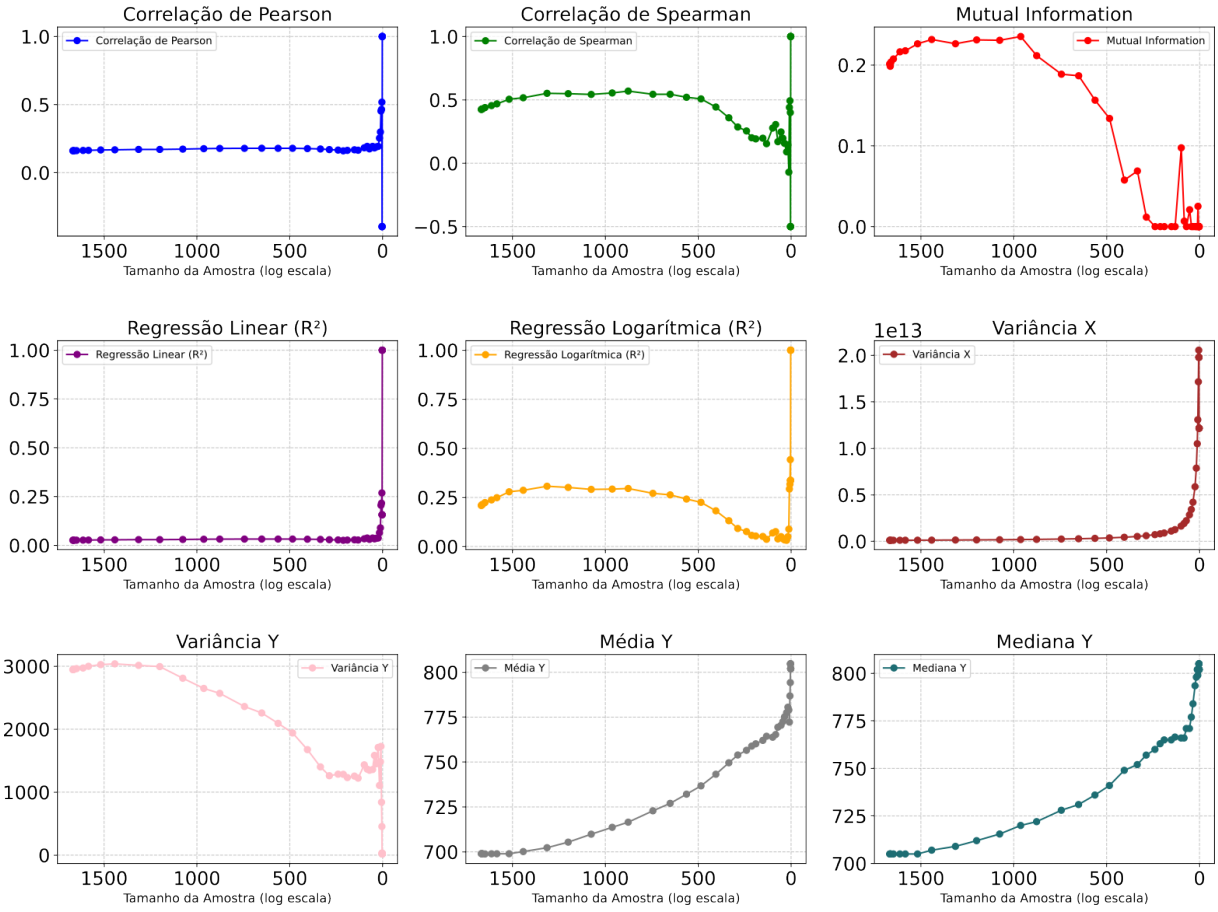

Figura 3.23 – Comparação entre diferentes alternaltivas de cálculo de correlação. Adicionalmente, há *subplots* da variância, média e mediana do IDHM e da população. Todas essas imagens, representam o comportamento das métricas em função de uma diminuição progressiva do tamanho da amostra.

Para a análise em escala logarítmica, além das correlações de Pearson e Spearman, utilizamos outras métricas como a “Informação Mútua”, “Regressões linear e logarítmica”, e métricas de dispersão (variância, média e mediana). A Informação Mútua revelou dependências não lineares mais sensíveis a padrões subjacentes, enquanto as regressões destacaram a importância de modelos lineares e exponenciais para compreender as tendências nos dados.

Por fim, é importante ressaltar que as abordagens utilizadas permitiram uma análise detalhada da relação entre população e IDHM, incluindo a avaliação de padrões globais e locais, contribuindo para uma melhor compreensão das dinâmicas socioeconômicas em diferentes níveis de agregação territorial no Brasil.

4 CONCLUSÃO

Entendemos que este trabalho pode contribuir para os desafios enfrentados na comparação de indicadores entre países, como evidenciado na Figura (Fig. 3.2), onde os valores do IDH para cidades chilenas são significativamente menores do que os de outros países da América Latina uma disparidade incongruente com o valor nacional calculado pelo Programa das Nações Unidas para o Desenvolvimento (PNUD). Após uma análise detalhada deste caso, percebemos que esses valores mais baixos resultam de um ajuste de critério econômico adotado pelo instituto de pesquisa chileno, que opta por uma escala independente e nacional para comparações entre cidades. Outra questão relevante de escala diz respeito ao limite superior na tabela de dados do IDH para regiões nos EUA, ligeiramente acima de 1000 (acima do padrão estabelecido pelo PNUD). Acreditamos que essa discrepância origina-se dos dados obtidos do banco de dados dos EUA, que fornece duas colunas: uma sem ajuste e outra com ajuste de IDH. A coluna ajustada incorpora critérios adicionais além dos três pilares do IDH, causando variações significativas nos valores finais do índice. Ao usar a coluna não ajustada, como adotado neste trabalho ao agrupar por condado, observamos a ocorrência desses pontos acima do limite superior. Diante deste problema, adotamos o princípio apoiado por (BACKHOUSE; MORGAN, 2000): econofísica rejeita normalização, log-normalização e mineração de dados visando eliminar dados anômalos de baixa frequência. Assim, consideramos que não há dados anômalos, mas sim dados de baixa frequência, que não devem ser descartados, pois podem ser peças-chave para entender um fenômeno (HOOVER; PEREZ, 2000).

Diante dessas questões, percebemos que não devemos percebê-las exclusivamente como obstáculos, mas sim como componentes essenciais da justificação que sustenta a premissa fundamental apresentada na introdução deste trabalho: “como fazer comparações em cenários com bases de cálculo diferentes?”. Portanto, é crucial explorar metodologias alternativas, como as empregadas em “Matemática Visual”[1] neste trabalho. Embora ainda não tenhamos alcançado uma solução definitiva, os resultados dos gráficos e as abordagens *Binscatter* e B-GCA permitem uma avaliação comparativa, tanto visual quanto numérica, entre os países.

Consideramos o caso específico de analisar um único indicador como base para trabalhos futuros, possibilitando o desenvolvimento de novas abordagens com características independentes de escala.

Os resultados deste estudo apresentam potenciais aplicações em áreas relacionadas que utilizam análises de distribuições de indicadores urbanos. Por exemplo, gráficos de dispersão podem representar a distribuição de relações entre cidades e caracterizar as proporções dos valores dos indicadores em cada estado, macrorregião ou país. Além disso, é possível identificar semelhanças entre diferentes países e classificar regiões simi-

[1] Para mais informações sobre o tópico: (PALAIS, 1999; TUFTE, 2001; MANCOSU, 2005)

lares, inferindo que tais regiões compartilham características comuns e, portanto, podem trocar informações de gestão. Se uma região tem uma distribuição semelhante a outra, podemos inferir que enfrentam problemas semelhantes em relação à distribuição de recursos governamentais.

Ademais, podemos identificar “cidades típicas” nos gráficos que representam padrões regionais ou determinar a probabilidade de uma cidade ter um certo IDH com base em sua faixa populacional. Também é possível verificar as proporções e correlações entre indicadores, como observado em alguns estados que apresentam mínimos globais em suas respectivas séries geradas pelo processo *binscatter*. A existência de um mínimo sugere que a correlação se inverte em determinado ponto. No caso do IDH, isso significa que cidades até o ponto mínimo tendem a apresentar uma redução no IDH à medida que a população aumenta, enquanto, além desse ponto mínimo, a relação se inverte. Essa descoberta é uma das principais conclusões da pesquisa, particularmente em termos práticos para formuladores de políticas públicas. Em certos casos, notavelmente no Brasil e no Peru, municípios com uma população em torno de 10.000 habitantes apresentam os piores índices de IDH. Portanto, ao projetar o crescimento de pequenas cidades, esse fator deve ser levado muito a sério.

Características específicas dos gráficos podem permitir análises sociológicas, como: “Por que Brasil e Peru, ou México e EUA, apresentam distribuições semelhantes no gráfico de dispersão?” . Existem fatores socioeconômicos além do IDH que poderiam explicar ou replicar tais semelhanças? Questões estatísticas também podem ser inferidas, como a distribuição e o cálculo de médias: “Por que os ajustes de IDH versus População na macrorregião norte do Brasil apresentam praticamente nenhuma correlação, enquanto cada estado individualmente mostra correlação positiva significativa (e, às vezes, forte)”, enquanto os gráficos de outras macrorregiões reproduzem as correlações dos estados individuais.

4.1 Trabalhos Futuros

Os desenvolvimentos futuros incluem a análise das relações entre o IDHM e a Densidade Populacional, bem como entre o IDHM e outras características das unidades federativas presentes nos conjuntos de dados já compilados por nossa equipe. Além disso, planejamos estender estas análises para incluir mais países, considerando até regiões fora das Américas. Por último, reafirmamos que a ferramenta online de análise resultante dessa tese estará em contínua manutenção, atualização e aprimoramento.

4.2 Agradecimentos

Este trabalho foi apoiado pelo Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq).

4.3 Bancos de Referências

Sites de Dados Governamentais (ou informes oficiais em PDF do IDH):

- México: México Link DataBase | <https://www.inegi.org.mx/siscon/>;
- Chile: Chile Link DataBase | <https://repositorio.uautonoma.cl/bitstream/handle/20.500.12728/6742/V11_digital_final.pdf?sequence=1&isAllowed=y>;
- Peru: Peru Link DataBase | <https://www.up.edu.pe/egp/programas-especializacion_copy(1)/SiteAssets/Lists/Observatorio/AllItems/Informe%20de%20Evidencia%20IDH%202019.pdf> ;
- El Salvador: ElSalvador Link DataBase | <https://www.undp.org/sites/g/files/zskgke326/files/publications/El%20Salvador_MDGReport_2005_SP.pdf> ;
- Brasil: Brasil Link DataBase | <https://censo2010.ibge.gov.br/resultados.html>;
- EUA: EUA Link DataBase | <https://web.archive.org/web/20110615084942/http://www.census.gov/hhes/www/poverty/poverty.html>.

4.3.1 Informações Suplementares (S.I)

Dados publicamente disponíveis em um repositório:

O conjunto de dados, imagens, diagramas, gráficos, códigos e outras informações importantes que apoiam ou complementam este artigo podem ser encontrados em seu repositório Github Repository Thesis.

Em adição à tese, elaboramos uma aplicação web City Comparing. Na data de publicação dessa tese, a ferramenta web encontra-se na publicação da Versão Alpha; o que significa que, para usuários que acessarem posteriormente, provavelmente encontrarão versões mais recentes, com aplicações novas e mais recursos na aplicação. Se o site / URL não estiver acessível, busque a aplicação atual no repositório oficial da dissertação; ou acessando o site da Empresa pessoal do Autor: Instituto Pense Mais.

Caso os hiperlinks não estejam funcionando, segue abaixo as URL bases da tese, escritas de forma explícita (por extenso):

- Github Repository Thesis: <https://github.com/LeonardoCamargoRossato/Analysis_SocioEconomic_Indicator/tree/main/Master_Thesis_EconoPhysics__UFRGS>
- City Comparing: <https://analysis-socioeconomic-indicators.streamlit.app/>
- Instituto Pense Mais: <https://institutopensemais.com/>

REFERÊNCIAS BIBLIOGRÁFICAS

ANTO, M. H. Introducing an Islamic Human Development Index (I-HDI) to Measure Development in OIC Countries. **Islamic Economic Studies**, 2011. Disponível em: <https://ideas.repec.org/a/ris/isecst/0024.html>.

BACHELIER, L. **Théorie de la spéculation**. [S.l.: s.n.], 1900. ISBN 9780691117522.

____. **Louis bachelier's theory of speculation**. Princeton, NJ: Princeton University Press, 2006.

BACKHOUSE, R. E.; MORGAN, M. S. Introduction: is data mining a methodological problem? **Journal of Economic Methodology**, Informa UK Limited, v. 7, n. 2, jan. 2000. ISSN 1469-9427. Disponível em: <http://dx.doi.org/10.1080/13501780050045065>.

BALTAGI, B. H. What is econometrics? In: **Econometrics**. Springer Berlin Heidelberg, 2011. Disponível em: <https://doi.org/10.1007/978-3-642-20059-5_1>.

BARZA, R. et al. **Cities as Engines of Opportunities: Evidence from Brazil**. [S.l.], 2024. Accessed: 2024-03-12. Disponível em: <http://www.nber.org/papers/w32426>.

BLACK, F.; SCHOLES, M. S. The pricing of options and corporate liabilities. **Journal of Political Economy**, 1973.

BOOZER, M. A. et al. Paths to success: The relationship between human development and economic growth. **Economic Growth eJournal**, 2003. Disponível em: <https://ssrn.com/abstract=487469>.

BRAUN, T.; SCHUBERT, A. Scientometric versus socio-economic indicators. scatter plots for 51 countries. 19781980. **Scientometrics**, Springer Science and Business Media LLC, v. 13, jan. 1988. ISSN 1588-2861. Disponível em: <http://dx.doi.org/10.1007/BF02095758>.

CAO, L. Data science: Challenges and directions. **Communications of the ACM**, ACM, 2017.

CASTRO, L. L. e; PAULA, F. L. de O. O processo de definição de sociofísica e econofísica como campos de estudo. **Revista do Professor de Física**, Instituto de Física - Universidade de Brasília, dezembro 2020. ISSN 2675-7026. Disponível em: http://periodicos.unb.br/index.php/rpf/article/view/29813. Disponível em: <http://periodicos.unb.br/index.php/rpf>.

CATTANEO, M. D. et al. On binscatter. **SSRN Electronic Journal**, Elsevier BV, 2019. ISSN 1556-5068. Disponível em: <http://dx.doi.org/10.2139/ssrn.3344739>.

CHAKRABORTI, A. et al. Econophysics review: I. empirical facts. **Quantitative Finance**, Informa UK Limited, v. 11, n. 7, jun 2011. ISSN 1469-7696. Disponível em: <http://dx.doi.org/10.1080/14697688.2010.539248>.

DALBERTO, C. et al. Índice de desenvolvimento humano eficiente: Uma mensuraÇÃo alternativa do bem-estar das naÇÕes. **Pesquisa e planejamento econômico**, 10 2015.

GOMEZ, J.; DASGUPTA, D.; NASRAOUI, O. A new gravitational clustering algorithm. **SIAM: Society for Industry and Applied Mathematics**, Society for Industrial and Applied Mathematics, maio 2003. Disponível em: <http://dx.doi.org/10.1137/1.9781611972733.8>.

HEER, J.; BOSTOCK, M.; OGIEVETSKY, V. A tour through the visualization zoo. **Communications of the ACM**, ACM, 2010.

HERRERO, C.; MARTíNEZ, R.; VILLAR, A. Population structure and the human development index. **Social Indicators Research**, Springer Science and Business Media LLC, v. 141, n. 2, fev. 2018. ISSN 1573-0921. Disponível em: <http://dx.doi.org/10.1007/s11205-018-1852-0>.

HESHMATI, A.; OH, J. Alternative Composite Lisbon Development Strategy Indices: A Comparison of EU, USA, Japan and Korea. **European Journal of Comparative Economics**, December 2006. Disponível em: <https://ideas.repec.org/a/liu/liucej/v3y2006i2p131-170.html>.

HICKS, D. A. The inequality-adjusted human development index: A constructive proposal. **World Development**, Elsevier BV, v. 25, ago. 1997. ISSN 0305-750X. Disponível em: <http://dx.doi.org/10.1016/S0305-750X(97)00034-X>.

HOOVER, K. D.; PEREZ, S. J. Three attitudes towards data mining. **Journal of Economic Methodology**, Informa UK Limited, v. 7, jan. 2000. ISSN 1469-9427. Disponível em: <http://dx.doi.org/10.1080/13501780050045083>.

JAHAN, S. Measuring living standard and poverty: Human development index as an alternate measure. **University of Massachusetts Political Economy Research Institute. URL: http://www. umass. edu/peri/pdfs/glw_jahan. pdf**, 2002.

JANNUZZI, P. d. M. Considerações sobre o uso, mau uso e abuso dos indicadores sociais na formulação e avaliação de políticas públicas municipais. **VEREDAS, Revista Eletrônica de Ciências**, 2002.

KEIM, D. A. et al. Visual analytics: Scope and challenges. **Proceedings of the 2008 Visual Analytics Science and Technology (VAST) Conference**, IEEE, 2008. Disponível em: <http://infovis.uni-konstanz.de>.

KLUGMAN, J.; RODRíGUEZ, F.; CHOI, H.-J. The hdi 2010: new controversies, old critiques. **The Journal of Economic Inequality**, Springer Science and Business Media LLC, v. 9, n. 2, maio 2011. ISSN 1573-8701. Disponível em: <http://dx.doi.org/10.1007/s10888-011-9178-z>.

MANCOSU, P. **Visualization in Logic and Mathematics**. [S.l.]: Springer Netherlands, 2005. ISSN 2542-8292. ISBN 9781402033353.

MANTEGNA, R. N.; KERTÉSZ, J. Focus on statistical physics modeling in economics and finance. **New Journal of Physics**, IOP Publishing, v. 13, fev. 2011. Disponível em: <https://doi.org/10.1088/1367-2630/13/2/025011>.

MAYORGA, A.; GLEICHER, M. Splatterplots: Overcoming overdraw in scatter plots. **IEEE Transactions on Visualization and Computer Graphics**, IEEE, v. 19, 2013. Disponível em: <https://doi.org/10.1109/TVCG.2013.65>.

NAYAK, P. **Methodological Developments in Human Development Literature**. [S.l.], 2013. Disponível em: <https://ideas.repec.org/p/pra/mprapa/50608.html>.

NEUMAYER, E. The human development index and sustainability a constructive proposal. **Ecological Economics**, Elsevier BV, v. 39, n. 1, out. 2001. ISSN 0921-8009. Disponível em: <http://dx.doi.org/10.1016/S0921-8009(01)00201-4>.

NOORBAKHSH, F. The human development index: some technical issues and alternative indices. **Journal of International Development**, Wiley, v. 10, n. 5, jul. 1998. ISSN 1099-1328. Disponível em: <http://dx.doi.org/10.1002/(SICI)1099-1328(199807/08)10:5<589::AID-JID484>3.0.CO;2-S>.

PALAIS, R. The visualization of mathematics: Towards a mathematical exploratorium. **Notices of the AMS**, v. 46, p. 647–, 01 1999.

PEREIRA, D.; MOTA, C. Human Development Index Based on ELECTRE TRI-C Multicriteria Method: An Application in the City of Recife. **Social Indicators Research: An International and Interdisciplinary Journal for Quality-of-Life Measurement**, 2016. Disponível em: <https://ideas.repec.org/a/spr/soinre/v125y2016i1p19-45.html>.

PROVOST, F.; FAWCETT, T. Data science and its relationship to big data and data-driven decision making. **Big Data**, Mary Ann Liebert, Inc., 2013.

ROY, A. et al. Human development at the cost of the environment?an application of planetary pressuresadjusted human development index in the lens of planetary boundaries. **Environmental Science and Pollution Research**, Springer Science and Business Media LLC, v. 30, n. 12, dez. 2022. ISSN 1614-7499. Disponível em: <http://dx.doi.org/10.1007/s11356-022-24399-2>.

SACHA, D. et al. Knowledge generation model for visual analytics. **IEEE Transactions on Visualization and Computer Graphics**, IEEE, 2014.

SALAS-BOURGOIN, M. A. A proposal for a modified human development index. **CEPAL Review**, United Nations Publications, v. 2014, n. 112, dez. 2014. ISSN 1684-0348. Disponível em: <http://dx.doi.org/10.18356/ea3f94ea-en>.

SCHINCKUS, C. 1996–2016: Two decades of econophysics: Between methodological diversification and conceptual coherence. **The European Physical Journal Special Topics**, Springer Science and Business Media LLC, v. 225, n. 17-18, dez. 2016. Disponível em: <https://doi.org/10.1140/epjst/e2016-60099-y>.

SILVA, M. C. d. et al. Ranking de desempenho de municcpios: Elaboração de um único índice a partir do idhm, ifdm e irfs (performance ranking of municipalities: Development of a single index, from the idhm, ifdm ande irfs). **SSRN Electronic Journal**, Elsevier BV, 2015. ISSN 1556-5068. Disponível em: <http://dx.doi.org/10.2139/ssrn.2830936>.

SOLIGO, V. Indicadores: conceito e complexidade do mensurar em estudos de fenômenos sociais. **Estudos em Avaliação Educacional**, Fundacao Carlos Chagas, v. 23, n. 52, aug 2012. ISSN 0103-6831. Disponível em: <http://dx.doi.org/10.18222/eae235220121926>.

STANTON, E. **The Human Development Index: A History**. [S.l.], 2007. Disponível em: <https://ideas.repec.org/p/uma/periwp/wp127.html>.

THOMAS, J. J.; COOK, K. A. **Illuminating the Path: The Research and Development Agenda for Visual Analytics**. Los Alamitos, CA, USA: IEEE Computer Society Press, 2005. Sponsored by the National Visualization and Analytics Center (NVAC). ISBN 978-0-7695-2328-4. Disponível em: <http://infovis.uni-konstanz.de>.

TRZESNIAK, P. Indicadores quantitativos: reflexões que antecedem seu estabelecimento. **Ciência da Informação**, IBICT, v. 27, n. 2, 1998. ISSN 0100-1965. Disponível em: <http://dx.doi.org/10.1590/S0100-19651998000200008>.

TUFTE, E. R. **The Visual Display of Quantitative Information PAPERBACK: Second edition PAPERBACK**. [S.l.]: Graphics Pr, 2001. ISBN 1930824130.

ZGHEIB, P. W. et al. The impact of population growth on human development index: a comparative analysis of middle eastern countries. **World Review of Science, Technology and Sustainable Development**, v. 3, n. 3, 2006. Disponível em: <https://www.inderscienceonline.com/doi/abs/10.1504/WRSTSD.2006.010226>.

ZIROGIANNIS, N. et al. Human development over time: An empirical comparison of a dynamic index and the standard hdi. **Social Indicators Research**, Springer Science and Business Media LLC, v. 142, n. 2, maio 2018. ISSN 1573-0921. Disponível em: <http://dx.doi.org/10.1007/s11205-018-1926-z>.

A APÊNDICE: TABELA COM INFORMAÇÕES ESTATÍSTICAS COMPLEMENTARES DOS ESTADOS E MACRORREGIÕES DO BRASIL

Nome	Correlação Pearson	Min Scatter X	Max Scatter X	Media Scatter X	Mediana Scatter X	Variança Scatter X	Min Scatter Y	Max Scatter Y	Media Scatter Y	Mediana Scatter Y	Variança Scatter Y
Brasil	0,138	805,000	11,254M	34,278k	10,934k	41.254,737M	418,000	862,000	659,157	665,000	5,184k
Nordeste	0,373	1,253k	2,676M	31,465k	14,541k	13.299,083M	443,000	788,000	591,108	589,000	1,934k
Centro-Oeste	0,313	1,020k	2,570M	30,325k	8,545k	20.684,588M	526,000	824,000	689,468	692,500	1,391k
Sul	0,256	1,216k	1,752M	22,996k	7,045k	6.278,264M	546,000	847,000	714,113	716,000	1,730k
Norte	0,243	1,037k	1,802M	35,564k	15,051k	13.613,590M	418,000	788,000	607,951	609,000	3,619k
Sudeste	0,161	805,000	11,254M	48,099k	10,556k	110.528,163M	529,000	862,000	698,984	705,000	2,946k
AP	0,636	3,793k	398,204k	41,845k	11,600k	9.604,958M	576,000	733,000	642,812	641,000	1,824k
SE	0,610	2,275k	571,149k	28,484k	13,503k	4.688,461M	529,000	770,000	596,933	592,000	1,393k
ES	0,607	4,516k	414,586k	45,063k	17,986k	7.015,603M	622,000	845,000	692,192	683,500	1,452k
AC	0,602	4,691k	336,038k	33,344k	14,990k	4.831,210M	469,000	727,000	586,091	588,500	3,456k
RR	0,556	6,750k	284,313k	31,764k	10,943k	4.931,100M	453,000	752,000	610,200	624,000	5,427k
RO	0,531	2,315k	428,527k	30,046k	13,884k	3.720,548M	584,000	736,000	644,038	643,000	1,621k
PE	0,510	2,630k	1,538M	47,422k	20,944k	16.692,446M	487,000	788,000	596,249	593,000	2,258k
AL	0,492	2,626k	932,748k	30,767k	17,140k	8.726,088M	484,000	721,000	563,500	562,500	1,567k
TO	0,490	1,037k	228,332k	9,907k	4,592k	581,106M	500,000	788,000	639,928	639,000	2,083k
RN	0,481	1,254k	803,739k	18,964k	7,925k	4.483,719M	530,000	766,000	610,850	606,000	1,434k
PB	0,466	1,256k	723,515k	16,486k	7,143k	3.067,356M	513,000	763,000	587,655	583,000	1,431k
MA	0,452	4,020k	1,015M	30,611k	17,482k	5.402,816M	443,000	768,000	576,184	572,000	2,131k
AM	0,449	7,326k	1,802M	56,193k	22,527k	51.179,730M	450,000	737,000	565,113	564,000	2,900k
CE	0,426	4,164k	2,452M	45,937k	19,971k	33.329,621M	540,000	754,000	616,630	612,000	1,003k
SC	0,422	1,465k	515,288k	21,301k	7,458k	2.569,151M	621,000	847,000	731,648	736,000	1,613k
PA	0,404	3,431k	1,393M	53,601k	27,904k	15.672,338M	418,000	746,000	581,545	583,000	3,134k
PI	0,403	1,253k	814,230k	13,933k	6,021k	3.076,676M	485,000	751,000	571,049	565,000	1,608k
MT	0,392	1,096k	551,098k	21,452k	10,316k	2.934,518M	538,000	785,000	684,291	686,000	1,464k
MS	0,389	2,928k	786,797k	31,398k	14,629k	8.253,362M	526,000	784,000	679,705	683,000	1,694k
BA	0,338	2,612k	2,676M	33,574k	16,713k	18.509,181M	486,000	759,000	593,904	589,000	1,702k
RJ	0,327	5,269k	6,320M	169,596k	34,879k	450.911,699M	611,000	837,000	708,913	712,500	1,352k
PR	0,300	1,409k	1,752M	26,077k	8,973k	9.680,634M	546,000	823,000	701,960	706,000	1,487k
GO	0,285	1,020k	1,302M	24,745k	6,992k	8.581,145M	584,000	799,000	694,984	697,000	1,120k
MG	0,277	815,000	2,375M	23,033k	7,913k	8.813,707M	529,000	813,000	667,878	670,000	2,464k
RS	0,207	1,216k	1,409M	21,520k	5,734k	5.744,457M	587,000	805,000	713,530	717,000	1,700k
SP	0,175	805,000	11,254M	64,286k	12,799k	206.683,671M	639,000	862,000	739,527	738,000	1,055k
DF	-	-	-	-	-	-	-	-	-	-	-

Figura A.1 – Tabela estatistica contendo informações de correlação de Pearlson, mínimo, máximo, média e mediana (de IDHM e População) para 100% da amostra dos scatters de todas macrorregiões e estados do Brasil.

B APÊNDICE: HISTOGRAMAS PARA TODAS MACRORREGIÕES E ESTADOS (REGIÕES) NO BRASIL

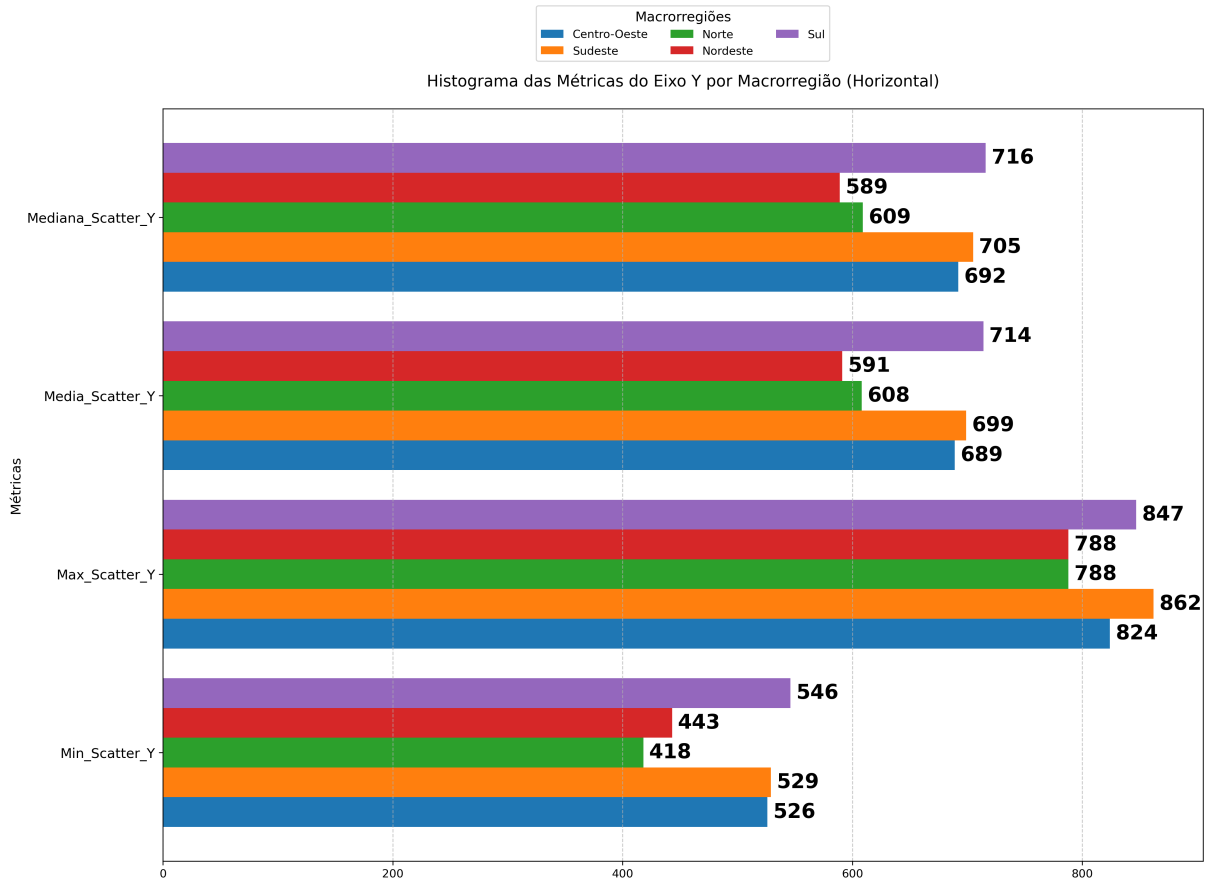

Figura B.1 – Histograma contendo informações de mínimo, máximo, média e mediana (do IDHM) para 100% da amostra dos scatters de todas macrorregiõesdo Brasil.

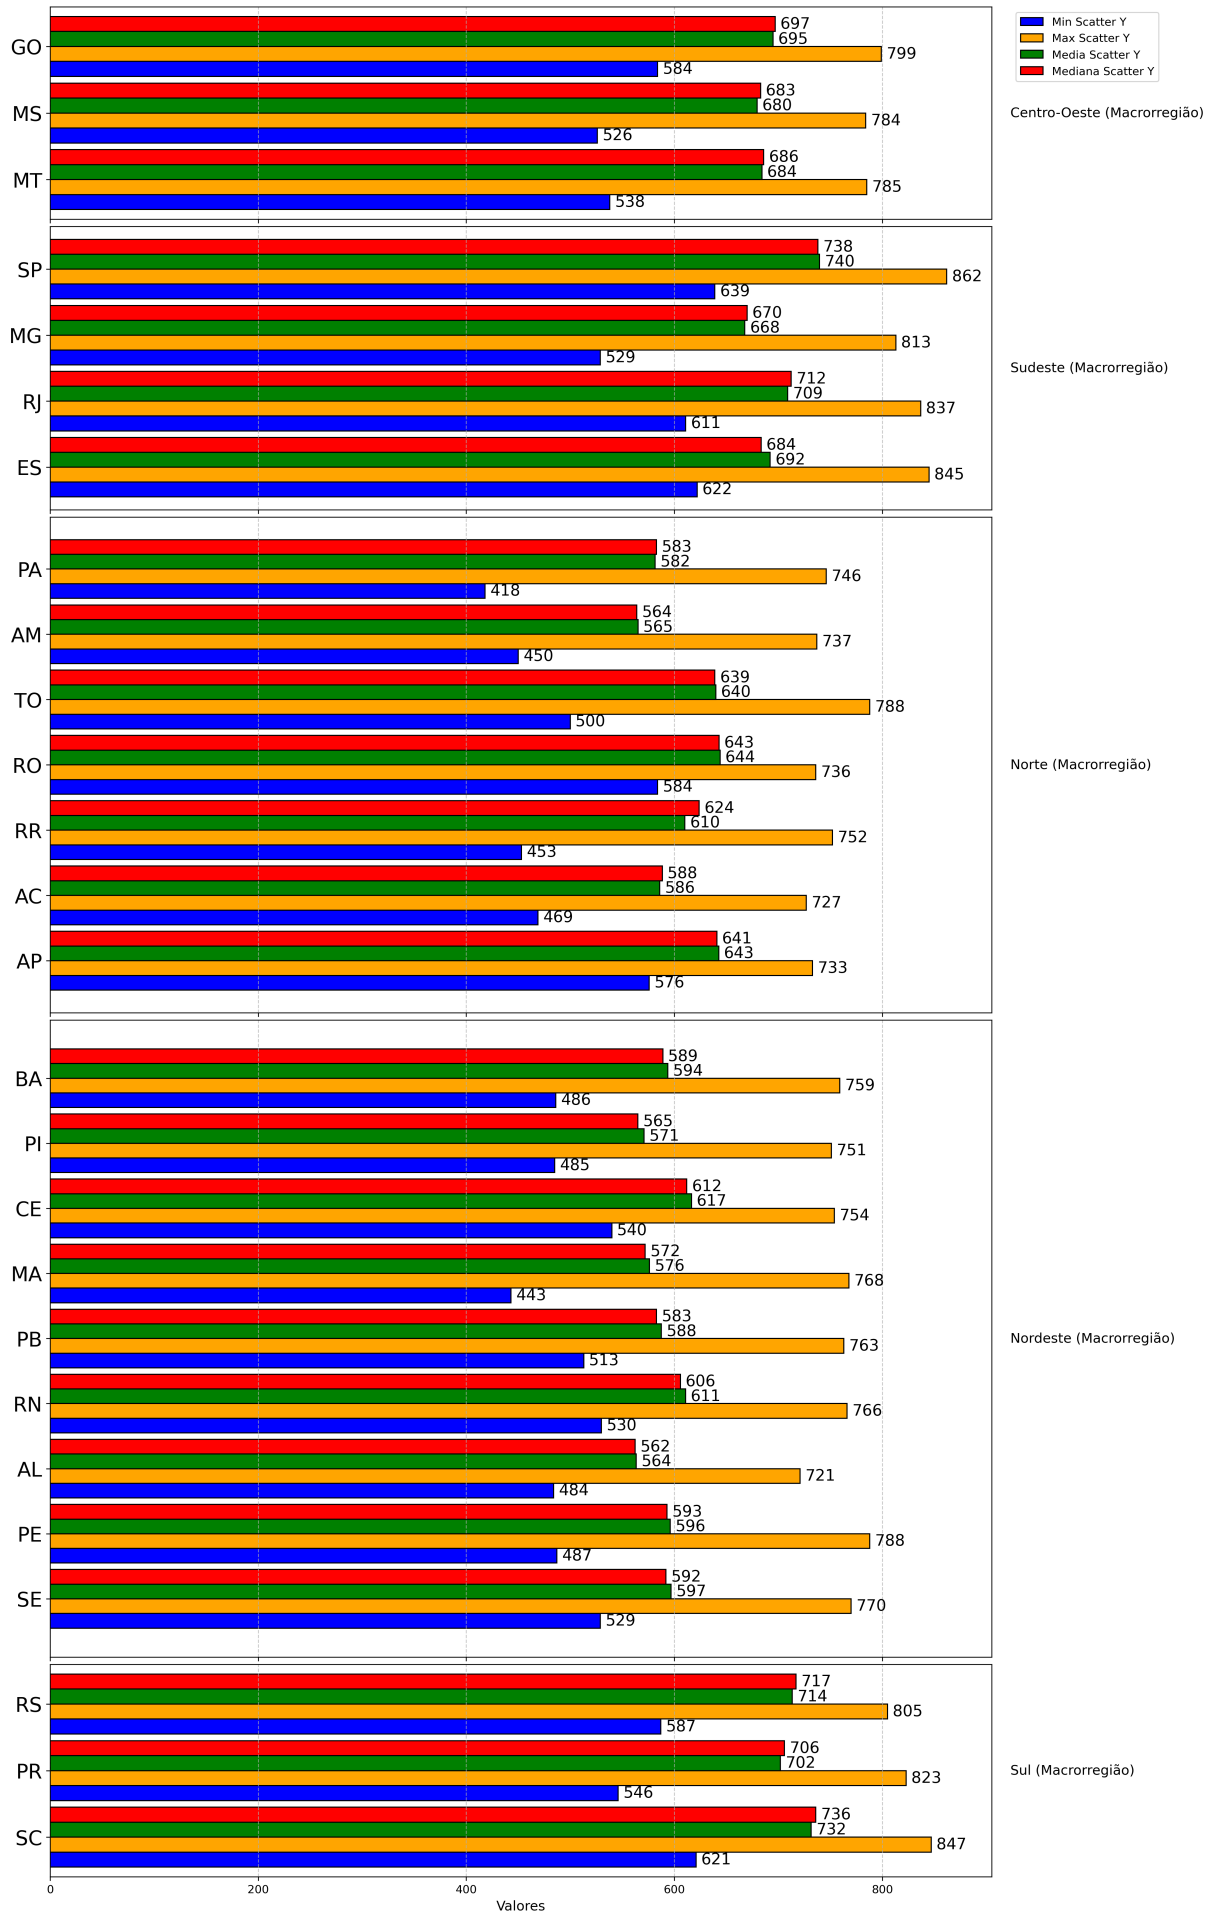

Figura B.2 – Histograma contendo informações de mínimo, máximo, média e mediana (do IDHM) para 100% da amostra dos scatters de todos estados do Brasil.

C APÊNDICE: ANÁLISE SIMPLES DE ROBUSTEZ E INFLUÊNCIA DOS VALORES DO RAIO DE CORTE (COMPARAÇÃO ENTRE PAÍSES)

Metric	Brazil	Chile	Peru	Mexico	ElSalvador	USA
Nº of nodes	5565	345	1874	2193	261	3142
Nº of edges	73597	558	5531	10122	135	33227
Average degree	26.4	3.2	5.9	9.2	1.0	21.2
Max. degree	68	14	17	34	4	59
Min. degree	0	0	0	0	0	0
Variance	198.4	8.7	14.2	45.7	1.2	211.1
Standard deviation	14.1	2.9	3.8	6.8	1.1	14.5
Average eccentricity	46	22.4	38.9	42.7	5.7	46.6

Figura C.1 – Raio de corte = 5

Metric	Brazil	Chile	Peru	Mexico	ElSalvador	USA
Nº of nodes	5565	345	1874	2193	261	3142
Nº of edges	73597	558	5531	10122	135	33227
Average degree	26.4	3.2	5.9	9.2	1.0	21.2
Max. degree	68	14	17	34	4	59
Min. degree	0	0	0	0	0	0
Variance	198.4	8.7	14.2	45.7	1.2	211.1
Standard deviation	14.1	2.9	3.8	6.8	1.1	14.5
Average eccentricity	46	22.4	38.9	42.7	5.7	46.6

Figura C.2 – Case +10% | Raio de corte = 5,5

Metric	Brazil	Chile	Peru	Mexico	ElSalvador	USA
Nº of nodes	5565	345	1874	2193	261	3142
Nº of edges	49342	361	3693	6852	89	22401
Average degree	17.7	2.1	3.9	6.2	0.7	14.3
Max. degree	49	8	14	25	4	42
Min. degree	0	0	0	0	0	0
Variance	96.5	4.2	7.5	23.1	0.8	99.6
Standard deviation	9.8	2.1	2.7	4.8	0.9	10.0
Average eccentricity	48.4	11.7	49.7	46.4	5.6	40.0

Figura C.3 – Case -10% | Raio de corte = 4,5

Tabelas de diferença percentual: entre Raio de corte = 5 vs os Casos (+10%) e (-10%) | Para todos os 6 países da tese

Métricas	Brasil	Chile	Peru	México	ElSalvador	EUA
Nº de Nós	5565.0	345.0	1874.0	2193.0	261.0	3142.0
Nº de Arestas	20.87%	22.37%	21.96%	19.80%	20.54%	20.16%
Grau Médio	20.55%	23.08%	22.92%	19.48%	11.11%	20.45%
Max. Grau	15.25%	41.67%	13.33%	13.33%	4.00%	9.26%
Min. Grau	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%
Variância	40.31%	45.00%	36.54%	37.65%	20.00%	41.77%
Desvio Padrão	18.49%	16.00%	18.75%	17.24%	10.00%	18.85%
Excentricidade Média	10.84%	117.48%	-2.06%	-4.90%	3.64%	-0.64%

Figura C.4 – Tabelas de diferença percentual: entre Raio de corte = 5 vs os Casos (+10%)

Métricas	Brasil	Chile	Peru	México	ElSalvador	EUA
Nº de Nós	5565.0	345.0	1874.0	2193.0	261.0	3142.0
Nº de Arestas	-18.97%	-20.83%	-18.57%	-18.90%	-20.54%	-18.99%
Grau Médio	-19.18%	-19.23%	-18.75%	-19.48%	-22.22%	-18.75%
Max. Grau	-16.95%	-33.33%	-6.67%	-16.67%	4.00%	-22.22%
Min. Grau	0.00%	0.00%	0.00%	0.00%	0.00%	0.00%
Variância	-31.75%	-30.00%	-27.88%	-30.42%	-20.00%	-33.11%
Desvio Padrão	-17.65%	-16.00%	-15.62%	-17.24%	-10.00%	-18.03%
Excentricidade Média	16.63%	13.59%	13.99%	3.34%	1.82%	-14.71%

Figura C.5 – Tabelas de diferença percentual: entre Raio de corte = 5 vs os Casos (-10%)

Caso EUA: Resultados B-GCA

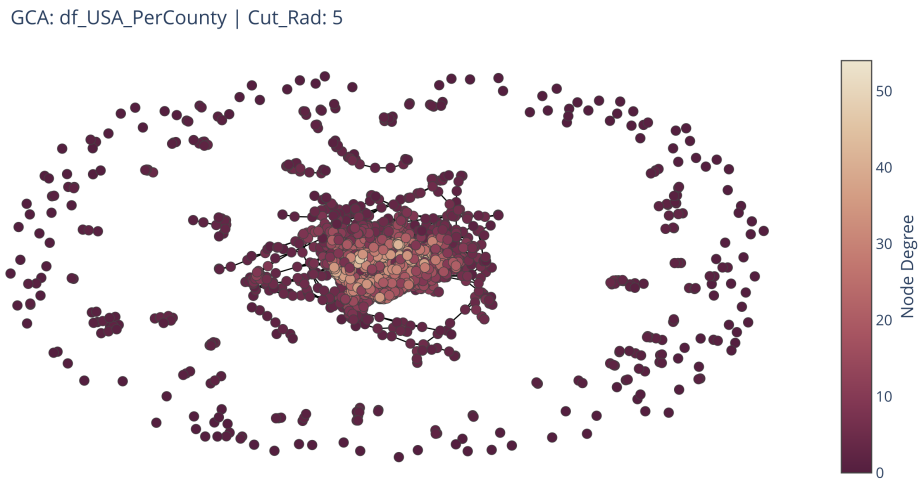

Figura C.6 – Caso EUA: Resultados B-GCA | Raio de corte = 5

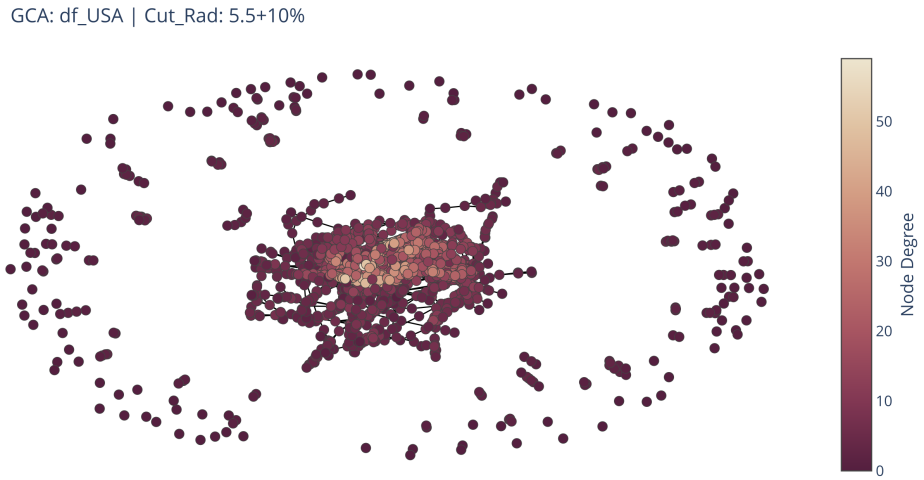

Figura C.7 – Caso EUA: Resultados B-GCA | Raio de corte = 5 + 10%

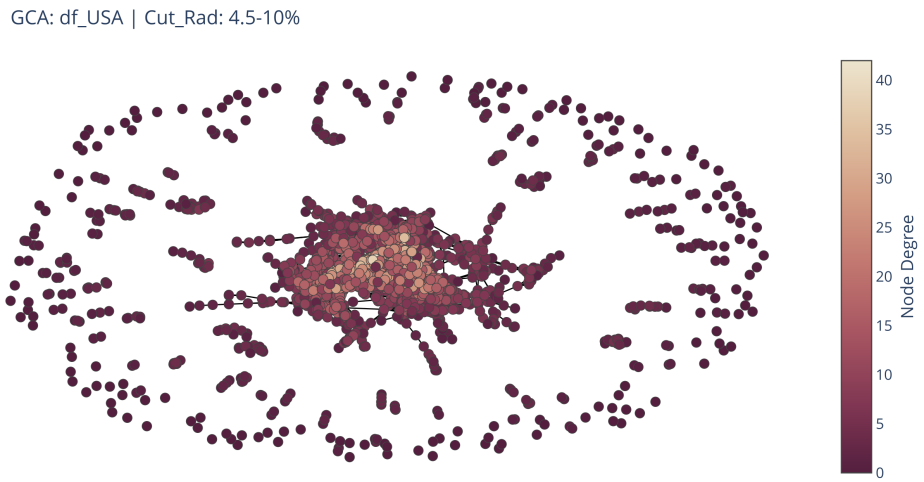

Figura C.8 – Caso EUA: Resultados B-GCA | Raio de corte = 5 -10%

Caso Chile: Resultados B-GCA

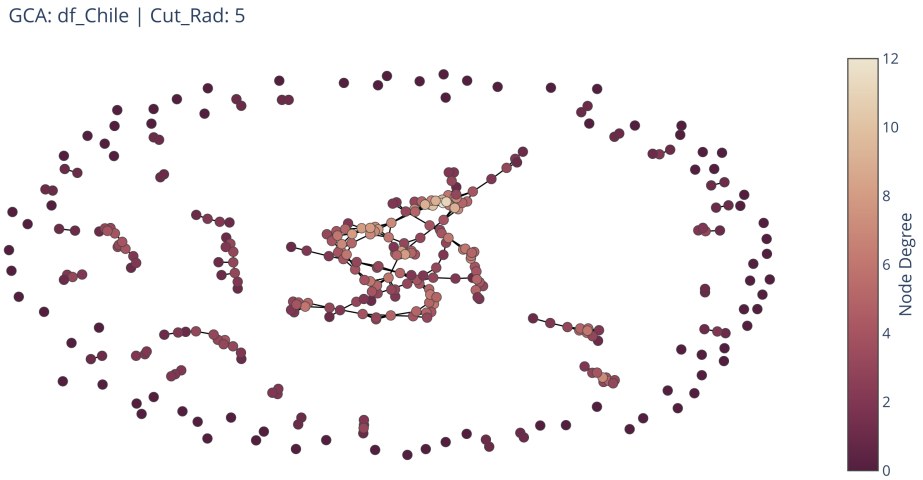

Figura C.9 – Caso Chile: Resultos B-GCA | Raio de corte = 5

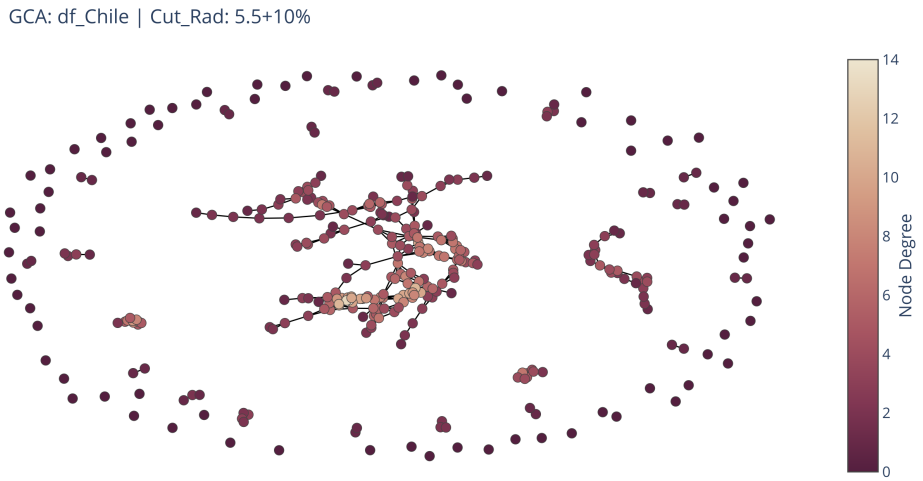

Figura C.10 – Case Chile: Result B-GCA | Raio de corte = 5 + 10%

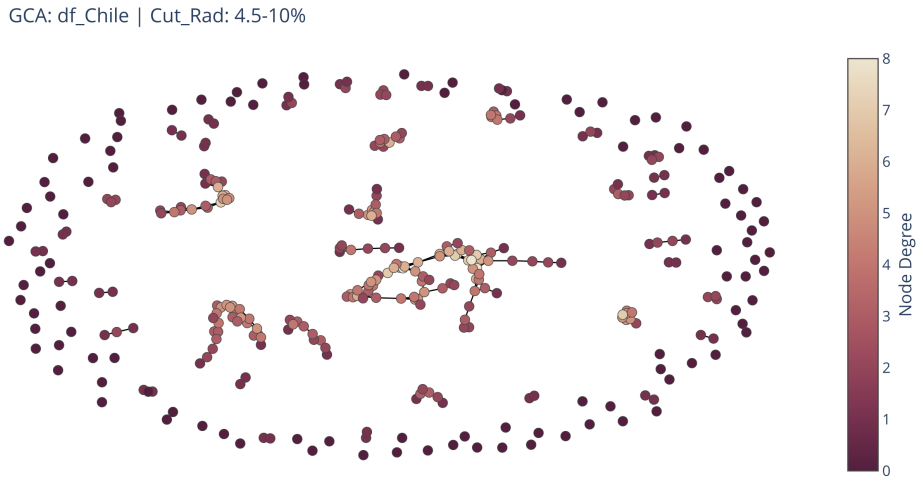

Figura C.11 – Case Chile: Result B-GCA | Raio de corte = 5 - 10%

D APÊNDICE: CITY COMPARING

A ferramenta City Comparing é uma aplicação interativa desenvolvida na plataforma Streamlit para análise comparativa de indicadores socioeconômicos em cidades, macrorregiões e países. Seu objetivo é suprir a lacuna existente na análise de cidades pequenas e médias, devido à complexidade de estruturação e comparação de dados. Com uma abordagem interdisciplinar que combina técnicas da econofísica, analytics visual e ciência de dados, a ferramenta permite que usuários explorem padrões emergentes e tendências em diversos indicadores.

Entre os principais diferenciais técnicos da ferramenta está a integração de metodologias avançadas, como os gráficos usando as técnicas apresentadas nesta tese, entre outras. Consequentemente, é possível refazer todos os gráficos da tese; testar os resultados aqui apresentados; tão como, analisar outros países e realizar estudo de casos de um país em específico, tanto em nível nacional, macrorregional quanto regional (estadual).

Outro destaque é a flexibilidade da aplicação, que permite o carregamento dinâmico de novos *datasets* para análise personalizada. Os usuários podem utilizar ferramentas interativas para explorar dados e visualizar relações complexas entre indicadores, não somente o Índice de Desenvolvimento Humano (IDH) pela população de cidade —como apresentado nesta tese.

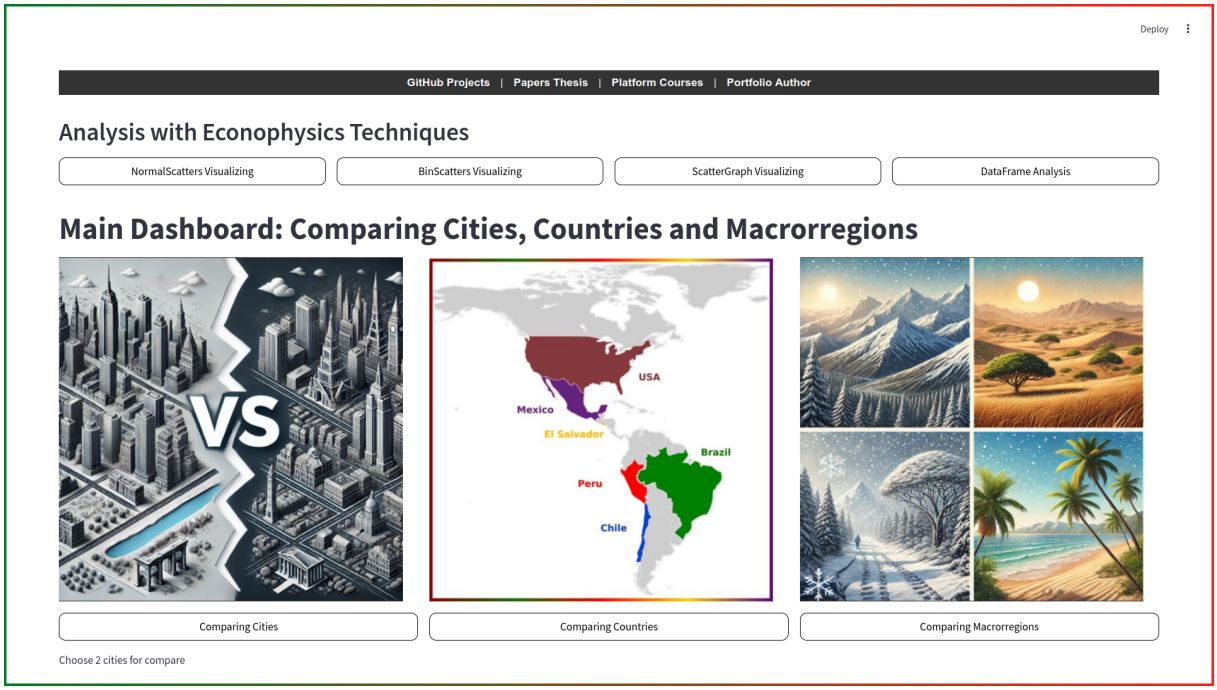

Figura D.1 – Captura de tela do dashboard principal com 3 técnicas mais complexas: NormalScatter, Binscatter e ScatterGraph (não definida e apresentada nesta tese). Além disso, inclui o modo de Análise de Distribuição e Histogramas de Dataframes. Também apresenta 3 ferramentas simples para comparação: cidades, macrorregiões e países.

A imagem apresentada de um *screenshot* do *dashboard* principal D.1, destaca os principais recursos interativos da ferramenta, incluindo o modo de comparação entre cidades, macrorregiões e países. Com uma interface intuitiva e um robusto conjunto de técnicas de análise, a ferramenta é um avanço significativo para estudos comparativos, contribuindo para análises mais abrangentes e inclusivas.

Como alguns exemplos simples de utilização, podemos gerar um gráfico de dispersão (*scatter*) interativo dos Estados Unidos D.2, onde cada ponto representa uma cidade e ao passar o mouse sobre um ponto, podemos observar mais informações detalhadas da cidade em questão, como nome, localização geográfica, população, IDHM entre outras informações que o usuário quiser adicionar no *hover* (e que tenha no *dataframe* base do gráfico).

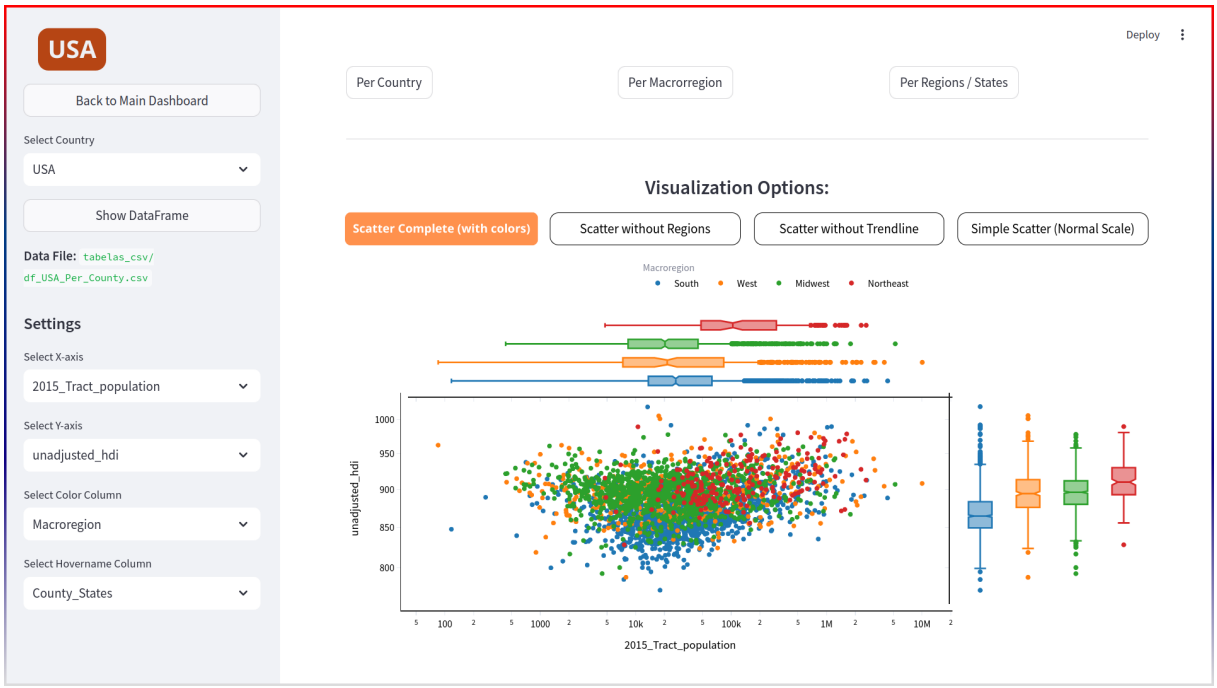

Figura D.2 – Gráfico de dispersão (*scatter)* dos EUA, com escala log-log e dividida por cores discretas de Macrorregiões: IDH por cidades vs População. Além disso, boxplots marginais para as distribuições de cada eixo, onde cada cor representa uma macrorregião.

Juntamente ao *scatter* dos EUA, é possível complementar análises por funcionalidades adicionais, como *boxplots* marginais interativos e métricas estatísticas básicas, tornando a plataforma acessível para diferentes níveis de experiência em análise de dados.

A análise de distribuição dos *bins* quanto da amostra de dados como um todo, também é possível realizar de forma interativa pela aplicação. Na imagem D.3, é possível observar os histogramas de frequência de *bins* do *dataframe* do México, especificamente para a população, tanto para o caso de 10 bins quanto 100 bins. Na ferramenta web, é possível escolher qualquer valor para divisão dos bins e todos os gráficos da imagem são gerados automaticamente, incluindo os gráficos de *binscatter*, as curvas de fit (com os valores dos coeficientes) assim como a ilustração comparativa entre *binscatter* e o *scatter*

inicial da amostra.

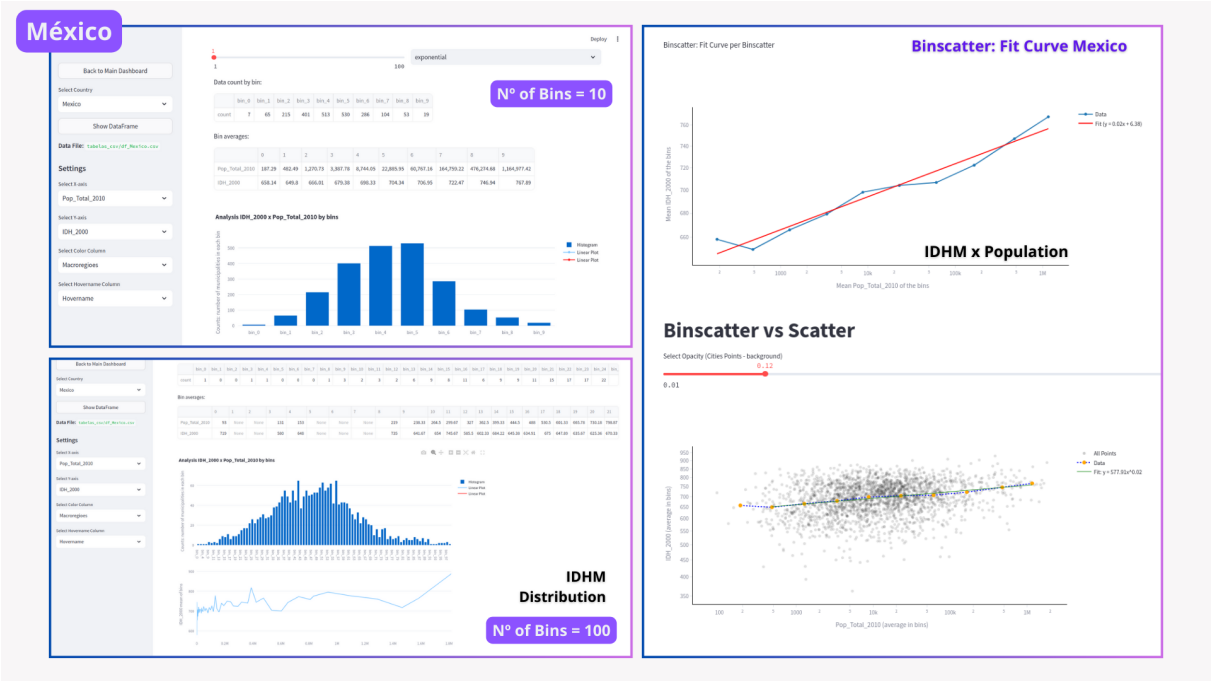

Figura D.3 – Distribuições com análise de histogramas para identificar o melhor número de intervalos (*bins*) a ser utilizado no processo de *binscatter*, para o caso do México. Em seguida, um gráfico contendo apenas a linha do *binscatter* é plotado junto com a curva de ajuste. Por fim, uma ilustração didática comparando *binscatter* com *scatter*.

Como último exemplo, é interessante apresentar e discutir a funcionalidade de comparação lado a lado de cidades que pertencem ao banco de dados.

Um desafio significativo, atualmente, é a comparação direta de indicadores entre países, especialmente quando o foco está em cidades pequenas e médias. Instituições privadas que geram dados em nível municipal tendem a se concentrar em grandes cidades, principalmente devido à dinâmica de custo-demanda de seus serviços. As dificuldades, combinadas com os altos custos necessários para coletar informações de cidades pequenas e médias, muitas vezes são proibitivamente altas.

Figura D.4 – Ferramenta para comparar cidades, entre países ou dentro do mesmo país. Na versão alfa, estão disponíveis apenas as técnicas apresentadas no trabalho. Entretanto, em versões futuras mais aprimoradas, pretendemos adicionar muitas outras funcionalidades.

Na Figura D.4, comparamos duas pequenas cidades: São Luiz Gonzaga (SLG), no interior do estado do Rio Grande do sul, Brasil, e Chachapoyas, na região de Amazonas, Peru. Cada cidade está destacada nos gráficos de dispersão com uma estrela, indicando sua localização dentro da distribuição de dados da amostra. Isso permite ao usuário inferir várias proposições: SLG é uma cidade brasileira com valores populacionais médios, posicionada entre os quartis (região interquartil) e próxima da mediana no boxplot populacional e com um IDH ligeiramente acima da média. Por outro lado, Chachapoyas está acima da média peruana tanto em população quanto em IDH, com valores populacionais próximos do quartil superior.

À primeira vista, parece que Chachapoyas é ligeiramente maior que SLG, com base nas análises de casos anteriores, que sugerem que IDH mais altos tendem a correlacionar-se com populações maiores (cidades maiores). No entanto, como essas visualizações são otimizadas para a distribuição nacional de cada país, observamos que Chachapoyas tem aproximadamente a mesma população de SLG, mesmo aparecendo mais à direita no gráfico de dispersão peruano. Isso implica, em um nível mais superficial de análise, que Chachapoyas, apesar de ter uma população semelhante à de SLG, provavelmente possui uma significância local ou nacional ligeiramente maior. No Peru, esse intervalo populacional pode indicar uma “cidade média”, enquanto no Brasil, SLG seria considerada uma “cidade pequena”.

Essa análise, ao basear-se apenas em métricas absolutas como população e IDH

de dados isolados, carece de uma relação causal mais direta e intuitiva. Se apenas valores absolutos fossem considerados, as duas cidades pareceriam muito semelhantes. No entanto, com uma visualização que contextualiza a relação da cidade com seu país, essa observaçãomais “social e local” por natureza torna-se mais acessível.

Por último e novamente, é importante destacar que essa tese apresenta a Versão Alfa da ferramenta, já funcional na web, mas com um escopo limitado em comparação aos planos de desenvolvimento futuro. Técnicas nativas, como binscatter, B-GCA e outras não apresentadas na tese, serão continuamente atualizadas para refletir avanços metodológicos e atender às necessidades emergentes dos usuários. Melhorias de desempenho e a adição de novos recursos estão planejadas para versões futuras, com o objetivo de maximizar a aplicabilidade e a eficácia da ferramenta.